

Modifiche IPA — AOT-literal universale & Input Vector flessibile

Refactor del design space P1/P2/P3 · documento delle modifiche a partire dal Task 1 · 2026

Stato di verifica. Tutto il codice è stato scritto e verificato **a livello Python** (sintassi, generazione sorgenti, risoluzione descrittore, dimensioni struct). **Non** è stato compilato né caricato nel kernel: l'ambiente di sviluppo è Windows, mentre eBPF/BCC/clang-bpf/verifier girano solo su Linux. La verifica end-to-end (compilazione BCC, verifier, `test_suite`) va fatta sul box Linux. I punti che lo richiedono sono segnalati come *“da verificare su Linux”*.

Sommario delle quattro attività

#	Attività	Esito
1	AOT-literal universale per hardcoded (P1)	FATTO
2	AOT “semplice” per template/modular	SALTATO
3	Input Vector flessibile a runtime per template (P2) e modular (P3)	FATTO
4	Pulizia codice obsoleto	FATTO
5	Polling MAC per-classe — correzione robustezza	FATTO
6	AOT-literal in sostituzione di BCC per il deploy hardcoded	FATTO
7	Profondità variabile in P1 hardcoded	FATTO
8	Trade-off larghezza vs profondità — misurato	FATTO — Linux

Il concetto chiave che ha guidato le scelte. Due assi *ortogonali*: **pesi** (literal in P1 · in mappa in P2/P3) e **compilazione** (AOT offline · BCC a runtime). “AOT-literal” = literal $\wedge$ AOT, specifico di P1. Non è applicabile ai map-based senza snaturarli (Task 2). Invece la **flessibilità dell'IV** (descrittore per-modello) è ortogonale e si porta ovunque (Task 3).

Task 1 — AOT-literal universale (hardcoded P1) FATTO

Problema di partenza

Il generatore AOT offline (`gen_full_c.py` , dialetto libbpf) era **cablato** al solo descrittore default `65-4-4-7` .
Qualsiasi descrittore sparse/eterogeneo era supportato solo dal path BCC (`ebpf_program.py`), non dall'AOT.
Un guard rifiutava i descrittori non-default.

Cosa è cambiato

`gen_full_c.py` è ora **descrittore-driven**: i 3 *kind* di feature sono stati portati dal dialetto BCC al dialetto libbpf, riproducendo la stessa logica di `ebpf_program._gen_feature_*` :

```
scalar          -> ttl = ip->ttl                (dal pacchetto)
dense_vector_map -> ls0..lsN via 1 bpf_map_lookup_elem (link_state / queue_state)
onehot          -> un solo switch che seleziona 1 peso (ingress_iface / node)
```

Ogni descrittore accettato dal BCC è ora anche **AOT-compilabile**. Le mappe dense (`link_state` , `queue_state`) vengono emesse solo se il descrittore le usa, dimensionate dalla topologia.

File modificati

File	Modifica
<code>shared/poc_aot/gen_full_c.py</code>	Riscritto descrittore-driven: <code>_feat_scalar/_feat_dense_vector/_feat_onehot_*</code> , <code>_emit_maps()</code> per-descrittore, <code>_resolve_shape()</code> via <code>model_meta.derive_shape</code> .
<code>shared/methods/method4_hardcoded_aot.py</code>	Rimosso il guard <code>_check_supported / _SUPPORTED</code> ; passa <code>meta + topology_config</code> al generatore.
<code>shared/poc_aot/loader_aot.c</code>	Seeding generico: <code>seed_vec_map()</code> semina <code>link_state / queue_state</code> solo se presenti (dimensione dalla mappa); classi <code>mac_table</code> derivate da <code>n_out</code> .

Come funziona adesso

- **Default** `[link_state, ingress_iface, ttl, node]` → `65-4-4-7` **byte-identico** a prima (stessi pesi, stesse colonne; ora combacia col dialetto BCC).
- **Custom** es. `[link_state, queue_occupancy, ttl]` → `n_in=11` , emette mappa `queue_state` , `qs0..qs3` , niente node/iface.
- Il path **BCC resta intatto** come fallback garantito.

Verificato (Python). Diff generatore nuovo vs vecchio sul default: solo differenze cosmetiche + riordino commutativo dei termini, *pesi e colonne identici*. Descrittore custom: mappa `queue_state` emessa, slicing pesi corretto (bias a offset 44 per 11-4-4-7).

Task 2 — AOT “semplice” per template/modular SALTATO

Sconsigliato e non implementato. Motivo: **beneficio marginale per design**. Template e modular compilano **una sola volta** all'avvio (il programma è indipendente dal modello; nuovo modello = solo `bpf_map_update_elem`). L'AOT toglierebbe una singola compilazione di startup, non i “1660 ms per modello” che affliggono solo P1. In più richiederebbe riscrivere due programmi interi dal dialetto BCC a libbpf. Costo alto, ritorno quasi nullo.

Task 3 — Input Vector flessibile a runtime (P2 template, P3 modular) FATTO

Problema di partenza

Le pipeline map-based avevano l'IV **cablato** al layout protocollare a 65 (link_state 0-5, iface one-hot 6-11, ttl 12, node one-hot 13-64), con offset fissi nel C. I pesi erano già in mappa (nessuna ricompilazione per modello) ma il *layout delle feature* era rigido: tutti i modelli dovevano usare le stesse 4 feature nello stesso ordine.

Decisioni di design (confermate)

Decisione	Scelta
Sorgente del descrittore a runtime	Registry map <code>model_desc[model_id]</code> , popolata dal control plane. NON dal pacchetto (autorevole, niente fiducia nel traffico, zero costo/pacchetto extra oltre 1 lookup).
Ceilings di unroll	<code>MAX_FEAT=4</code> . Le dimensioni dense sono topology-fixed (link_state=6, queue=4); i one-hot grandi (node 52) sono un <i>singolo lookup runtime-indexed</i> , non srotolati.
Tecnica di loop	<code>#pragma unroll</code> (portabile, stile esistente; nessuna dipendenza da kernel ≥ 5.13).
Coppie <code>feat*</code> dell'header IPA	Restano metadata/osservabilità , NON sorgente dell'IV.

La nuova registry `model_desc`

```
#define MAX_FEAT 4
struct feat_ent { __u8 code; __u8 size; __u8 col_off; __u8 _pad; };
struct model_desc { __u8 n_feat; __u8 n_in; __u8 _p0; __u8 _p1;
                    struct feat_ent feats[MAX_FEAT]; }; /* 20 byte */
BPF_HASH(model_desc, __u8 model_id, struct model_desc, 256);
```

`col_off` = colonna iniziale della feature nella riga di input di fc1 (somma cumulativa delle size precedenti). Il control plane la calcola con `model_meta.resolve_descriptor()`, così l'IV a runtime coincide col layout dei pesi allenati.

Il primo layer, ora descrittore-driven

Gli offset cablati (+12 ttl, +13 node, 5+iface) sono sostituiti da un loop unrolled su MAX_FEAT che, per ogni neurone j , accumula il contributo di ogni feature dichiarata alla sua colonna runtime:

```
for (f = 0; f < MAX_FEAT; f++) if (f < desc->n_feat) {
    base = woff + fc1_w_off + j*n_in + desc->feats[f].col_off;
    switch (code) {
        TTL          -> acc += _ttl * W(base);
        LINK_STATE    -> for i<size: acc += ls[i] * W(base+i);    // unroll 6
        QUEUE_OCC      -> for i<size: acc += qs[i] * W(base+i);    // unroll 4
        INGRESS_IF     -> if active: acc += W(base + (iface-1));    // 1 lookup
        NODE           -> if node<size: acc += W(base + node);    // 1 lookup
    }
}
```

n_in è ora runtime (da model_desc) e guida il layout dei pesi (fc1_b_off = n_in*n_h1 , ecc.). Gli indici restano *bounded* (il check idx >= MAX_WEIGHT_ENTRIES / il lookup che ritorna NULL) → verifier-safe.

File modificati

shared/model_meta.py	Aggiunti FEATURE_CODE (codici numerici, sorgente unica: link_state=1, iface=2, ttl=3, node=4, queue=5) e resolve_descriptor() (→ lista {code,size,col_off}).
shared/ebpf_template_arch.py	Mappe model_desc + queue_state ; fc1 descrittore-driven; n_in runtime nel layout pesi; arch_weight_count(n_h1,n_h2,n_in) parametrizzato; load_model_desc() ; load_arch_weights() semina model_desc (default) internamente.
shared/ebpf_modular.py	Stesse mappe/strutture nel common header; layer_first descrittore-driven; check first-layer n_in==65 rilassato a [1,128] ; load_model_desc() ; load_modular_weights() semina model_desc internamente.
shared/methods/method5_template.py , method6_modular.py	Nessuna chiamata extra necessaria (il seeding è integrato nei loader dei pesi).

Verificato (Python). Il descrittore default risolve a [(1,6,0),(2,6,6),(3,1,12),(4,52,13)] , n_in 65 → **esattamente** gli offset cablati vecchi (comportamento byte-identico). Descrittore custom [link_state,queue,ttl] → col_off 0/6/10 . Struct model_desc = 20 byte (combacia col C). Conteggio mappe: template 2/2 (dispatcher + ramo standalone), modular 1/1 (common header incluso una volta). Zero offset cablati residui.

Compatibilità test harness. Il seeding di model_desc è stato **integrato dentro** load_arch_weights() e load_modular_weights() : così *tutti* i chiamanti esistenti (i metodi e i test: verify_prog_run , verify_multi_model , bench_model_add , test_suite) registrano il descrittore default senza modifiche. Senza questo, l'inferenza avrebbe restituito XDP_PASS (lookup fallito).

Nota sulla narrativa design-space

P2/P3 diventano **descrittore-flessibili** come P1: non più "65 fisso". Da concordare col relatore come impatta il confronto della tesi.

Task 4 — Pulizia obsoleti FATTO

Codebase risultato pulito. Eliminati 3 alias di retrocompatibilità **morti** (0 usi) in `shared/model_meta.py`, residui del refactor `node_config` → `topology_config`:

- `DEFAULT_NODE_CONFIG` (alias di `DEFAULT_TOPOLOGY_CONFIG`)
- `load_node_config` (alias di `load_topology_config`)
- `node_config_for` (alias di `topology_config_for`)

Il resto (`method4/5/6`, `test_ipa`, `fix_bpf.sh`, `host_headers`, `weights_method2.json`) è attivo e conservato. Rimosso anche il guard obsoleto `_check_supported` dell'AOT (parte del Task 1).

Task 5 — Polling MAC per-classe: correzione FATTO

Problema di partenza

`install_mac_per_class()` (già introdotta per far sì che ogni classe dell'argmax usi il MAC risolto via ARP della **propria** porta egress, non sempre la stessa) aveva due difetti scoperti in revisione:

- **Doppia lettura ARP disallineata**: la funzione risolveva il MAC del vicino internamente, poi ciascun metodo (`method4/5/6`) rifaceva *una seconda* lettura di `/proc/net/arp` per decidere quali classi avviare in polling di refresh. Tra le due letture l'ARP poteva risolversi → il thread di refresh non veniva avviato per una classe in realtà ancora sul MAC di fallback, oppure veniva avviato per una classe già corretta.
- **Thread di refresh che si auto-terminava**: `start_mac_refresh_thread` usciva dal loop non appena tutte le classi avevano risolto una volta. Ma una entry ARP può scadere o il vicino dietro una porta può cambiare (flap, riavvio) — dopo l'uscita del thread nessuno correggeva più la entry nella mappa BPF.

Cosa è cambiato

`install_mac_per_class()` ora calcola risoluzione ARP e "quali classi restano in fallback" nella **stessa, unica lettura**, e ritorna `{"installed": [...], "pending": [(cls, iface), ...]}`. I tre metodi passano `pending` direttamente a `start_mac_refresh_thread`, senza ricalcolarlo. Il thread di refresh ora gira per **tutta la vita della pipeline** (non esce più al primo giro completo), riscrivendo la entry BPF solo quando il MAC risolto cambia rispetto all'ultimo scritto — quindi in stato stazionario è di sola lettura, nessun overhead di scrittura extra.

File modificati

File	Modifica
<code>shared/common.py</code>	<code>install_mac_per_class()</code> ritorna <code>{"installed", "pending"}</code> da un'unica lettura ARP; <code>start_mac_refresh_thread()</code> gira indefinitamente, scrive solo sui cambiamenti.
<code>shared/methods/method4_hardcoded.py</code> , <code>method5_template.py</code> , <code>method6_modular.py</code>	Consumano <code>mac_info["pending"]</code> invece di ricalcolare con una seconda <code>neighbor_mac()</code> .

Verificato (Linux, Kathara). Il comportamento per-classe (`class 0 -> eth0` , `class 1 -> eth1` , ecc., ARP-risolto) era già confermato funzionante prima di questa correzione; la correzione riguarda solo la **robustezza** del polling (niente più doppia lettura disallineata, niente più thread che smette di sorvegliare). Consigliato un nuovo giro di fumo su Kathara dopo l'update, dato che la firma di ritorno è cambiata.

Task 6 — AOT-literal in sostituzione di BCC per il deploy hardcoded

FATTO

Richiesta esplicita del relatore: AOT-literal deve **sostituire** BCC come backend di deploy per hardcoded, non restare una semplice alternativa. Fatto. Il vincolo che inizialmente sembrava bloccante — i nodi Kathara non hanno `clang /libbpf ( FileNotFoundError: clang )` — riguardava solo la *build* (che infatti resta offline, su build-box) e il **loader** (`loader_aot.c`), che era linkato **dinamicamente** contro libbpf: un binario compilato altrove non sarebbe comunque partito su un nodo senza `libbpf.so` .

Fix: `loader_aot.c` ora si linka **staticamente** contro libbpf (+ libelf/zlib, sue dipendenze), lasciando dinamica solo libc — binario autosufficiente, buildato una volta su una build-box, eseguibile su qualunque nodo Kathara senza clang/libbpf installati. `execute_pipeline.py` non offre più la scelta `--hardcoded-backend` : AOT-literal è l'unico percorso di deploy per hardcoded.

Eccezione mantenuta, deliberata: l'infrastruttura di test interna (`verify_prog_run.py` , `test_suite.py --only kernel`) continua a usare BCC per compilare-e-verificare — non gira mai sul nodo datapath in produzione, è un problema distinto dal deploy.

Task 7 — Profondità variabile in P1 hardcoded

FATTO

Problema di partenza

Sia il generatore BCC (`ebpf_program.generate_ebpf_hardcoded`) sia quello AOT (`gen_full_c._emit_model_body`) avevano la profondità **cablata a 2 hidden layer** (`n_h1` , `n_h2 = hidden_dims`). Anche il riferimento Python usato dal kernel test (`verify_prog_run.ref_infer_sparse`) assumeva esattamente 2 layer.

Cosa è cambiato

`hidden_dims` è ora una sequenza di **lunghezza qualsiasi**: `(4,4)` (storico), `(8,)` (1 layer), `(4,4,4,4)` (4 layer), `()` (modello lineare puro, nessun hidden layer). Layout dei pesi generico per-layer (`n_prev*n_cur` pesi poi `n_cur` bias, layer per layer), che si riduce esattamente al vecchio schema a 2 layer quando `hidden_dims == (n_h1, n_h2)` .

File modificati

File	Modifica
<code>shared/ebpf_program.py</code>	<code>generate_ebpf_hardcoded</code> : <code>layer_sizes = [n_in] + dims + [n_out]</code> , loop generico sui layer invece di <code>fc1/fc2/out</code> cablati; gestisce anche 0 hidden layer (il primo layer diventa direttamente l'output, niente ReLU).
<code>shared/poc_aot/gen_full_c.py</code>	Stessa generalizzazione lato AOT: <code>_layer_sizes()</code> , <code>_weight_count()</code> , <code>_slices()</code> parametrici sul numero di layer.
<code>shared/test/verify_prog_run.py</code>	<code>ref_infer_sparse</code> : stesso schema generico per-layer lato riferimento Python (il PASS/FAIL del kernel test ora funziona per qualunque profondità, non solo 2).
<code>shared/methods/method4_hardcoded_aot.py</code>	Bonus: corretto un <code>NameError</code> latente (<code>build_ms</code> referenziato non definito nel path "clang assente, riuso <code>.o</code> prebuilt" senza <code>--iface</code>).

Verificato (Python). Output del generatore BCC per `hidden_dims=(4,4)` confrontato byte-per-byte con la versione precedente al refactor: identico (a meno di righe vuote). Riferimento Python generalizzato confrontato numericamente contro la vecchia implementazione esplicita a 2 layer su pesi/input casuali: risultato identico (stessa classe, stesso valore). `model_meta.json` 's `hidden_dims` (già letto ovunque) accetta ora qualunque profondità senza altre modifiche.

Task 8 — Trade-off larghezza vs profondità (P1 hardcoded)

FATTO — misurato su Linux

Domanda

A parità di budget di pesi, conviene aumentare i neuroni di un layer (**largo**) o aggiungere un nuovo layer (**profondo**)? Nuovo script: `shared/test/bench_depth_vs_width.py` .

Metodologia

- **3 tier a budget-pesi abbinato** (A ~300, B ~1200, C ~4700 pesi), ciascuno con una forma larga (1 layer) e due profonde (4 e 8 layer), scarto di pesi dichiarato esplicitamente (mai assunto "circa uguale").
- **4 descrittori di feature diversi** (0, 1, 2 feature one-hot; one-hot piccola vs grande) per isolare l'effetto del descrittore da un effetto generale larghezza/profondità — il descrittore di default ha una feature one-hot

molto costosa (node , size 52) che avrebbe potuto falsare la conclusione se testata da sola.

- **Statistica: minimo su 7 trial indipendenti**, non media/mediana di un solo campione. Un run preliminare con un solo campione (repeat=2000) mostrava oscillazioni fino a 20× senza alcuna correlazione col numero di istruzioni — rumore di sistema **a senso unico** (un interrupt/scheduling può solo rallentare un trial, mai accelerarlo), quindi il minimo è la statistica corretta per stimare il costo al netto delle interferenze (stesso principio di hyperfine / Google Benchmark).
- **Isolamento in subprocess**: quando una forma sfiora lo stack eBPF di 512 byte, il backend LLVM di BCC termina con un abort **fatale, non catturabile** come eccezione Python. Due tentativi di stimare a priori la soglia di overflow con una formula sono stati smentiti dal comportamento reale del compilatore (-O2 a volte riesce a riutilizzare slot di stack, a volte no, in modo non prevedibile). Soluzione: ogni cella (descrittore × forma) gira nel suo **proprio subprocess** — un crash marca solo quella cella e lo sweep prosegue.

Risultato (minimo su 7 trial, 4 descrittori, box Linux)

Tier	Forma	Pesi	ns/pkt (min, range sui 4 descrittori)
A (~100-320 pesi)	baseline / wide 1 layer	~90-320	44 - 56 ns
	deep 8×3	~150-310	57 - 76 ns (overhead profondità: +13/+32 ns)
B (~300-1300 pesi)	wide 1×16	~310-1175	103 - 111 ns (sempre il più veloce)
	deep 4×11	~610-1210	203 - 236 ns (~2× più lento)
	deep 8×9	~810-1295	269 - 301 ns (~2.5-3× più lento)
C (~1200-4700 pesi)	tutte (wide/deep 4/deep 8)	—	CRASH sempre , ogni descrittore, ogni forma

Cosa significa

A parità di budget-pesi, allargare batte approfondire — risultato coerente su tutti e 4 i descrittori indipendenti testati (non un artefatto delle feature one-hot del descrittore di default). Ogni layer nascosto in più costa un overhead fisso (~15-40 ns/layer, transizione + ReLU) indipendente dalla composizione delle feature. Al budget più piccolo (Tier A) la differenza è presente ma contenuta; al budget medio (Tier B) diventa un fattore 2-3×.

Tetto di capacità assoluto: oltre ~1200-1300 pesi lo stack eBPF (512 byte) va in overflow **sempre**, larga o profonda che sia la rete — non è una scelta di design larghezza/profondità, è un limite strutturale dell'architettura "tutto srotolato in un'unica funzione C, pesi come literal". Per modelli più grandi serve spostare gli array grandi in una BPF per-cpu array map (suggerimento diretto del compilatore nel messaggio di errore), non più semplicemente redistribuire gli stessi pesi su più layer.

Come rilanciare


```
sudo python3 shared/test/bench_depth_vs_width.py                # tutti i 4 descrittori
sudo python3 shared/test/bench_depth_vs_width.py --descriptor no_onehot
sudo python3 shared/test/bench_depth_vs_width.py --repeat 5000    # più stabile, più lento
```

Come testare (sul box Linux)

```
# Task 1 – AOT-literal universale
python3 shared/methods/method4_hardcoded_aot.py            # default 65-4-4-7
#   + con un model_meta.json custom accanto al .pt per un descrittore sparse

# Task 3 – P2/P3 con IV descrittore-driven (default => output invariato)
sudo python3 shared/execute_pipeline.py --method template --iface eth0 --model-id 0
sudo python3 shared/execute_pipeline.py --method modular  --iface eth0 --model-id 0

# Regressione / verifier / perf
sudo python3 shared/test/test_suite.py --kernel
sudo python3 shared/test/verify_prog_run.py
sudo python3 shared/test/verify_multi_model.py
```

Cosa controllare per primo su Linux. (1) Che i tre programmi **passino il verifier** col nuovo primo layer unrolled (budget complessità). (2) Che l'output del descrittore **default** sia identico a prima (regressione byte-compatibile). (3) Se un descrittore usa `queue_occupancy`, seminare `queue_state` via `queue_state_monitor.init_queue_state()` nel control plane.

Riepilogo in una riga

L'**AOT-literal** non è più bloccato al 65-4-4-7 (P1), e l'**Input Vector** è ora **descrittore-driven a runtime** anche nei map-based P2/P3 (via registry `model_desc`), con il descrittore default byte-compatibile ovunque. Task 2 saltato (non conveniente per design), obsoleti rimossi. Tutto scritto e verificato in Python; **compilazione e verifier da eseguire su Linux**.

Aggiornamenti successivi (Task 5-8, questi **verificati/misurati su Linux**): polling MAC per-classe reso robusto (unica lettura ARP, refresh perenne); AOT-literal ora sostituisce BCC come backend di deploy per hardcoded (richiesta del relatore — loader linkato staticamente contro libbpf, BCC resta solo per il test harness interno); P1 hardcoded ora supporta **profondità arbitraria** (non più fissa a 2 hidden layer); misurato che a parità di budget-pesi **allargare batte approfondire** (2-3× più veloce), coerente su 4 descrittori di feature indipendenti, con un tetto di capacità assoluto ~1200-1300 pesi per l'architettura attuale.