Inferenza di una rete neurale nel kernel Linux

Le slide una alla volta, ognuna con la sua spiegazione

Ogni pagina ha l'immagine di una slide e sotto la spiegazione. I riquadri grigi sono **esempi con i numeri**; i riquadri gialli segnalano i **punti da correggere o da dire con cautela**; i riquadri verdi le **verifiche** fatte ricontrollando i dati.

Le parole e le unità che tornano sempre

Nodo	Il computer che riceve il pacchetto, esegue la rete neurale per scegliere da quale porta farlo uscire, e lo inoltra.
XDP, eBPF	XDP è il primo punto del kernel Linux in cui un programma può vedere un pacchetto appena arrivato; eBPF è il linguaggio di quei programmi, che il kernel controlla prima di eseguirli.
Versione (P1, P1.5, P2, P3)	Uno dei quattro modi di scrivere il programma che esegue la rete neurale: da tutto scritto nel programma (P1) a tutto letto da tabelle (P3).
Senza rete (baseline)	Il nodo che riceve e inoltra senza eseguire nessuna rete neurale: il costo fisso che ogni versione paga. «Solo ricezione» riceve e basta.
Tabella	Una zona di memoria del kernel che il programma consulta mentre gira e che si può riscrivere senza ricompilarlo (in eBPF si chiama mappa).
Salto fra programmi	Il passaggio da un programma eBPF a un altro (tail call). P3 ne fa uno per ogni strato della rete.
Compilare	Tradurre il programma in codice eseguibile. P1 si compila per ogni modello nuovo, fuori dal nodo; P2 e P3 una volta sola.
Popolazione	Le 91 reti neurali generate su cui gira ogni misura: diverse per ingressi, strati, neuroni, pesi e pesi a zero.
Mediana, fra i modelli	La mediana sui modelli: metà costa meno, metà di più. «Fra i modelli da A a B»: il modello più leggero e il più pesante, che sono reti diverse, non un errore di misura.
Rumore di misura	Quanto cambia la stessa misura rifatta in un'altra sessione: fino al 5 % (90° percentile). Una differenza più piccola non è una differenza, e un rapporto fra due misure di sessioni diverse può uscire poco sopra 100 %.
Legge di costo	Costo della rete ≈ parte fissa + moltiplicazioni × costo di una + strati × costo di uno, stimata su tutti i modelli e provata su modelli lasciati fuori.

Moltiplicazioni eseguite	Le moltiplicazioni che il programma fa davvero per un pacchetto (in inglese MAC). Un ingresso con molte colonne di cui una sola vale 1 ne conta una.
Capacità	Quanti pacchetti al secondo il nodo riesce a elaborare al massimo.
Costo per pacchetto	Il tempo di processore per elaborare un pacchetto: 1 diviso la capacità. 2 milioni di pacchetti al secondo = 500 ns per pacchetto.
ns, µs, ms	Nanosecondi (miliardesimi di secondo), microsecondi (1 µs = 1 000 ns), millisecondi (1 ms = 1 000 µs).
Nodo pieno	Il generatore manda più pacchetti di quanti il nodo ne regga: la coda resta piena e il core lavora il 100 % del tempo.
Coda	I posti davanti al nodo dove i pacchetti aspettano. Se è piena, chi arriva è respinto.
Collo di bottiglia	Il pezzo più lento della catena: decide quanto traffico passa.
P-core, E-core, LP E-core	I tre tipi di core del processore: veloci, efficienti (a gruppi di quattro che condividono una cache) e a basso consumo (in un'altra parte del chip, al massimo 2,5 GHz).
Ciclo di clock, IPC	Il ciclo è il battito dell'orologio del core (3,5 miliardi al secondo a 3,5 GHz). IPC = istruzioni eseguite per ciclo: dice quanto lavoro il core fa a ogni battito.
Istruzioni per pacchetto	Quante istruzioni il processore esegue per ogni pacchetto, contate dal processore stesso. Dipendono dal codice, non dal core.
Cache	Una piccola memoria veloce vicino al core. Un dato che non c'è va letto dalla memoria principale, molto più lenta.
Tre orologi	Una versione del programma legge l'orologio all'ingresso, prima di inoltrare e all'arrivo al nodo successivo: separa il tempo del programma da quello del trasporto.
Programma da solo	Il kernel esegue il programma su un pacchetto preparato, senza traffico: serve a contare letture di tabella e salti, e a misurare il cambio di modello.

Come si misura e da dove vengono i tempi

Che cosa fa il nodo. In una rete di calcolatori ogni nodo riceve pacchetti e deve decidere da quale porta farli ripartire. Qui la decisione la prende una piccola **rete neurale** che gira **dentro il kernel Linux**, nel primo punto in cui il pacchetto arriva (XDP, una funzione del kernel che lascia eseguire un programma su ogni pacchetto appena ricevuto). Il programma legge alcune informazioni (lo stato dei collegamenti, la porta d'ingresso, il TTL, cioè quanti salti di rete restano al pacchetto), le dà alla rete neurale, e inoltra il pacchetto sulla porta che la rete sceglie, oppure lo scarta.

Il banco. Un solo portatile fa tutto: il generatore di traffico, il nodo che esegue la rete neurale e il nodo successivo che riceve i pacchetti inoltrati. Sono collegati da cavi virtuali; il programma del nodo vede ogni pacchetto come lo vedrebbe da una scheda di rete vera. Ogni ruolo ha un core del processore tutto suo.

Le condizioni della macchina. Lasciato a sé stesso, il portatile cambia velocità di continuo, addormenta i core e mette altri programmi sul core che sta misurando. Prima di ogni misura il banco fissa la frequenza dei core a 3,5 GHz, impedisce che si addormentino, sposta il resto del sistema su altri core e sorveglia la macchina (frequenza, temperatura, rallentamenti per calore, alimentazione). Una misura in cui la macchina esce da queste condizioni viene marcata e non entra nelle conclusioni.

I tre tipi di core. Il processore (Intel Core Ultra 7 155H) ha core **veloci** (P-core), core **efficienti** (E-core) e due core **a basso consumo** (LP E-core), che stanno in un'altra parte del chip. Dove non è detto altro, il nodo gira su un P-core.

La popolazione di modelli. Ogni misura è ripetuta su **91 reti neurali diverse**, generate apposta. Hanno da 5 a 117 ingressi, da 1 a 6 strati nascosti, da 2 a 8 neuroni per strato, da 3 a 7 uscite, da 21 a 1 349 pesi. Sono di quattro tipi:

- il **disegno principale** (53 modelli): le combinazioni di tipo d'ingresso, numero di strati e larghezza;
- le **repliche** (20): sei forme ripetute con pesi estratti a caso in modo diverso, per vedere quanto contano i valori dei pesi;
- i **modelli con pesi a zero** (8): quattro forme con il 50 e il 90 % dei pesi uguali a zero;
- le **forme a pari pesi** (10): circa 592 pesi distribuiti su 1, 2, 3, 4 o 5 strati.

Le prove più lunghe (traffico crescente, core a basso consumo, due core, decisioni diverse, pacchetti di taglie diverse) usano 6–14 modelli, scelti dal più leggero al più pesante.

Cinque modi di misurare, ognuno per una domanda diversa:

1. **A nodo pieno.** Il generatore manda più pacchetti di quanti il nodo ne regga: il core del nodo lavora il 100 % del tempo. Si misura la **capacità** (quanti pacchetti al secondo il nodo elabora) e il **tempo per pacchetto**, che è 1 diviso la capacità. In più, il processore stesso conta istruzioni, cicli di clock e letture andate in memoria.
2. **A traffico crescente.** Il traffico sale da 0,5 a 12 milioni di pacchetti al secondo; si contano i pacchetti inviati, quelli che il programma riceve e quelli inoltrati. Dice dove si perdono i pacchetti oltre la capacità (slide 10).
3. **Con tre orologi.** Una versione del programma legge l'orologio all'ingresso, subito prima di inoltrare, e all'arrivo al nodo successivo: separa il tempo del programma da quello del trasporto, con poco traffico (slide 12 e 17).

4. **Il programma caricato.** Il kernel dice quanto è grande ogni programma, in istruzioni (slide 5, 18, 21, 24).
5. **Il programma da solo.** Il kernel esegue il programma su un pacchetto preparato, senza traffico. Serve a contare quante volte il programma legge una tabella e quante volte salta da un programma all'altro, e a misurare quanto costa installare un modello nuovo (slide 18 e 19).

Da dove vengono i tempi (P-core a 3,5 GHz, mediane sui 91 modelli):

- **ricevere il pacchetto**: circa 40 ns (un nanosecondo, ns, è un miliardesimo di secondo);
- **leggere l'intestazione e inoltrare**: circa 27 ns in più. Insieme fanno i ~67 ns del **nodo senza rete** (in inglese *baseline*): il costo fisso, uguale con qualunque modello;
- **la rete neurale**: quello che ogni versione aggiunge al nodo senza rete. 52 ns per P1, 59 per P1.5, 225 per P2, 420 per P3; dal modello più leggero al più pesante da 19 a 852 ns;
- **il trasporto** verso il nodo successivo: circa 200 ns, uguale per tutte le versioni e tutti i modelli.

> **I limiti del banco.** Il cavo virtuale non è una scheda di rete, e il generatore sta sulla stessa macchina: il costo del programma è quello vero, quello di ricezione su una scheda vera può essere diverso. Le cifre assolute valgono a 3,5 GHz. I modelli sono generati: coprono forme e tipi d'ingresso diversi, non dicono niente sull'accuratezza di un modello addestrato.

> **Quanto è pulito il dato.** Su 526 misure 2 sono fuori dalle conclusioni, perché la macchina era disturbata. Su questo portatile un breve rallentamento del processore arriva circa una volta al minuto: le curve a traffico crescente, che durano quasi tre minuti, sono tenute senza i pochi istanti colpiti (17 su 1 920).

Il rumore di misura. La stessa misura, rifatta in un'altra sessione, non dà esattamente lo stesso numero. Lo si vede in tre modi: i 3 giri di una stessa misura si discostano dell'1,3 % in mediana; il nodo senza rete, misurato in 91 sessioni diverse, varia di ±1 % in mediana e al più del 3,5 %; lo stesso modello con la stessa versione, misurato in due sessioni diverse, cambia dell'1,8 % in mediana e fino al **5 %** (90° percentile). Quindi due misure di sessioni diverse che differiscono meno del 5 % sono **uguali, entro il rumore**: la differenza non vuol dire niente.

Per chi vuole rifare le misure. Tutto lo fa `ipa/test/remeasure_popolazione.sh` (circa 4 ore e mezza); le conclusioni le calcola `ipa/test/population_report.py`, e queste slide le rigenera `docs/slides_src/popolazione.py`. I banchi sono `bench_throughput.py` (nodo pieno, tre orologi), `bench_bitrate.py` (traffico crescente), `bench_solo.py` (programma da solo), il generatore è `xdp_gen.py`, le condizioni della macchina `host_conditions.py`. La guida completa è `docs/testing.md`, §13.

SLIDE 1

Copertina

TESI · EBPF / XDP

Inferenza di una rete neurale nel kernel Linux con eBPF/XDP

Quattro modi di scrivere la stessa rete neurale dentro il kernel Linux, misurati con traffico vero su 91 reti diverse: quanto costa ogni pacchetto, perché, e che cosa cambia su un core più lento.

Ettore Cantile
ottobre 2026

La tesi esegue una piccola rete neurale **dentro il kernel Linux**, nel punto in cui il pacchetto è appena arrivato, per decidere da quale porta farlo uscire. La stessa rete è scritta in quattro modi, da completamente fissata nel programma a completamente configurabile, e la domanda è: quanto costa, per ogni pacchetto, ciascuna scelta? E perché?

La risposta non deve dipendere da un modello particolare. Per questo ogni misura è ripetuta su **91 reti neurali diverse**, e ogni conclusione è un intervallo o una legge che vale su tutte.

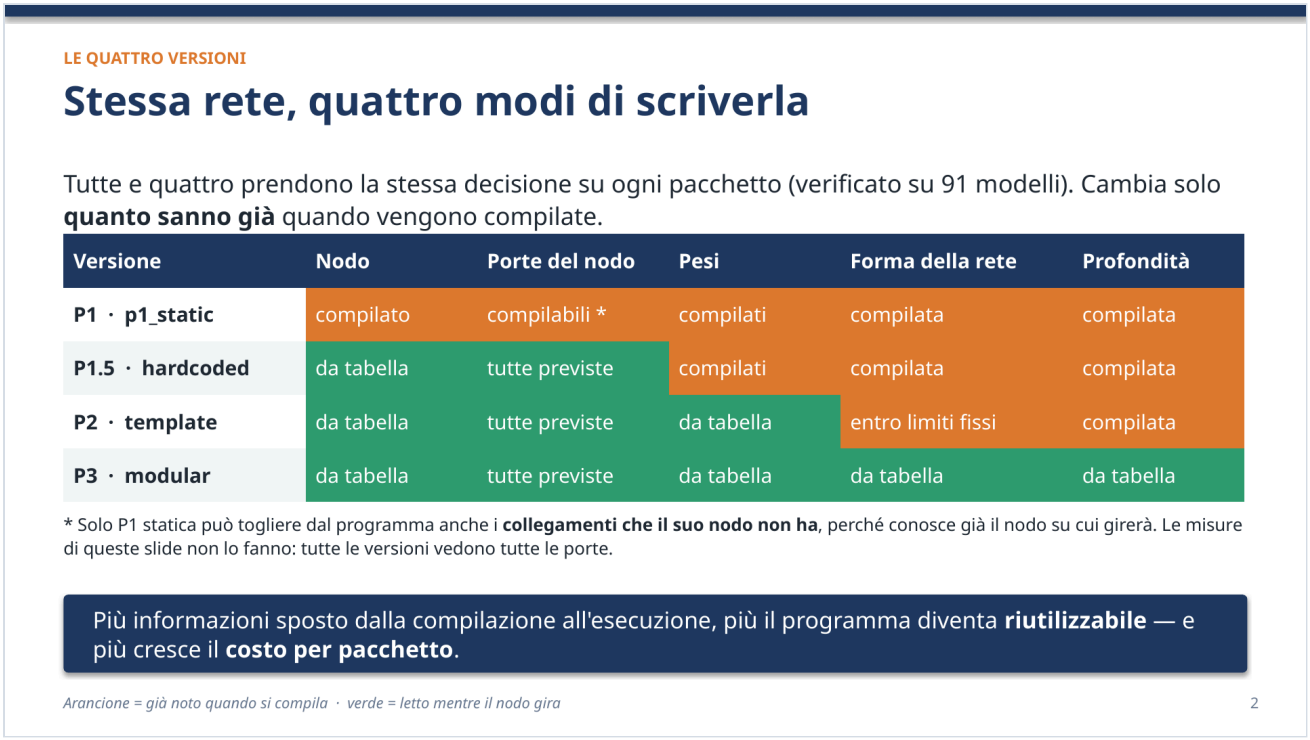
La presentazione segue cinque passi:

1. **Il nodo** (slide 4–5): quanto costa un pacchetto e quanto lavora il processore per elaborarlo.
2. **Tre tipi di core** (slide 6–9): che cosa cambia se il nodo gira su un core efficiente o a basso consumo.
3. **Sotto carico** (slide 10–13): che cosa succede quando il traffico supera la capacità, con due core, e che cosa non influisce sul costo.
4. **La forma del modello** (slide 14–17): quanto pesano strati, neuroni e pesi a zero sul nodo intero.
5. **La sola rete neurale** (slide 18–24): il prezzo della configurabilità, il cambio di modello, e una legge che prevede il costo di un modello prima di misurarlo.

Le cifre vengono dalla campagna dell'11–12 ottobre 2026 sul portatile di laboratorio. Prima delle slide, la pagina «Come si misura e da dove vengono i tempi» descrive il banco, i modelli e i modi di misurare; le spiegazioni la danno per letta.

SLIDE 2

Stessa rete, quattro modi di scriverla



LE QUATTRO VERSIONI

Stessa rete, quattro modi di scriverla

Tutte e quattro prendono la stessa decisione su ogni pacchetto (verificato su 91 modelli). Cambia solo **quanto sanno già** quando vengono compilate.

Versione	Nodo	Porte del nodo	Pesi	Forma della rete	Profondità
P1 · p1_static	compilato	compilabili *	compilati	compilata	compilata
P1.5 · hardcoded	da tabella	tutte previste	compilati	compilata	compilata
P2 · template	da tabella	tutte previste	da tabella	entro limiti fissi	compilata
P3 · modular	da tabella	tutte previste	da tabella	da tabella	da tabella

* Solo P1 statica può togliere dal programma anche i **collegamenti che il suo nodo non ha**, perché conosce già il nodo su cui girerà. Le misure di queste slide non lo fanno: tutte le versioni vedono tutte le porte.

Più informazioni sposto dalla compilazione all'esecuzione, più il programma diventa **riutilizzabile** — e più cresce il **costo per pacchetto**.

Arancione = già noto quando si compila · verde = letto mentre il nodo gira 2

Tutte e quattro le versioni calcolano **la stessa rete neurale** e prendono **la stessa decisione** su ogni pacchetto. Lo verifica, su ogni modello, un confronto esatto con un calcolo di riferimento fatto fuori dal kernel: 200 pacchetti per modello, nessuna differenza. P2 accetta al più 1 024 pesi, quindi per P2 i modelli sono 85 invece di 91.

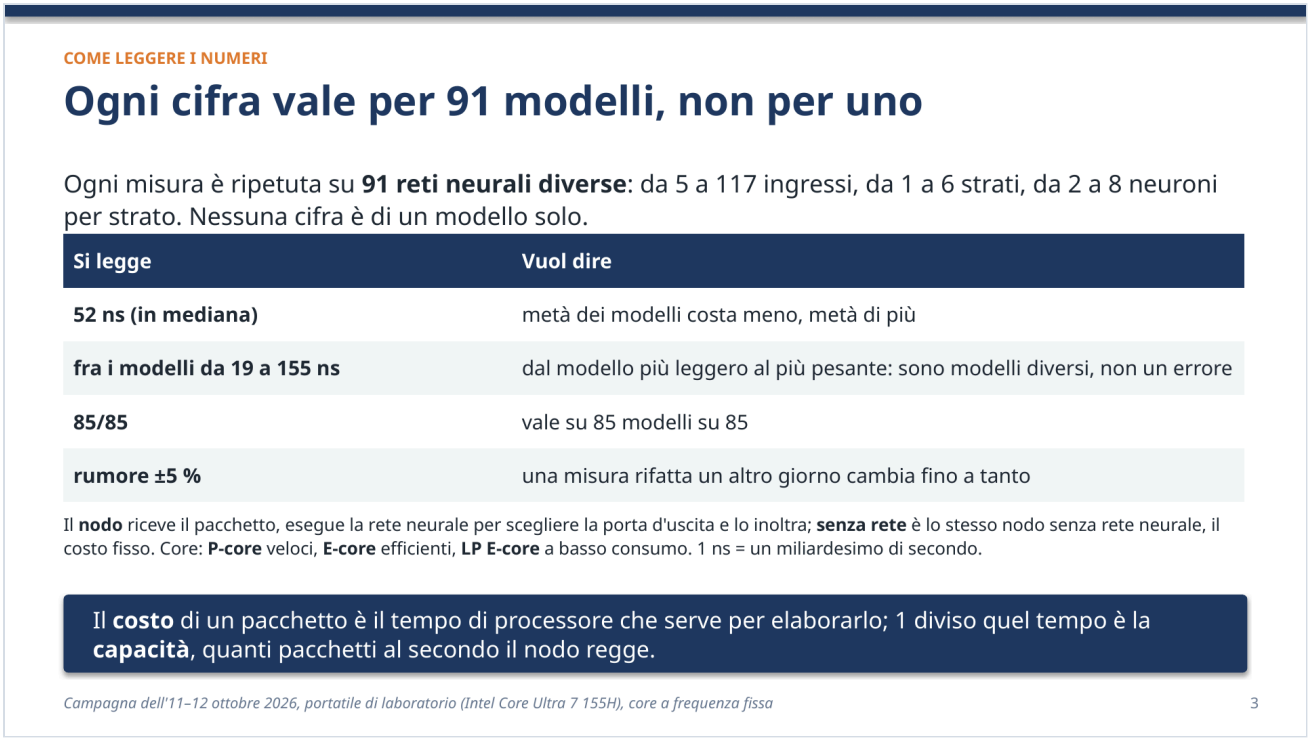
Le versioni differiscono in **che cosa è già scritto nel programma quando lo si compila** (arancione nella tabella) e **che cosa il programma legge da tabelle mentre gira** (verde). Una tabella, qui, è una zona di memoria del kernel che il programma consulta e che si può riscrivere senza ricompilare il programma.

- **P1 statica**: i pesi e l'identità del nodo sono scritti nel programma. Serve un programma diverso per ogni nodo.
- **P1.5**: i pesi sono nel programma, il nodo si legge da tabella. Un programma per ogni modello.
- **P2**: anche la forma della rete (quanti ingressi, quanti neuroni) si legge da tabella; nel programma ci sono solo i valori massimi ammessi. Un programma per molti modelli.
- **P3**: anche il numero di strati si legge da tabella, e ogni strato è un programma a parte, raggiunto con un salto. Un programma per tutto.

La regola che le slide successive misurano: più informazioni si spostano dalla compilazione all'esecuzione, più il programma diventa riutilizzabile, e più cresce il costo per pacchetto. I colori restano gli stessi in tutti i grafici: P1 rosso, P1.5 arancione, P2 verde, P3 blu.

SLIDE 3

Ogni cifra vale per 91 modelli, non per uno



COME LEGGERE I NUMERI

Ogni cifra vale per 91 modelli, non per uno

Ogni misura è ripetuta su **91 reti neurali diverse**: da 5 a 117 ingressi, da 1 a 6 strati, da 2 a 8 neuroni per strato. Nessuna cifra è di un modello solo.

Si legge	Vuol dire
52 ns (in mediana)	metà dei modelli costa meno, metà di più
fra i modelli da 19 a 155 ns	dal modello più leggero al più pesante: sono modelli diversi, non un errore
85/85	vale su 85 modelli su 85
rumore ±5 %	una misura rifatta un altro giorno cambia fino a tanto

Il **nodo** riceve il pacchetto, esegue la rete neurale per scegliere la porta d'uscita e lo inoltra; **senza rete** è lo stesso nodo senza rete neurale, il costo fisso. Core: **P-core** veloci, **E-core** efficienti, **LP E-core** a basso consumo. 1 ns = un miliardesimo di secondo.

Il **costo** di un pacchetto è il tempo di processore che serve per elaborarlo; 1 diviso quel tempo è la **capacità**, quanti pacchetti al secondo il nodo regge.

Campagna dell'11–12 ottobre 2026, portatile di laboratorio (Intel Core Ultra 7 155H), core a frequenza fissa 3

Questa slide spiega come leggere i numeri del resto della presentazione.

Nessuna cifra delle slide è di un modello solo. Ogni numero è di uno di questi tipi, e il testo dice sempre quale:

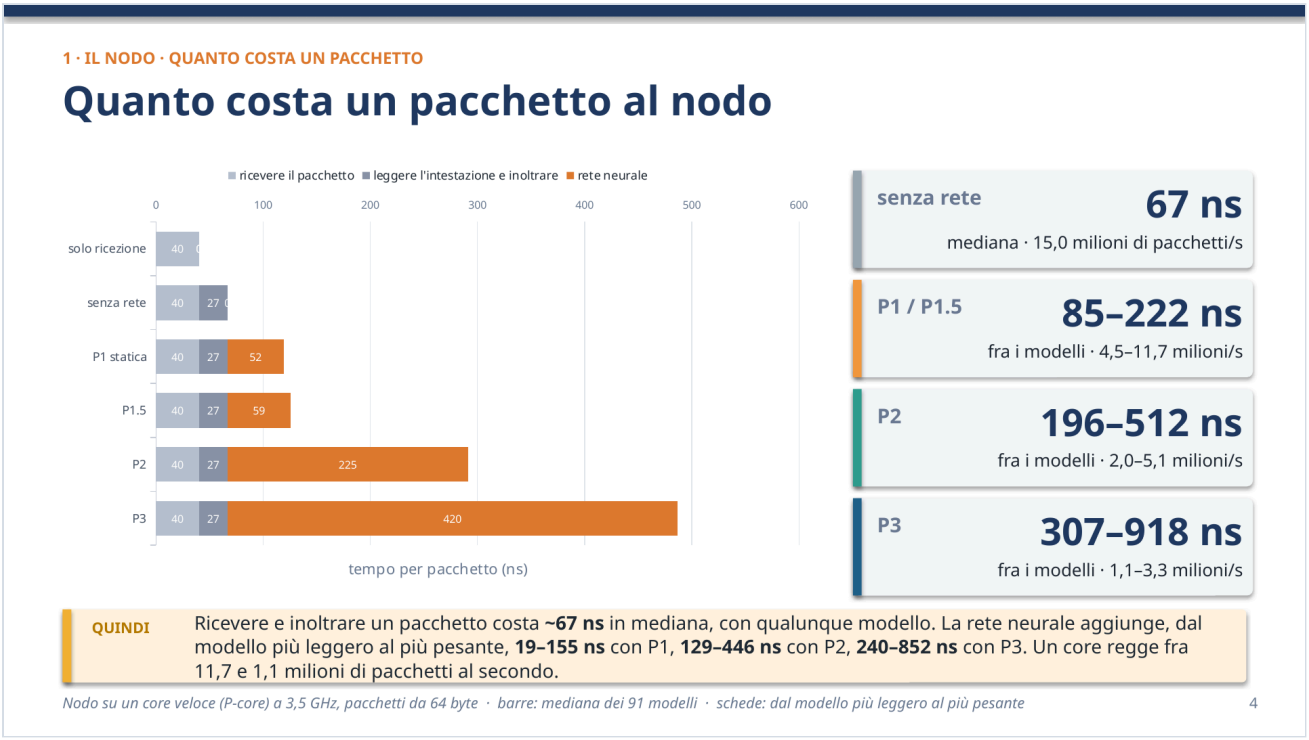
- **«52 ns, in mediana»**: la **mediana** sui modelli. Metà dei modelli costa meno, metà di più. È il valore tipico.
- **«fra i modelli da 19 a 155 ns»**: il valore del modello più leggero e quello del più pesante. Non è un errore di misura: sono reti diverse, che costano davvero cose diverse.
- **«da 27 ns senza rete a 391 ns con P3»**: mediane di versioni diverse, messe in fila. Quando un intervallo va da una versione all'altra, il testo nomina le versioni.
- **«secondo la legge»**: un coefficiente della legge di costo (slide 23), stimato su tutti i modelli insieme.
- **«85/85»**: un'affermazione vale su 85 modelli su 85. Se un modello la smentisse, il conteggio lo direbbe.
- **«rumore ±5 %»**: quanto cambia la stessa misura rifatta in un'altra sessione (pagina iniziale). Una differenza più piccola non è una differenza; e un rapporto fra due misure di sessioni diverse può uscire poco sopra 100 % anche dove fisicamente non può (slide 11).

Un rapporto come **«4,3 volte»** si calcola modello per modello (per esempio il costo di P2 diviso quello di P1 sullo stesso modello), poi si riassume con la mediana. **«Senza rete»** è il nodo che riceve e inoltra il pacchetto senza eseguire nessuna rete neurale: il costo fisso che ogni versione paga.

Due grandezze tornano ovunque. Il **costo** di un pacchetto è il tempo di processore che serve per elaborarlo, in nanosecondi. La **capacità** è quanti pacchetti al secondo il nodo regge: 1 diviso il costo. Un nodo che spende 250 ns per pacchetto ne regge 4 milioni al secondo.

SLIDE 4

Quanto costa un pacchetto al nodo



Come si misura. Il generatore manda al nodo più pacchetti di quanti ne possa elaborare. La coda davanti al nodo resta sempre piena, il core lavora il 100 % del tempo, e il ritmo a cui elabora è la sua capacità.

Le barre scompongono il costo di un pacchetto in tre pezzi (mediane sui 91 modelli):

- **ricevere il pacchetto** (grigio chiaro), circa 40 ns: lo misura un programma che riceve e basta;
- **leggere l'intestazione e inoltrare** (grigio scuro), circa 27 ns: quello che il nodo senza rete fa in più;
- **rete neurale** (arancione): quello che ogni versione aggiunge.

Le schede a destra danno, per ogni versione, il costo e la capacità dal modello più leggero al più pesante.

> **Esempio di calcolo.** P2, nella mediana dei modelli, regge 3,4 milioni di pacchetti al secondo: spende 1 / 3 400 000 di secondo, circa 291 ns, per pacchetto. Il nodo senza rete ne spende 67. La differenza, circa 225 ns, è il tempo della rete neurale.

Fra il modello più leggero e il più pesante, la rete neurale costa da 19 a 155 ns se i pesi sono scritti nel programma (P1), da 129 a 446 se la forma si legge da tabella (P2), da 240 a 852 se anche il numero di strati (P3). Un core regge da 11,7 a 1,1 milioni di pacchetti al secondo. L'ordine P1 ≤ P2 ≤ P3 vale su 85 modelli su 85.

SLIDE 5

Quanto è grande il programma non dice quanto lavora

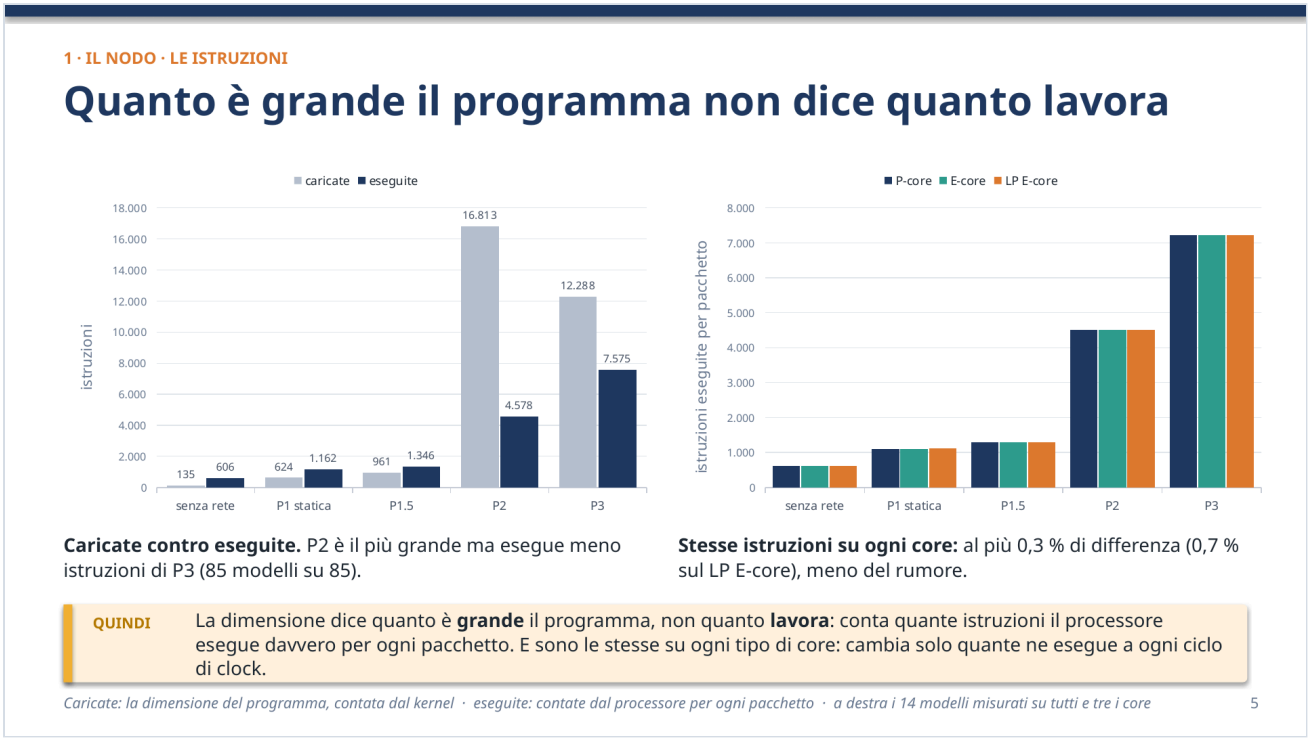


Grafico a sinistra. Due modi di contare le istruzioni:

- **caricate** (grigio): quante istruzioni ha il programma. È la sua dimensione, contata dal kernel quando lo carica;
- **eseguite** (blu): quante istruzioni il processore esegue davvero per ogni pacchetto, contate dal processore stesso. Comprendono anche il lavoro del kernel per ricevere e inoltrare.

Le due misure dicono cose diverse. **P2 è il programma più grande** (circa 16 800 istruzioni) **ma ne esegue meno di P3** (circa 4 600 contro 7 600 per pacchetto), su 85 modelli su 85. P2 contiene il codice per tutte le forme ammesse, ma per ogni pacchetto ne percorre solo una parte; P3 è più piccolo (12 288 istruzioni, sempre uguale) ma ripete il suo codice una volta per strato.

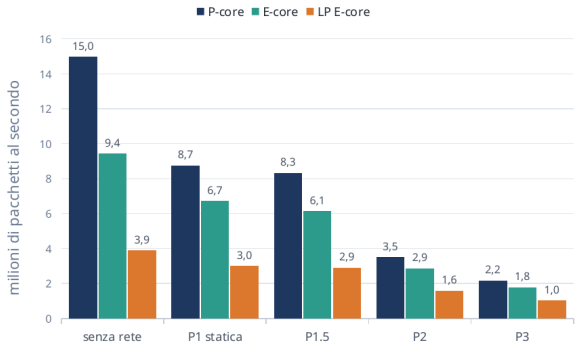
Grafico a destra. Le istruzioni eseguite per pacchetto sui tre tipi di core: le barre coincidono. Il codice è lo stesso, quindi lo è anche il lavoro: fra un core e l'altro la differenza è al più dello 0,7 %. Se i core vanno a velocità diverse (slide 6), non è perché eseguono istruzioni diverse.

SLIDE 6

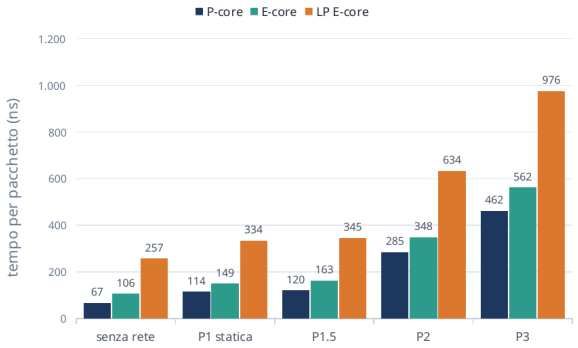
Su un E-core il nodo regge dal 61 al 91 % del P-core

2 · TRE TIPI DI CORE

Un E-core regge dal 61 al 91 % di un P-core



Capacità (mediane). Fra i modelli, l'E-core regge da 0,61 a 0,66 volte il P-core senza rete, da 0,72 a 0,89 con P3.



Tempo per pacchetto (mediane). Sull'E-core il lavoro fisso costa il 56 % in più, la rete di P3 solo il 13 %.

QUINDI

A parità di frequenza l'E-core rallenta soprattutto il **lavoro fisso del nodo** (ricevere e inoltrare): più la rete pesa sul totale, meno conta il core. Il LP E-core (2,5 GHz) regge dal 32 al 53 % del P-core, secondo modello e versione.

Core veloce (P-core) ed efficiente (E-core) a 3,5 GHz, a basso consumo (LP E-core) a 2,5 GHz · grafici: mediana dei 14 modelli misurati su tutti e tre i core 6

Il processore ha tre tipi di core: sei **P-core** veloci, otto **E-core** efficienti (a gruppi di quattro che condividono una cache) e due **LP E-core** a basso consumo, in un'altra parte del chip. La domanda: che cosa succede se il nodo gira su un core più lento?

Il disegno della misura. Cambia solo il core del nodo; generatore e nodo successivo restano su P-core. P-core ed E-core girano alla stessa frequenza, 3,5 GHz, quindi la differenza dipende solo da come il core esegue il codice. Il LP E-core gira al suo massimo, 2,5 GHz.

A sinistra la capacità, **a destra** il tempo per pacchetto, nella mediana dei 14 modelli misurati su tutti e tre i core.

In mediana, sull'E-core il nodo regge il 63 % del P-core senza rete e l'82–83 % con P2 e P3; fra i modelli si va dal 61 al 91 %. Più la versione è pesante, meno pesa il tipo di core: la slide 8 spiega perché. Il LP E-core regge dal 32 al 53 % del P-core.

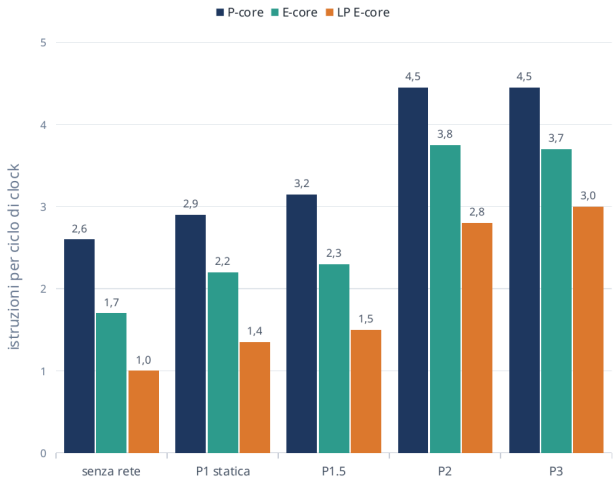
Esempio. P3, mediana dei 14 modelli: 2,2 milioni di pacchetti al secondo sul P-core, 1,8 sull'E-core, 1,0 sul LP E-core. In tempo: 462, 562 e 976 ns per pacchetto.

SLIDE 7

Stesse istruzioni, meno istruzioni per ciclo

2 · TRE TIPI DI CORE · ISTRUZIONI PER CICLO

Stesse istruzioni, meno istruzioni per ciclo



Versione	Istruzioni	Cicli P	Cicli E
P1 statica	1 162	414	531
P1.5	1 346	438	569
P2	4 578	1 016	1 218
P3	7 575	1 697	2 021

QUINDI

Il codice è lo stesso su ogni core; cambia quante istruzioni il core esegue a ogni ciclo di clock (IPC, mediane): 2,6 → 1,7 senza rete, dove il kernel salta e aspetta la memoria; 4,4 → 3,7 con P3, una fila di moltiplicazioni.

Contatori del processore sul core del nodo · tabella: mediane su 91 modelli · grafico: i 14 modelli misurati sui tre core 7

Se le istruzioni per pacchetto sono le stesse su ogni core (slide 5), la differenza sta nei **cicli di clock**: quanti battiti dell'orologio del core servono per eseguirle. Il rapporto fra istruzioni e cicli si chiama **IPC**, istruzioni per ciclo: più è alto, più lavoro il core fa a ogni battito.

Il grafico mostra l'IPC sui tre core; la tabella istruzioni e cicli per pacchetto su P-core ed E-core.

> **Esempio.** P3 esegue circa 7 600 istruzioni per pacchetto. Il P-core ci mette circa 1 700 cicli (IPC 4,4), l'E-core circa 2 000 (IPC 3,7). A 3,5 GHz (3,5 miliardi di cicli al secondo) sono circa 485 e 577 ns: gli stessi tempi misurati con il primo metodo.

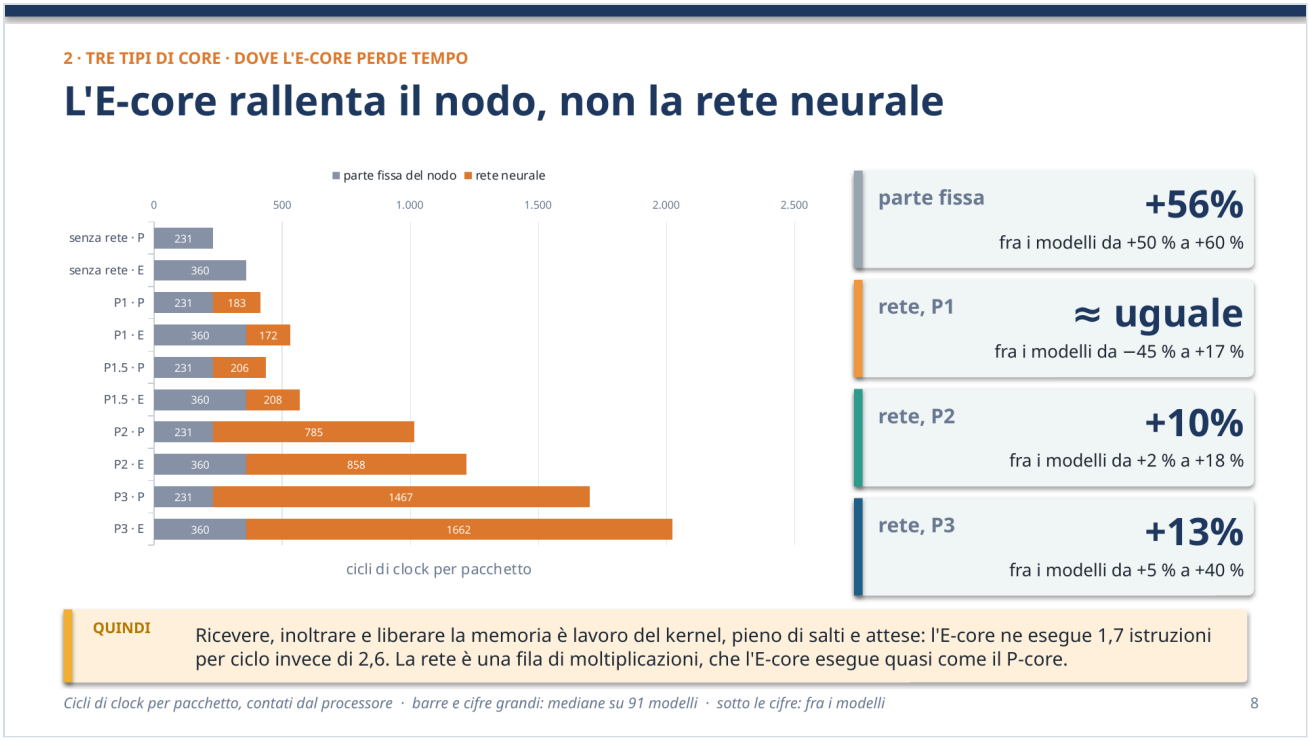
Due cose si leggono nel grafico:

- l'IPC cresce con la versione: senza rete sta a 2,6 sul P-core, perché il lavoro del kernel è pieno di salti e di attese della memoria; P2 e P3 arrivano a 4,4–4,5, perché la rete neurale è una lunga fila di moltiplicazioni indipendenti, che il core esegue molte per volta;
- il distacco fra i core è più grande dove l'IPC è basso: 2,6 → 1,7 senza rete, 4,4 → 3,7 con P3.

Il LP E-core ha l'IPC più basso (da 1,0 a 3,0) perché, oltre a essere più semplice, aspetta spesso la memoria (slide 9).

SLIDE 8

L'E-core rallenta il nodo, non la rete neurale



Le barre dividono i cicli per pacchetto in due parti, sul P-core (P) e sull'E-core (E):

- **parte fissa del nodo** (grigio): i cicli del nodo senza rete, cioè ricevere, leggere l'intestazione, inoltrare e liberare la memoria del pacchetto;
- **rete neurale** (arancione): i cicli che ogni versione aggiunge.

Il risultato è netto. La parte fissa passa da 231 a 360 cicli in mediana, il 56 % in più; fra i modelli da +50 a +60 %, quindi su ogni modello. La rete neurale cambia poco: in mediana +10 % per P2 e +13 % per P3. Nelle schede la cifra grande è la mediana, la riga sotto l'intervallo fra i modelli.

Perché. La parte fissa è codice del kernel con molti salti e accessi alla memoria, dove un core più semplice si ferma spesso ad aspettare. La rete neurale è una fila di moltiplicazioni e somme indipendenti, che anche l'E-core esegue molte per volta.

È per questo che nella slide 6 il rapporto fra i core migliora con le versioni più pesanti: più tempo il nodo passa nella rete neurale, meno conta che il core sia un E-core.

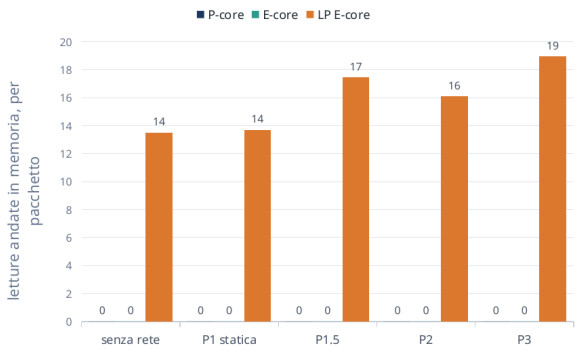
P1, «≈ uguale». Per P1 la rete costa poche decine di cicli sopra una parte fissa di 231–360: è la piccola differenza fra due numeri grandi, e fra i modelli va da −45 a +17 %. Il segno non è affidabile: la scheda dice «≈ uguale», non «l'E-core è più veloce».

SLIDE 9

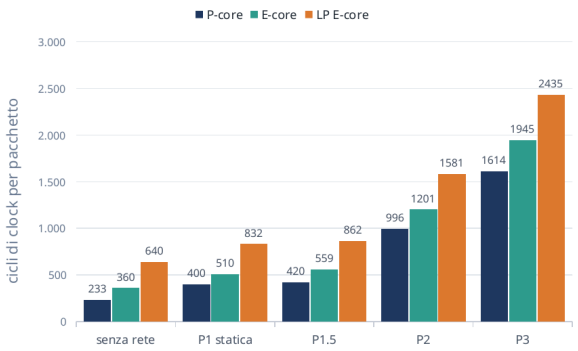
Il LP E-core paga anche la memoria

2 · TRE TIPI DI CORE · IL CORE A BASSO CONSUMO

Il LP E-core paga anche la memoria



Letture andate in memoria (mediane): zero su P-core ed E-core, 14–19 sul LP E-core.



Cicli per pacchetto (mediane). Per P3: 1 614 sul P-core, 1 944 sull'E-core, 2 435 sul LP E-core; in tempo 462, 562 e 976 ns.

QUINDI Il LP E-core sta in un'altra parte del chip, fuori dalla cache che gli altri core condividono: i pacchetti gli arrivano dalla memoria. Fra attese, un core più semplice e 2,5 GHz regge dal 32 al 53 % del P-core, secondo modello e versione.

Contatori del processore, per pacchetto, a nodo pieno · LP E-core a 2,5 GHz · mediane dei 14 modelli misurati sui tre core 9

A sinistra le **letture andate in memoria** per pacchetto: quante volte il core cerca un dato nella sua cache (una piccola memoria veloce vicino al core) e non lo trova, e deve andarlo a prendere nella memoria principale, molto più lenta. Su P-core ed E-core sono zero: i pacchetti che il generatore scrive restano nella cache che questi core condividono. Il LP E-core sta fuori da quella cache: ha 14–19 letture in memoria per pacchetto, e ogni volta aspetta.

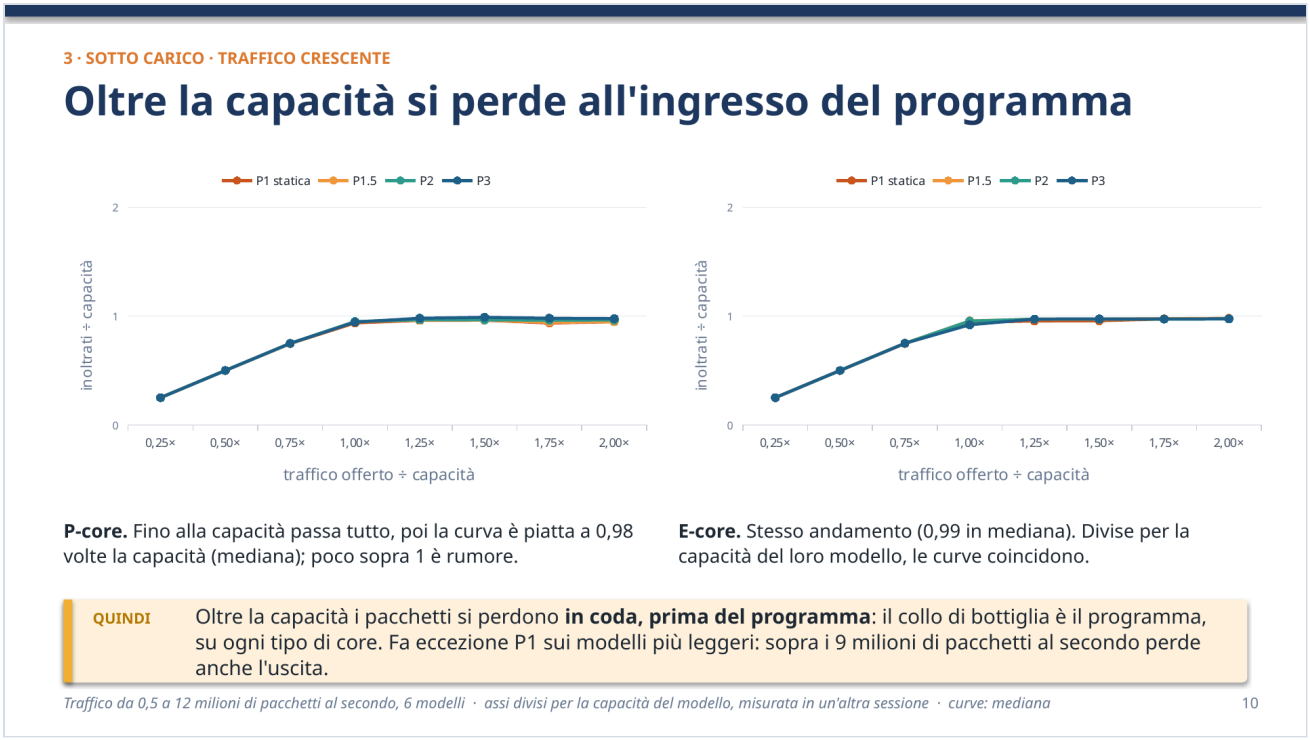
A destra i cicli per pacchetto sui tre core. Per P3: circa 1 600 sul P-core, 1 900 sull'E-core, 2 400 sul LP E-core. In tempo conta anche la frequenza più bassa del LP E-core: 462, 562 e 976 ns.

Esempio. Il nodo senza rete sul LP E-core spende 640 cicli per pacchetto, contro 233 sul P-core: quasi tre volte tanto, per lo stesso codice. La differenza è quasi tutta attesa della memoria.

Il LP E-core regge dal 32 al 53 % del P-core. È il caso estremo: un core pensato per tenere acceso il sistema consumando poco, non per elaborare pacchetti.

SLIDE 10

Oltre la capacità si perde all'ingresso del programma



Qui il traffico **cresce** a poco a poco, da 0,5 a 12 milioni di pacchetti al secondo, e si contano i pacchetti inoltrati. A sinistra il nodo su un P-core, a destra su un E-core; sei modelli, dal più leggero al più pesante.

Modelli diversi hanno capacità diverse. Per metterli sullo stesso grafico, entrambi gli assi sono divisi per la capacità di ogni modello: sull'asse orizzontale il traffico offerto, sull'asse verticale i pacchetti inoltrati. Così «1» vuol dire «la capacità di quel modello», qualunque sia.

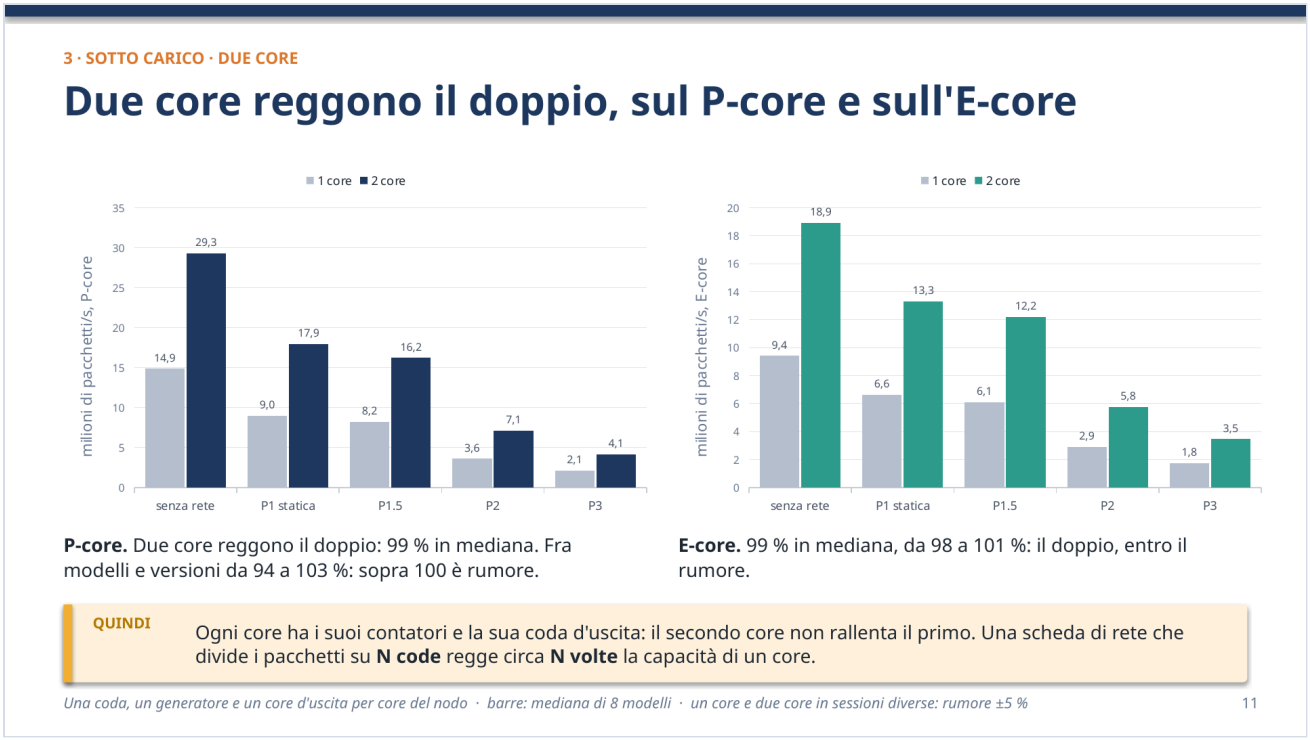
Ogni curva sale in diagonale (tutto ciò che arriva viene inoltrato) finché il traffico resta sotto la capacità, poi diventa piatta: il nodo non può inoltrare di più, e il resto viene respinto dalla coda d'ingresso piena. Il massimo inoltrato coincide con la capacità misurata a nodo pieno: 0,98 volte sul P-core e 0,99 sull'E-core, in mediana. Qualche curva arriva poco sopra 1 (fino a 1,03): le due grandezze vengono da sessioni diverse, ed è rumore di misura, non un nodo che inoltra più della sua capacità.

Dove si perde. Il banco conta i pacchetti in tre punti: inviati, ricevuti dal programma, inoltrati. Quasi tutti i pacchetti persi si perdono **prima** del programma, nella coda: il programma inoltra tutto ciò che riceve. Il collo di bottiglia è il programma, non la trasmissione, su ogni tipo di core.

L'eccezione. P1 sui modelli più leggeri regge più di 9 milioni di pacchetti al secondo, e lì comincia a perdere anche all'uscita: è il limite del cavo virtuale e del core d'uscita, non della rete neurale.

SLIDE 11

Due core reggono il doppio, sul P-core e sull'E-core



Qui il nodo usa **due core**, ciascuno con la sua coda d'ingresso, il suo generatore, la sua coda d'uscita e il suo core d'uscita. A sinistra due P-core, a destra due E-core (in due gruppi diversi del chip). Barre chiare: un core; barre scure: due. Mediane di 8 modelli dal più leggero al più pesante.

Come si legge. P2 con un P-core regge 3,6 milioni di pacchetti al secondo, con due 7,1: il doppio. Sull'E-core 2,9 e 5,8.

In mediana due core reggono il 99 % del doppio di un core, sia sul P-core sia sull'E-core. Fra modelli e versioni il rapporto va dal 94 al 103 % sul P-core e dal 98 al 101 % sull'E-core.

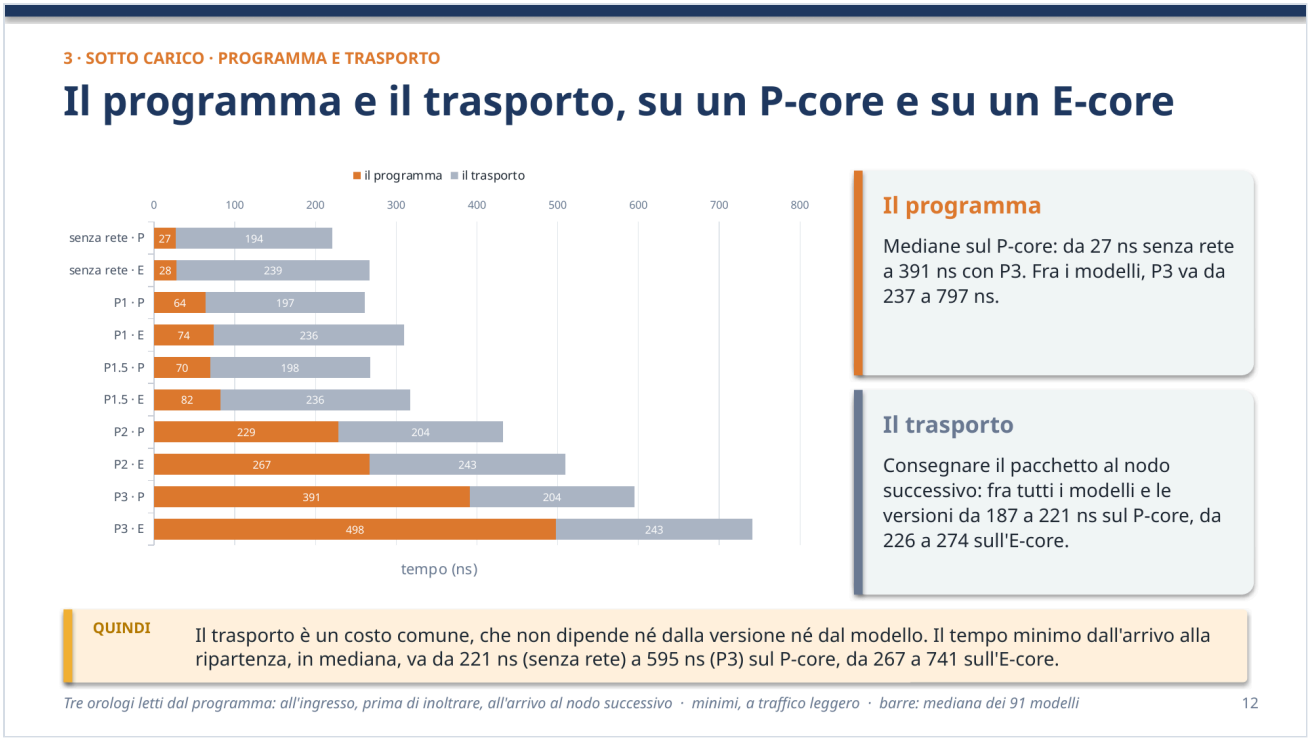
Perché il 103 %. Due core non possono reggere più del doppio di uno. Ma «un core» e «due core» sono due misure fatte in sessioni diverse, ciascuna con il suo rumore (fino al 5 %): il loro rapporto oscilla di qualche punto attorno al valore vero, sopra e sotto. Il 94–103 % dice quindi una cosa sola: **il doppio, entro il rumore**.

Il secondo core non rallenta il primo perché non scrivono mai negli stessi dati: ogni core ha i suoi contatori e la sua coda d'uscita.

Conseguenza pratica: una scheda di rete vera divide i pacchetti su più code, ognuna servita da un core. Un nodo con N code regge circa N volte la capacità di un core.

SLIDE 12

Il programma e il trasporto, su un P-core e su un E-core



Una versione del programma legge l'orologio in tre punti: all'ingresso del programma, subito prima di inoltrare, e all'arrivo al nodo successivo. Così si separano due tempi:

- **il programma** (arancione): dall'ingresso a prima di inoltrare;
- **il trasporto** (grigio): dall'inoltro all'arrivo al nodo successivo, cioè passaggio sul cavo virtuale e ricezione.

Le barre mostrano il tempo minimo di ciascun pezzo, nella mediana dei 91 modelli, sul P-core (P) e sull'E-core (E).

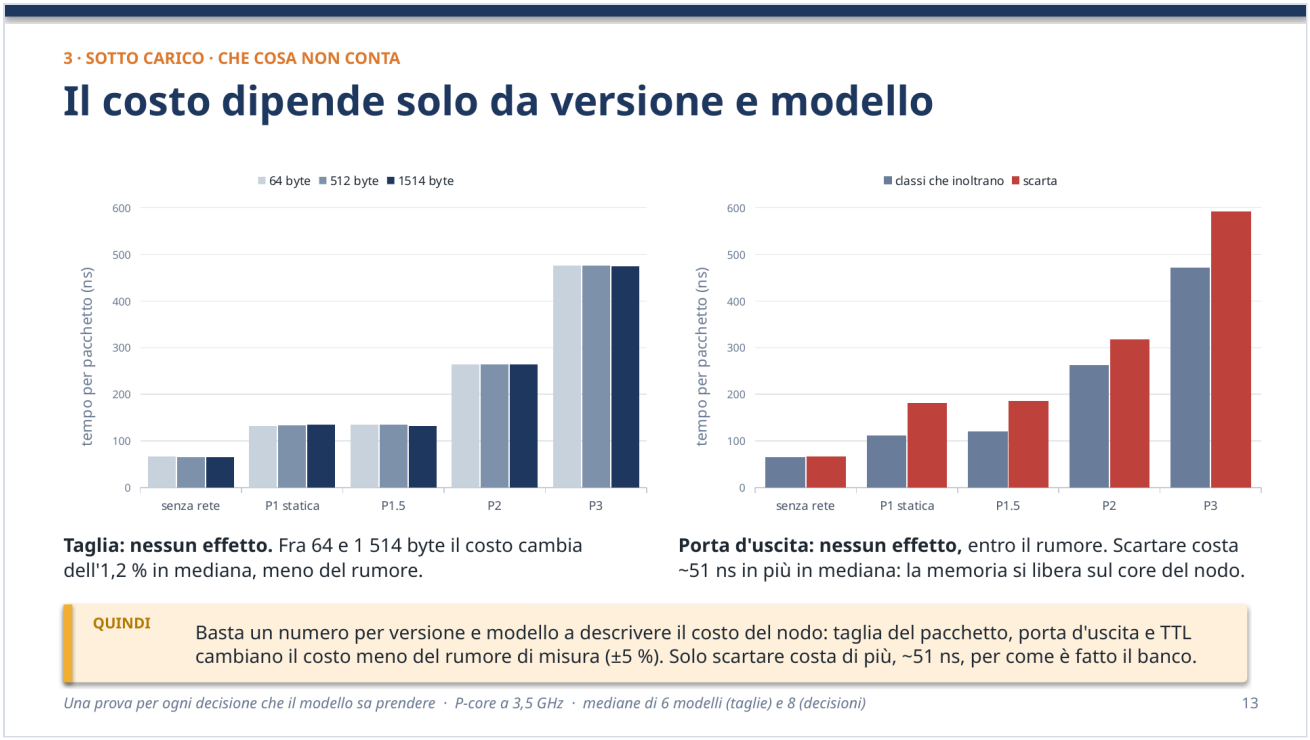
Il trasporto è un costo comune: fra tutti i modelli e le versioni sta fra 187 e 221 ns sul P-core e fra 226 e 274 sull'E-core. Il programma, in mediana sul P-core, va da 27 ns senza rete a 391 ns con P3; fra i modelli, P3 va da 237 a 797 ns. Sull'E-core costa di più, tanto di più quanto più è lungo.

Esempio. P2 sul P-core: 229 ns di programma più 204 di trasporto. La somma, circa 430 ns, è il tempo minimo fra l'arrivo del pacchetto e il suo arrivo al nodo successivo.

Il minimo, non la media. In questa misura il nodo successivo gira sullo stesso core del nodo, quindi il tempo medio di trasporto contiene anche l'attesa in coda, e cresce col traffico. Il minimo è il trasporto senza attesa. Leggere l'orologio costa un poco: questa versione serve a capire dove va il tempo, non a misurare la capacità (che danno le slide 4 e 6).

SLIDE 13

Il costo dipende solo da versione e modello



Tre controlli sul P-core, ciascuno su modelli dal più leggero al più pesante:

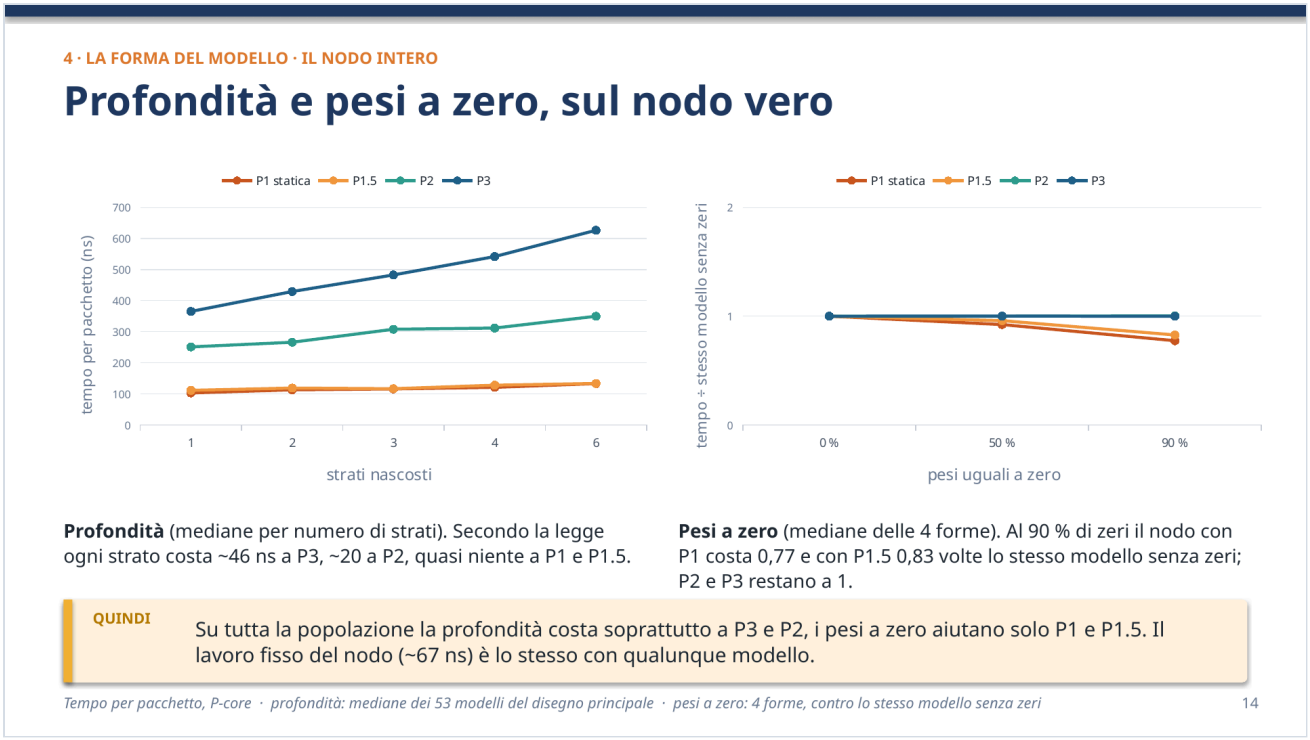
- **a sinistra la taglia del pacchetto** (6 modelli): a 64, 512 e 1 514 byte ogni versione costa uguale: l'1,2 % di differenza in mediana, meno del rumore. Il nodo legge solo l'intestazione del pacchetto, come farebbe su una scheda di rete vera;
- **a destra la decisione presa** (8 modelli): lo stato dei collegamenti e il TTL sono scelti apposta perché la rete decida ciascuna delle uscite che il modello sa raggiungere. inoltrare su una porta o su un'altra costa uguale, entro il rumore; **scartare** il pacchetto (rosso) costa circa 51 ns in più, in mediana;
- nel riquadro, **pacchetti tutti diversi** (12 modelli): un TTL diverso a ogni pacchetto fa prendere al modello decisioni diverse pacchetto per pacchetto, e il costo non cambia.

Perché scartare costa di più. Quando il pacchetto è inoltrato, la sua memoria la libera il core d'uscita; quando è scartato, la libera il core del nodo, che quindi lavora di più. È un effetto del banco, non della rete neurale.

Basta quindi un numero per versione e modello a descrivere il costo del nodo.

SLIDE 14

Profondità e pesi a zero, sul nodo vero



Qui il tempo è quello del **nodo intero** (rete neurale più parte fissa), sul P-core.

A sinistra la profondità: il tempo per pacchetto per numero di strati nascosti, nella mediana dei 53 modelli del disegno principale (che hanno 1, 2, 3, 4 o 6 strati). Ogni punto mescola modelli con ingressi e larghezze diverse; la legge della slide 23 separa l'effetto dello strato: uno strato in più costa circa 46 ns a P3, 20 a P2, quasi niente a P1 e P1.5.

A destra i pesi a zero: quattro forme con il 50 e il 90 % di pesi uguali a zero, confrontate con lo stesso modello senza zeri. P1 e P1.5 accelerano (al 90 % di zeri il nodo costa 0,77 e 0,83 volte), perché il compilatore vede lo zero e toglie la moltiplicazione. P2 e P3 non cambiano: per loro uno zero letto da una tabella è un numero come un altro.

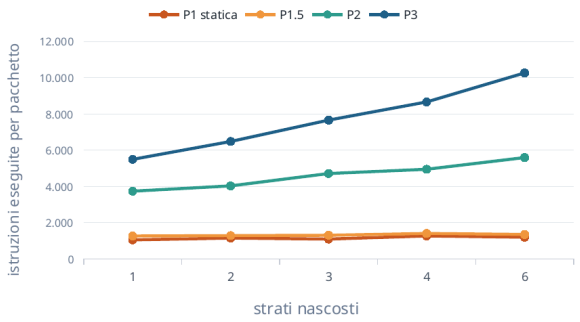
La parte fissa del nodo, circa 67 ns, è la stessa con qualunque modello.

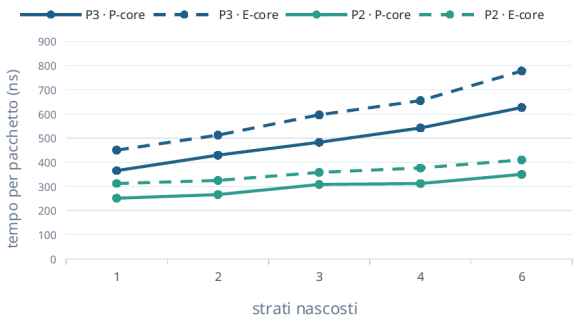
SLIDE 15

Ogni strato di P3 costa ~900 istruzioni

4 · LA FORMA DEL MODELLO · LE ISTRUZIONI

Ogni strato di P3 costa ~900 istruzioni





Istruzioni (legge su 83 modelli). Ogni strato in più ne aggiunge 901 a P3 e 370 a P2, uguali su P-core ed E-core.

Tempo (legge). Ogni strato costa a P3 ~46 ns sul P-core, ~62 sull'E-core (tratteggio).

QUINDI

P3 esegue uno strato alla volta: a ogni strato salta a un altro programma e rilegge dalle tabelle dove si trova. È sempre lo stesso lavoro, per questo ogni strato costa uguale, su ogni modello.

Mediane per numero di strati sui 53 modelli del disegno principale · costo per strato stimato su 83 modelli senza zeri · contatori del processore

15

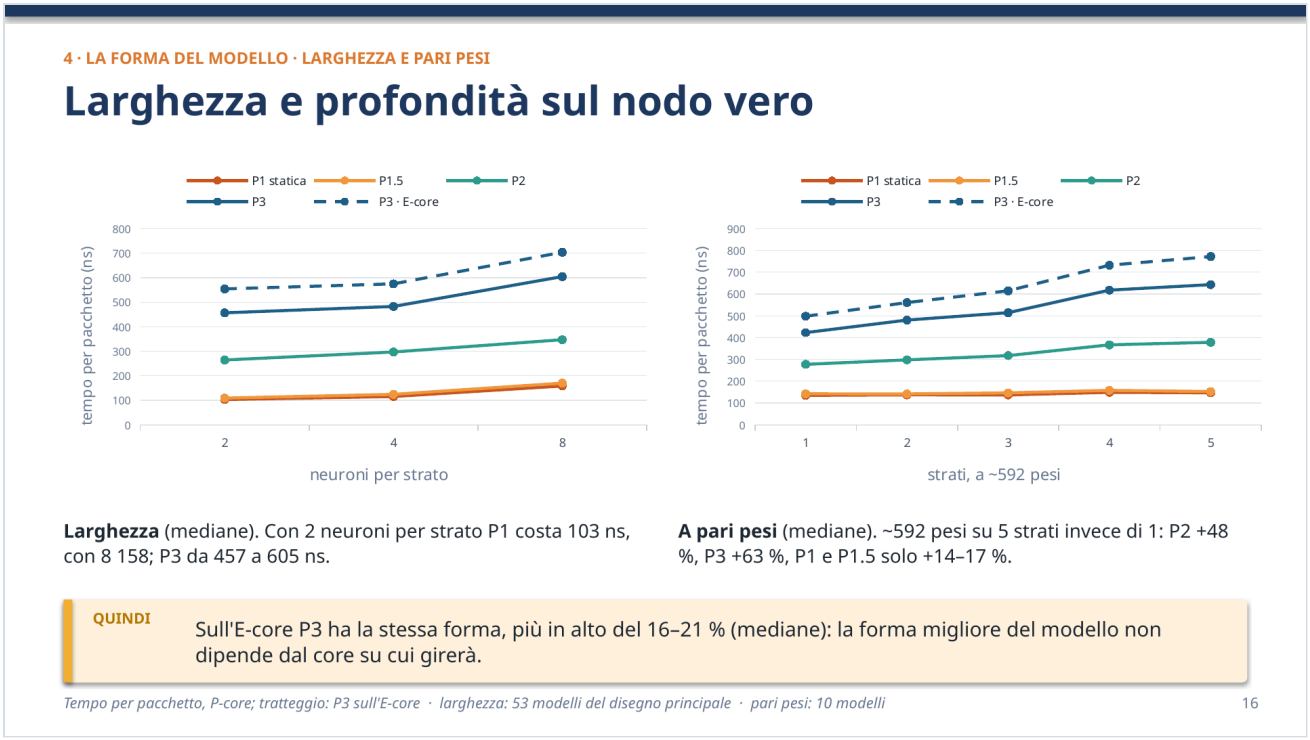
A sinistra le istruzioni eseguite per pacchetto, contate dal processore, per numero di strati. Stimato su tutti gli 83 modelli senza pesi a zero, ogni strato in più aggiunge **circa 900 istruzioni a P3**, uguali su P-core ed E-core, e circa 370 a P2. P1 e P1.5 non pagano lo strato in sé: le loro istruzioni crescono con le moltiplicazioni.

Che cosa sono le ~900 istruzioni. P3 esegue uno strato alla volta. Alla fine di ogni strato salta di nuovo al programma generico dello strato, che deve rileggere dalle tabelle dove si trova, che forma ha lo strato e dove stanno i suoi pesi. È sempre lo stesso lavoro, per questo ogni strato costa uguale, su ogni modello.

A destra il tempo per pacchetto di P3 e P2 sul P-core (linea continua) e sull'E-core (tratteggio). Ogni strato costa a P3 circa 46 ns sul P-core e 62 sull'E-core: le stesse istruzioni, eseguite più lentamente.

SLIDE 16

Larghezza e profondità sul nodo vero



Altre due analisi sul nodo intero, sul P-core; il tratteggio è P3 sull'E-core.

A sinistra la larghezza: quanti neuroni per strato (2, 4 o 8), nella mediana dei modelli del disegno principale. Il tempo sale su tutte le versioni: P1 da 103 a 158 ns, P3 da 457 a 605. Un neurone in più è lavoro vero a ogni pacchetto.

A destra a pari pesi: le dieci forme con circa 592 pesi, distribuiti su 1, 2, 3, 4 o 5 strati. Passando da 1 a 5 strati la rete costa il 48 % in più con P2 e il 63 % in più con P3; P1 e P1.5 solo il 14–17 %.

Che cosa vuol dire per chi progetta il modello. Con P1 e P1.5 la forma della rete si sceglie solo per l'accuratezza. Con P2 e P3, a parità di pesi, conviene una rete larga e poco profonda.

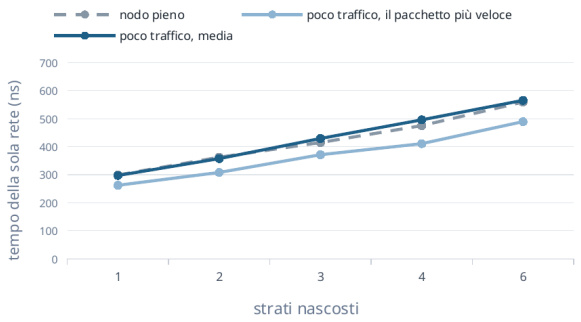
Sull'E-core P3 ha la stessa forma, più in alto del 16–21 %: la forma migliore del modello non dipende dal core su cui girerà.

SLIDE 17

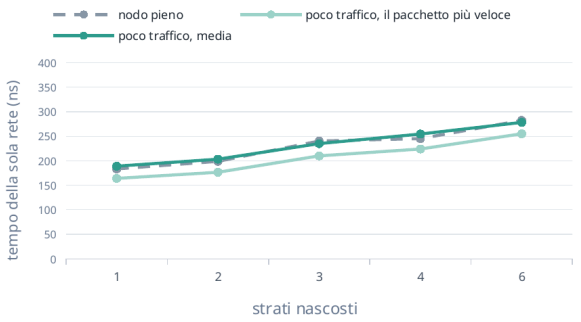
Poco traffico o nodo pieno: la rete di P2 e P3 costa uguale

4 · LA FORMA DEL MODELLO · DUE MODI DI MISURARE

Poco traffico o nodo pieno: la rete di P2 e P3 costa uguale



P3 (mediane). Con poco traffico la rete costa 1,02 volte quanto a nodo pieno: uguale, entro il rumore. Il pacchetto più veloce costa il 14 % meno della media.



P2: 1,03 volte, uguale entro il rumore. P1 e P1.5 no (0,77 e 0,83): la loro rete è troppo piccola per le due misure.

QUINDI

Due modi indipendenti di misurare la rete, a nodo pieno e con poco traffico, danno lo stesso costo per P2 e P3 su ogni modello. Il pacchetto più veloce è quello che trova la cache già pronta.

Tempo letto dal programma stesso, con 0,25 e 0,5 milioni di pacchetti al secondo, meno il nodo senza rete · mediane per strati, 53 modelli · P-core 17

Prima di passare alla sola rete neurale, un controllo su come la si misura. Il costo della rete si può ricavare in due modi indipendenti:

- **a nodo pieno**: il tempo per pacchetto meno quello del nodo senza rete (slide 4);
- **con poco traffico**: con i tre orologi della slide 12, il tempo del programma meno lo stesso tempo del nodo senza rete.

Ogni grafico ha tre curve, mediane per numero di strati: **nodo pieno** (grigio tratteggiato), **poco traffico, il pacchetto più veloce** (chiaro) e **poco traffico, media** (scuro). **A sinistra P3, a destra P2.**

In mediana, per P3 la media con poco traffico vale 1,02 volte il costo a nodo pieno, per P2 1,03: **le due misure danno lo stesso costo**, entro il rumore. Il pacchetto più veloce costa circa il 14 % meno della media.

Perché il pacchetto più veloce costa meno. Fra un pacchetto e l'altro il core riceve, inoltra e serve il kernel, e una parte di ciò che il programma aveva in cache viene sostituita. Il pacchetto più veloce è quello che trova tutto già pronto; la media è il costo tipico, e coincide con quello misurato a nodo pieno.

P1 e P1.5 no. Per loro le due misure non coincidono (0,77 e 0,83 volte). La loro rete costa poche decine di ns sopra un nodo senza rete di circa 67: una differenza piccola fra due misure grandi, che i due metodi stimano con errori diversi. Per P1 e P1.5 il riferimento è il tempo a nodo pieno.

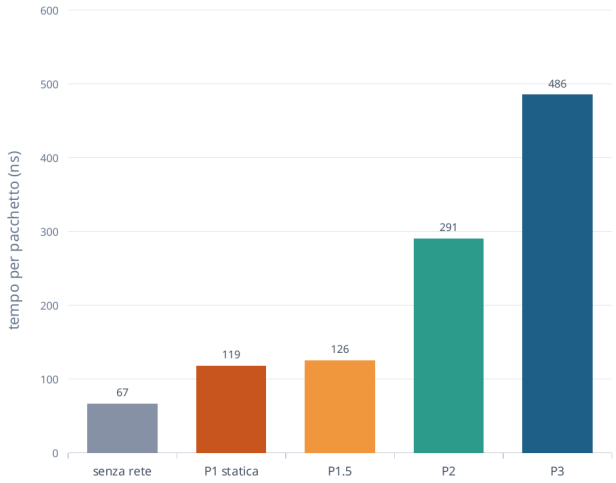
Da qui in poi ogni tempo è il **tempo a nodo pieno meno il nodo senza rete**: il costo che il nodo paga davvero per la rete neurale.

SLIDE 18

La configurabilità si paga per pacchetto: da +52 a +420 ns

5 · LA SOLA RETE NEURALE · IL PREZZO DELLA CONFIGURABILITÀ

La configurabilità si paga per pacchetto: da +52 a +420 ns



Versione	Istruzioni	Letture tabella	Salti
P1 statica	624	5	1
P1.5	961	6	1
P2	16 813	12	1
P3	12 288	23–54	2–7

QUINDI

Il prezzo della configurabilità sta nelle **letture di tabella** (in mediana da 5 con P1 a 35 con P3) e nei **salti fra programmi** (P3 ne fa uno per strato), non nelle moltiplicazioni. In mediana P2 costa **4,3 volte** P1, P3 **7,8 volte**; P1.5 quasi come P1.

Mediane su 91 modelli (P2: 85) · tempo per pacchetto, P-core · letture e salti contati da una versione del programma che li conta

Il grafico dà il tempo per pacchetto in mediana sui 91 modelli: 67 ns senza rete, 119 con P1, 126 con P1.5, 291 con P2, 486 con P3. La sola rete neurale costa quindi da **+52 ns (P1) a +420 ns (P3)**.

La tabella spiega da dove viene la differenza, con tre proprietà del programma (mediane):

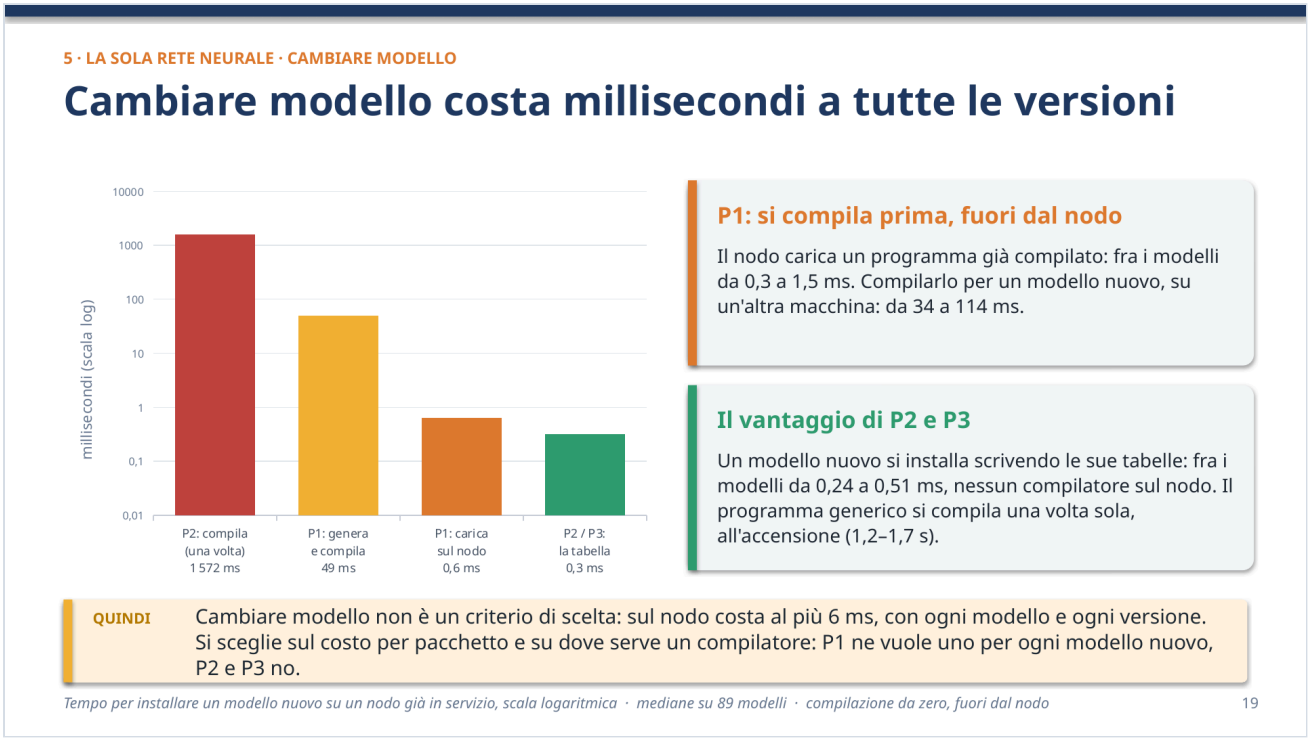
- **istruzioni**: la dimensione del programma;
- **letture di tabella** per pacchetto: quante volte il programma consulta una tabella. 5 per P1, 6 per P1.5, 12 per P2, e per P3 da 23 a 54 secondo il modello, circa 6 in più per ogni strato. Le conta una versione del programma che incrementa un contatore a ogni lettura;
- **salti fra programmi** per pacchetto: P1, P1.5 e P2 sono un programma solo, raggiunto con un salto; P3 salta una volta per ogni strato (da 2 a 7 salti), su 89 modelli su 89.

Esempio. P2 ha circa 16 800 istruzioni, P3 12 288: P3 è più piccolo, eppure costa quasi il doppio. Lo spiegano i salti (uno per strato) e le letture di tabella (35 contro 12 per pacchetto).

Il prezzo della configurabilità sta nelle letture di tabella e nei salti, non nelle moltiplicazioni. Modello per modello, P2 costa 4,3 volte P1 e P3 7,8 volte, in mediana; P1.5 quasi come P1. I rapporti più alti vengono dai modelli più piccoli, dove P1 costa poche decine di ns.

SLIDE 19

Cambiare modello costa millisecondi a tutte le versioni



Questi non sono tempi per pacchetto, ma il tempo per **installare un modello nuovo** su un nodo già in servizio. Il grafico (scala logaritmica: ogni tacca vale dieci volte la precedente) dà le mediane:

- **P2 e P3: compilare il programma generico**, una volta sola all'accensione del nodo: 1,2–1,7 secondi;
- **P1: generare e compilare** il programma con i pesi dentro, su una macchina qualunque fuori dal nodo: 34–114 millisecondi secondo il modello;
- **P1: caricarlo sul nodo**: 0,3–1,5 ms. Il kernel controlla che il programma sia sicuro e lo traduce in codice macchina;
- **P2 e P3: scrivere le tabelle** con i pesi del modello nuovo: 0,24–0,51 ms.

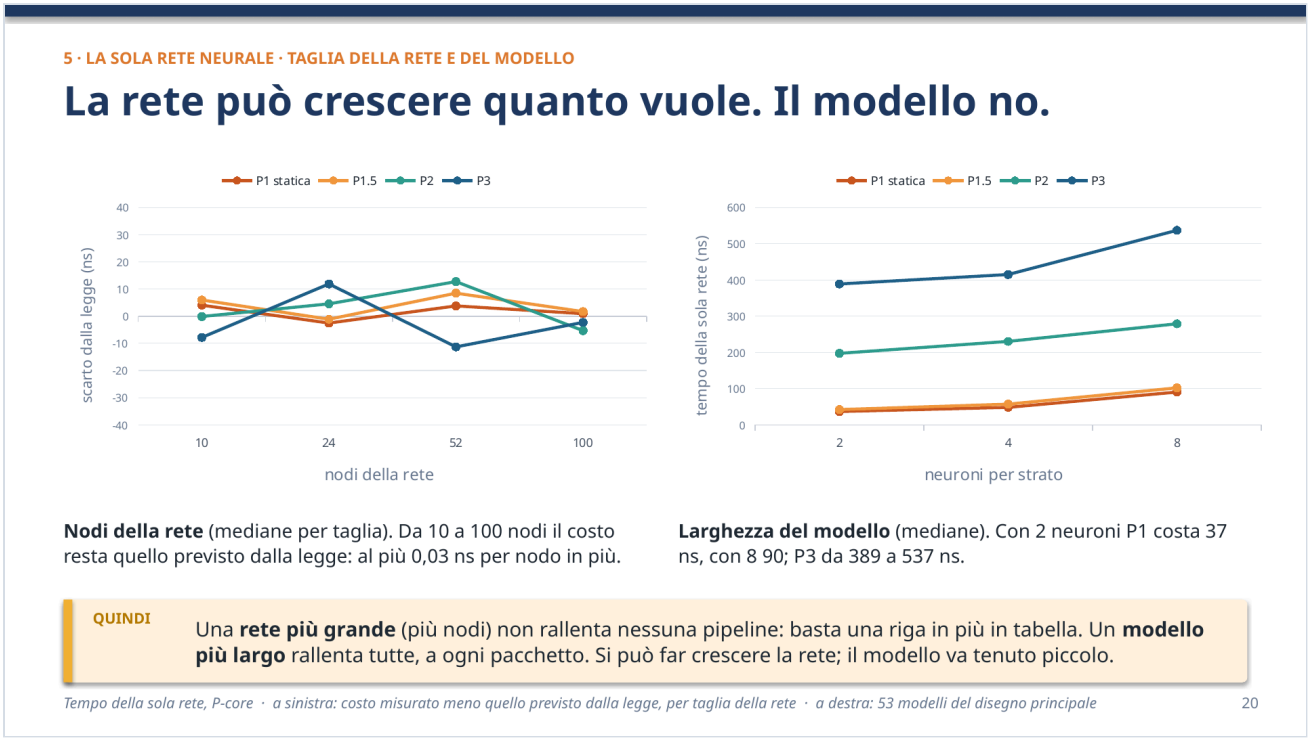
Perché P1 non ha bisogno di un compilatore sul nodo. Il programma con i pesi si compila prima, su un'altra macchina (*ahead of time*), e al nodo arriva un file già pronto, che un piccolo caricatore attacca. Sul nodo non serve né il compilatore né il suo ambiente.

Cambiare modello non è quindi un criterio di scelta: sul nodo costa meno di 6 ms a tutte le versioni. Si sceglie sul costo per pacchetto (slide 18) e su dove serve un compilatore: P1 ne vuole uno per ogni modello nuovo, su qualche macchina; P2 e P3 nessuno.

Che cosa non dice. Scrivere le tabelle è misurato su un nodo che le ha già aperte. E non dice che cosa succede ai pacchetti che passano **mentre** il modello cambia: è una prova che il banco non fa ancora.

SLIDE 20

La rete può crescere quanto vuole. Il modello no.



A sinistra la taglia della rete. Fra gli ingressi di 56 modelli c'è l'identità del nodo, codificata con una colonna per ogni nodo della rete (10, 24, 52 o 100 nodi), di cui una sola vale 1. Il grafico dà, per ogni taglia, lo **scarto dalla legge**: il costo misurato meno quello previsto dalla legge della slide 23, che non tiene conto dei nodi. Se la taglia della rete costasse qualcosa, lo scarto crescerebbe con i nodi. Non cresce: oscilla di qualche ns attorno a zero, al più 0,03 ns per nodo in più.

Il motivo: delle colonne dell'identità del nodo una sola vale 1, e il programma legge solo i pesi di quella colonna, qualunque sia il numero di nodi.

A destra la larghezza del modello: più neuroni per strato. Il costo sale su tutte e quattro le versioni: P1 da 37 a 90 ns, P3 da 389 a 537 ns. Un neurone in più è lavoro vero a ogni pacchetto.

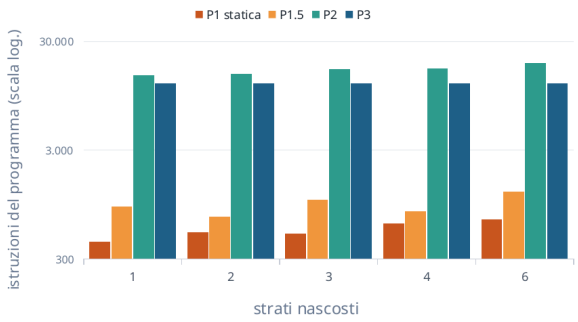
Una rete più grande non rallenta nessuna versione: basta una riga in più in tabella. Un modello più largo rallenta tutte. Si può far crescere la rete; il modello va tenuto piccolo.

SLIDE 21

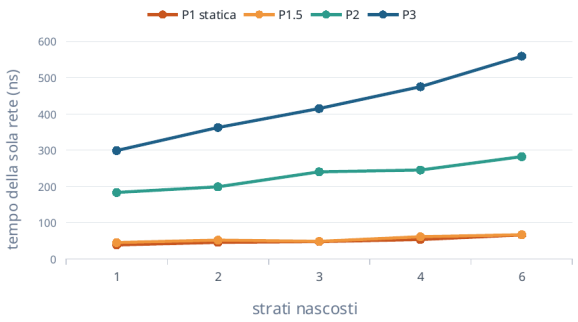
Uno strato in più: P2 lo paga in spazio, P3 in tempo

5 · LA SOLA RETE NEURALE · PROFONDITÀ

Uno strato in più: P2 lo paga in spazio, P3 in tempo



Dimensione (legge). P2: ~890 istruzioni in più per strato. P3: sempre 12 288.



Tempo (legge). Ogni strato costa a P3 ~46 ns, a P2 ~20, a P1 e P1.5 ~1.

QUINDI

Un modello profondo si paga sempre: P2 con un programma più grande da compilare, P3 con ~46 ns in più a ogni pacchetto per ogni strato. P3 è la versione più flessibile, ed è quella che la profondità rallenta di più.

Mediane per numero di strati, 53 modelli del disegno principale · dimensione: istruzioni del programma caricato · tempo: sola rete, P-core 21

Mediane per numero di strati nascosti, sui modelli del disegno principale.

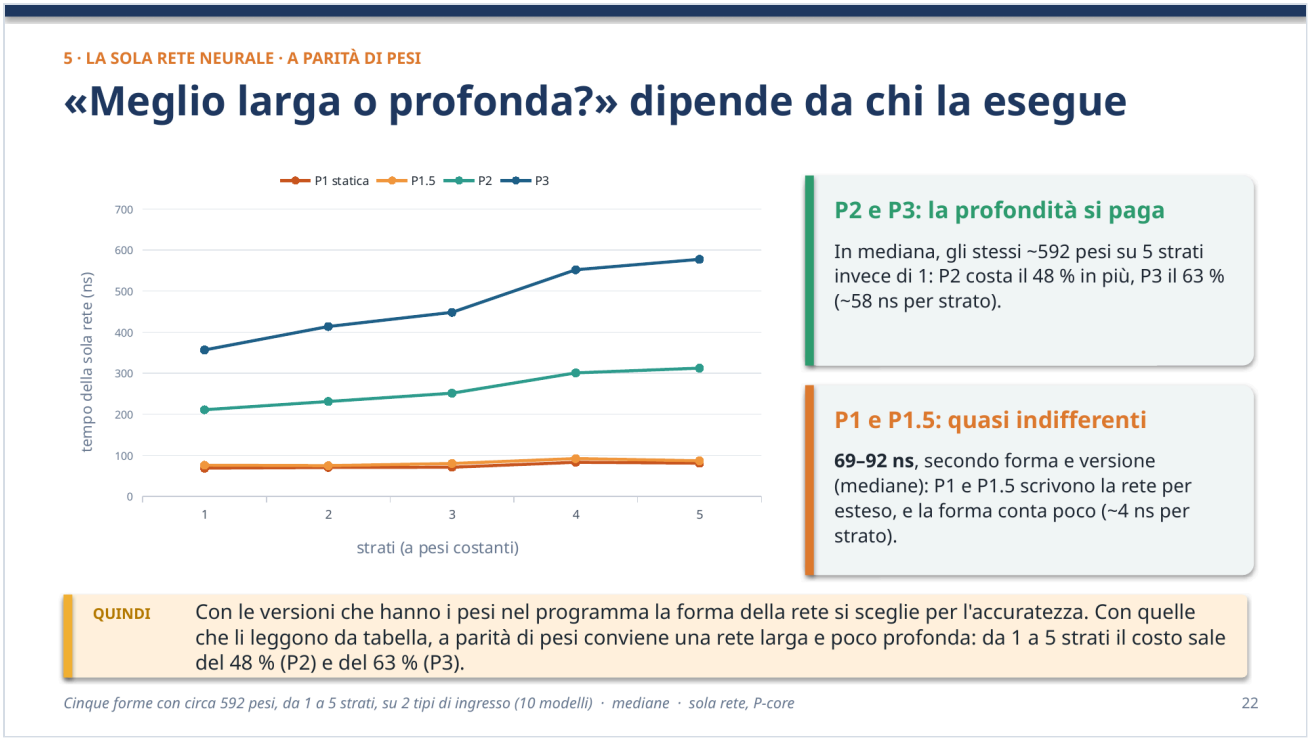
A sinistra la dimensione del programma (scala logaritmica). P2 si ricompila per ogni profondità e scrive per esteso il codice di ogni strato: circa 890 istruzioni in più per strato. P3 non si muove: 12 288 istruzioni con ogni modello, perché esegue sempre lo stesso strato generico.

A destra il tempo della sola rete. Ogni strato costa a P3 circa 46 ns, perché è un salto fra programmi e un giro di letture di tabella (le ~900 istruzioni della slide 15); a P2 circa 20 ns; a P1 e P1.5 quasi niente.

Un modello profondo si paga sempre: con P2 in un programma più grande da compilare, con P3 in tempo a ogni pacchetto. P3 è la versione più flessibile, ed è quella che la profondità rallenta di più.

SLIDE 22

«Meglio larga o profonda?» dipende da chi la esegue



Le dieci forme a pari pesi: circa 592 pesi in un solo strato largo, oppure distribuiti su fino a cinque strati più stretti, su due tipi d'ingresso. Lo stesso numero di pesi, disposto in modo diverso. Il grafico dà la mediana dei due tipi d'ingresso.

- **P2 e P3: la profondità si paga.** Da 1 a 5 strati P2 costa il 48 % in più, P3 il 63 % (circa 58 ns per strato).
- **P1 e P1.5: quasi indifferenti.** 69–92 ns di rete, circa 4 ns per strato: il compilatore scrive tutta la rete per esteso in una funzione sola, e la forma conta poco.

Esempio. Lo stesso budget di circa 592 pesi costa a P3 357 ns in un solo strato e 577 in cinque: la scelta della forma vale più di 200 ns per pacchetto con P3, una decina con P1.

Qui uno strato costa a P3 58 ns invece dei 46 della legge: a pesi fermi, passare da uno strato largo a più strati stretti cambia anche il numero di moltiplicazioni, che la legge conta a parte.

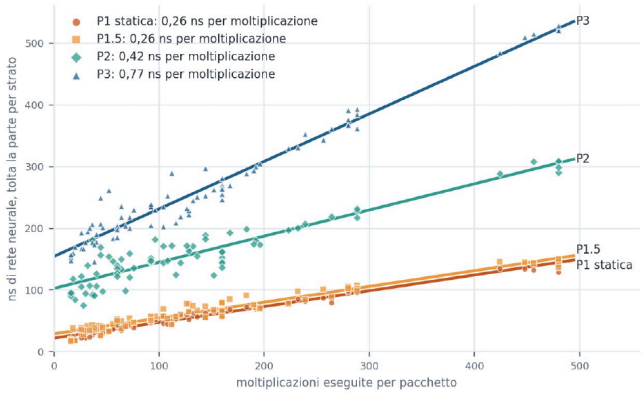
Con P1 e P1.5 la forma della rete si sceglie per l'accuratezza. Con P2 e P3, a parità di pesi, conviene una rete larga e poco profonda.

SLIDE 23

Il costo di un modello si può prevedere prima di misurarlo

5 · LA SOLA RETE NEURALE · PREVEDERE IL COSTO

Il costo di un modello si può prevedere prima di misurarlo



Versione	fisso · moltipl. · strati
P1 statica	40 % · 50 % · 8 %
P1.5	48 % · 46 % · 5 %
P2	47 % · 18 % · 31 %
P3	37 % · 18 % · 39 %

Dove va il tempo. Con P1 e P1.5 circa metà è moltiplicazioni. Con P2 e P3 circa l'82 % è struttura: il lavoro fisso e quello per strato, cioè salti fra programmi e letture di tabella. Su modelli mai visti la legge sbaglia del 3–9 %.

QUINDI **Costo della rete ≈ fisso + moltiplicazioni × costo di una + strati × costo di uno.** P1: ~22 ns + 0,26 ns per moltiplicazione. P3: ~154 ns + 0,77 ns per moltiplicazione + ~46 ns per strato.

Stimata su 83 modelli senza pesi a zero, errore su modelli lasciati fuori · grafico: costo meno la parte per strato · tabella: quanto pesa ogni parte 23

Si può sapere quanto costerà un modello prima di misurarlo? Su tutti gli 83 modelli senza pesi a zero, il costo della rete segue una legge semplice:

costo della rete ≈ parte fissa + moltiplicazioni × costo di una + strati × costo di uno

Sul P-core:

- **P1**: 22 ns + 0,26 ns per moltiplicazione + 1 ns per strato;
- **P1.5**: 29 ns + 0,26 ns per moltiplicazione + 1 ns per strato;
- **P2**: 103 ns + 0,42 ns per moltiplicazione + 20 ns per strato;
- **P3**: 154 ns + 0,77 ns per moltiplicazione + 46 ns per strato.

Il trucco è contare le moltiplicazioni **davvero eseguite**. Un ingresso codificato con molte colonne di cui una sola vale 1 (come l'identità del nodo) occupa molte colonne di pesi, ma il programma ne legge una sola: contato dalla forma del modello sembra costoso, nel programma no.

Il grafico mostra ogni modello: sull'asse orizzontale le moltiplicazioni eseguite, su quello verticale il costo della rete tolta la parte per strato. I punti cadono sulle rette.

> **Su modelli che non ha mai visto.** La legge si stima lasciando fuori un modello alla volta e prevedendo quello: sbaglia in mediana del 3 % per P3, del 6 % per P1 e P2, del 9 % per P1.5. Il costo di un modello nuovo si stima quindi prima di misurarlo, con qualche punto percentuale di errore. (Per chi conosce la statistica: r^2 fra 0,93 e 0,99; contando le moltiplicazioni dalla forma del modello scende a 0,58–0,79.)

Dove va il tempo. La tabella dà, per ogni versione, quanto pesa in mediana ciascuna parte della legge (parte fissa · moltiplicazioni · strati):

- **P1**: 40 · 50 · 8 %; **P1.5**: 48 · 46 · 5 %. Con i pesi nel programma circa metà del tempo sono moltiplicazioni;
- **P2**: 47 · 18 · 31 %; **P3**: 37 · 18 · 39 %. Con i pesi in tabella circa l'82 % del tempo è **struttura**: la parte fissa (il primo programma, la lettura della descrizione del modello, la preparazione degli ingressi da tabella) e la parte per strato (il salto allo strato generico e la rilettura del suo contesto).

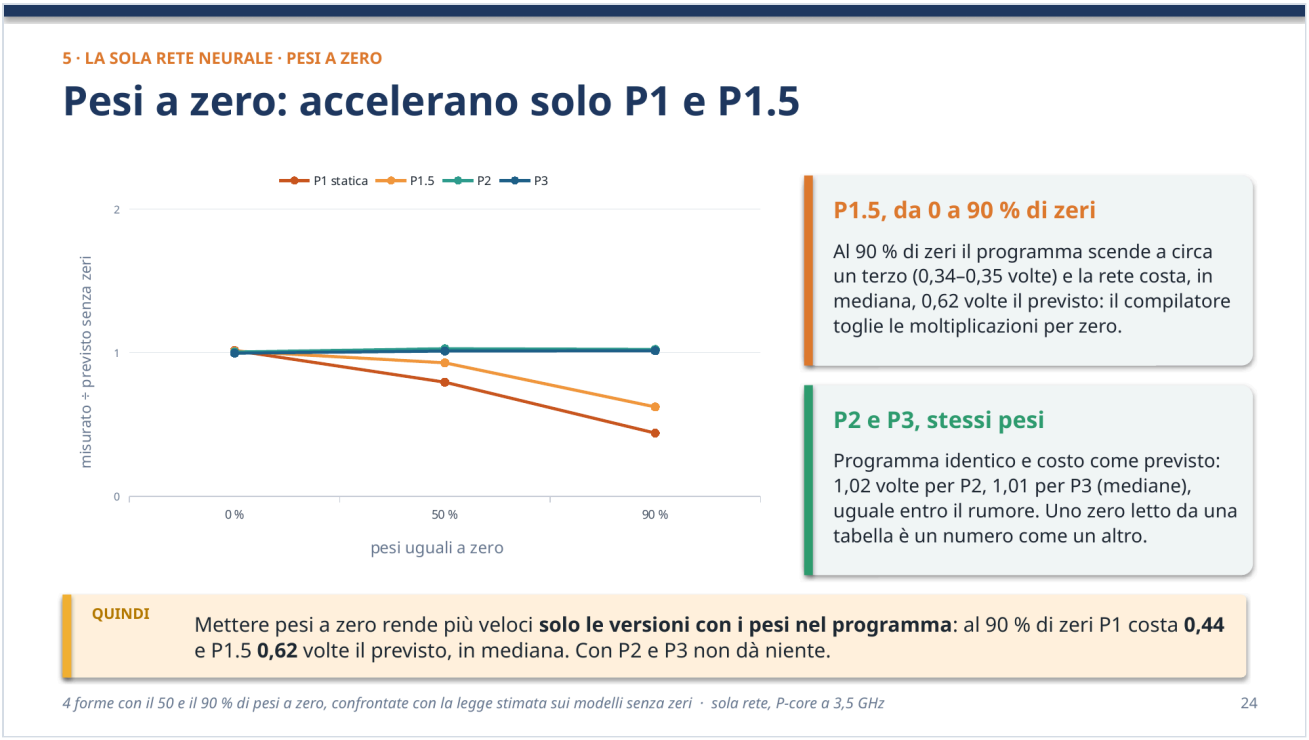
Anche il costo per moltiplicazione contiene le tabelle: P3 paga 0,77 ns per moltiplicazione contro 0,26 di P1 perché legge ogni peso da una tabella, mentre in P1 il peso è un numero scritto nel programma.

> **Nessun passaggio fuori dal kernel.** Le tabelle si leggono dentro il kernel, senza mai uscire verso i programmi normali: questi le scrivono solo quando si installa un modello. Quanto dei 46 ns per strato di P3 sia il salto e quanto le letture di tabella, la campagna non lo separa.

Anche i valori dei pesi contano poco: sei forme ripetute con pesi estratti in modo diverso danno un costo che varia al più del 5–6 % (2 % per P3).

SLIDE 24

Pesi a zero: accelerano solo P1 e P1.5



Le quattro forme con il 50 e il 90 % di pesi esattamente uguali a zero. Il grafico dà il costo misurato della rete diviso quello che la legge della slide 23 prevede per lo stesso modello senza zeri: 1 vuol dire «come previsto», sotto 1 «più veloce».

- **P1 e P1.5 accelerano**: al 90 % di zeri P1 costa 0,44 volte il previsto e P1.5 0,62. Il programma di P1.5 scende a circa un terzo delle istruzioni: il compilatore vede che un peso è zero e toglie la moltiplicazione.
- **P2 e P3 non cambiano**: 1,02 e 1,01 volte il previsto in mediana, cioè come previsto entro il rumore, con un programma identico a quello senza zeri. Uno zero letto da una tabella è un numero come un altro, e la moltiplicazione si fa comunque.

È l'unico caso in cui dimensione del programma e tempo scendono insieme. Mettere pesi a zero (potare il modello) rende più veloci solo le versioni con i pesi nel programma; con P2 e P3 non dà niente in velocità, e va scelto solo per l'accuratezza.