

Quaderno di lavoro

Che cosa è cambiato e perché

Settembre 2026 — dal laboratorio emulato
al datapath reale

Progetto **IPA/eBPF**

inferenza di una rete neurale dentro il kernel, a bordo del pacchetto

Ogni numero di questo quaderno viene da una misura eseguita,
non da una stima. Dove una cosa non è stata verificata, è scritto.

Indice

1	Di che cosa stiamo parlando	3
1.1	L'idea in una pagina	3
1.2	Dove gira: XDP	3
1.3	Le tre pipeline	3
2	La matematica che sta dentro il kernel	4
2.1	Perché i numeri sono interi	4
2.2	Il problema dei bias, e l'errore che ci stava dentro	4
2.3	Il TTL: dividere il prodotto, mai il valore	5
3	Le classi non sono porte	6
3.1	Il problema	6
3.2	La soluzione: una catena esplicita	6
3.3	Un errore che questa separazione ha fatto emergere	7
4	Il motore non è lo scenario	8
4.1	Com'era	8
4.2	Com'è adesso: tre strati	8
4.3	La prova	9
5	Dall'emulatore al kernel vero	10
5.1	Che cosa provavano i test di prima	10
5.2	Il banco nuovo	10
5.3	Tre difetti del test, trovati misurando	10
5.4	Il risultato	11
6	La feature che non c'era	12
6.1	Il sintomo	12
6.2	Perché nessun test lo vedeva	12
6.3	La correzione	12
6.4	La prova che adesso è viva	13
6.5	Il prezzo, misurato	13
7	Il nodo non sapeva di essere un nodo	14
7.1	L'ingresso più grande di tutti	14
7.2	Il sintomo	14
7.3	La correzione, e perché una tabella e non un array	14
7.4	Una pipeline ha resistito un giorno	14
7.5	La prova che il nodo è vivo	15
8	Il verificatore non conta le istruzioni	16
8.1	Due monete diverse	16
8.2	Il ciclo era girato dalla parte sbagliata	16
8.3	Perché il risultato non cambia di un bit	16
8.4	Il risultato, che sembra un errore	16


8.5	Un effetto collaterale che vale una riga di tabella	17
9	I numeri, e che cosa dicono davvero	18
9.1	La tabella	18
9.2	Primo risultato: la dimensione non predice la velocità	18
9.3	Secondo risultato: quanto valgono le latenze assolute	19
9.4	Terzo risultato: la genericità ha un costo di verifica	20
9.5	Quarto risultato: togliere il compilatore dal nodo	20
9.6	Che cosa questi numeri non dicono	20
10	Come cresce il costo	22
10.1	La domanda	22
10.2	Come è impostata la misura	22
10.3	Profondità: chi paga in spazio e chi in tempo	23
10.4	Aggiornare il modello: due ordini di grandezza	24
10.5	Congelare il nodo: conviene?	24
10.6	Due larghezze, due risposte opposte	27
10.7	I pesi contano, ma solo per una delle tre	29
10.8	Il risultato che non cercavamo	29
10.9	Che cosa questi grafici non dicono	30
11	Quel che resta	31
11.1	Fatto	31
11.2	Aperto	31
11.3	Il filo conduttore	32

Di che cosa stiamo parlando

1.1 L'idea in una pagina

Un router normale decide dove mandare un pacchetto consultando una tabella riempita da un protocollo di routing. L'idea di **IPA** (*Intelligent PAckets*) è diversa: il pacchetto **porta con sé** una piccola rete neurale, e ogni nodo che attraversa la esegue per decidere l'uscita.

Niente segnalazione, niente tabella condivisa: la decisione nasce dai dati che il nodo ha sotto mano in quel momento.



Il modello è una rete piccola: quattro tipi di ingresso, due strati nascosti da quattro neuroni, sette uscite. In tutto **319 pesi**. Deve stare in un header ed essere eseguibile in decine di nanosecondi.

1.2 Dove gira: XDP

Il codice gira in **eBPF** agganciato a **XDP**, il punto più precoce in cui il kernel Linux permette di toccare un pacchetto: prima che venga costruita la struttura `sk_buff`, quindi prima di quasi tutto il resto dello stack di rete.

Questo impone un vincolo forte, che spiega metà delle scelte di progetto: un programma eBPF deve essere **dimostrato sicuro** da un componente del kernel chiamato *verificatore* prima di poter girare. Niente cicli di lunghezza ignota, niente accessi non controllati alla memoria, niente ricorsione. Tutto ciò che nel documento sembra contorto — cicli srotolati, tetti dichiarati a priori, tabelle al posto di calcoli — nasce da lì.

1.3 Le tre pipeline

Lo stesso modello è implementato in tre modi, per misurare un compromesso.

	i pesi stanno	cambiare modello
P1 hardcoded	scritti nel codice C	ricompilare
P2 template	in una mappa	scrivere la mappa
P3 modular	in una mappa, uno strato per programma	scrivere la mappa

P1 è veloce perché il compilatore vede i pesi e li semplifica; è rigido perché ogni modello nuovo richiede una ricompilazione. P2 e P3 sono l'opposto. Il lavoro di settembre serve a rendere questo confronto *misurabile davvero*.

La matematica che sta dentro il kernel

2.1 Perché i numeri sono interi

Nel kernel non ci sono numeri in virgola mobile: eBPF lavora con interi. Il modello però è addestrato in virgola mobile. Serve una conversione, e si chiama **quantizzazione**.

Ogni peso reale w diventa un intero a 8 bit:

$$w_{\text{int}} = \text{round}(w \cdot s)$$

dove s è il **fattore di scala**, uno solo per tutta la rete.

Perché il risultato stia in un byte con segno serve

$$s \cdot \max_i |w_i| \leq 127.$$

Sul modello depositato $\max |w| = 5,098$, quindi $s \leq 24,9$. Due scelte convivono nel progetto: $s = 24$ (il massimo intero ammesso) e $s = 16$ (la potenza di due più vicina per difetto, che rende le divisioni degli shift).

Superare quel limite non dà un errore: dà un *overflow silenzioso*. I pesi grandi si troncano e il modello sbaglia senza che nulla lo segnali. Per questo i test distinguono le scale *rappresentabili* da quelle che saturano, e misurano solo sulle prime.

2.2 Il problema dei bias, e l'errore che ci stava dentro


Qui sta l'errore più sottile trovato in settembre, e vale la pena seguirlo passo passo perché è istruttivo.

Quando moltiplichiamo un ingresso per un peso quantizzato, il risultato porta un fattore s in più rispetto al valore reale:

$$x \cdot w_{\text{int}} = x \cdot w \cdot s.$$

Se impiliamo gli strati, quel fattore si accumula. Dopo $\ell + 1$ moltiplicazioni l'accumulatore dello strato ℓ porta $s^{\ell+1}$.

Ma il **bias** è memorizzato come un peso qualsiasi, cioè con un solo fattore s . Sommarlo così com'è significa sommare una quantità sistematicamente troppo piccola. Va riportato nelle unità dell'accumulatore:



La regola è semplice: allo strato ℓ (contando da zero) il bias va moltiplicato per s^ℓ .

L'errore

Il modello di riferimento in Python — quello con cui si controlla che il datapath calcoli la cosa giusta — applicava s^0 e s^1 correttamente ai primi due strati, e lasciava l'**ultimo strato** a s^0 invece di s^2 .

Il bias dell'uscita era sottopesato di $s^2 = 24^2 = 576$.

Perché nessuno se n'era accorto per mesi

Tutti i test eseguivano il modello con **tutti i link attivi**. In quella condizione gli accumulatori sono grandi e un errore di 576 non sposta mai il massimo. Basta spegnere qualche link perché gli accumulatori si riducano e l'errore decida l'esito.

Nello stesso file c'era una seconda funzione di riferimento, scritta per forme arbitrarie, che usava la formula generale s^ℓ ed era **già corretta**. Due riferimenti, uno giusto e uno sbagliato, e quello sbagliato era l'unico mai esercitato con link spenti.

Corretto l'errore, il riferimento e le tre pipeline concordano su tutti i casi provati.

La lezione non è "c'era un bug". È che **un test che varia un solo ingresso non è un test**: verifica una condizione e la ripete. Ci torneremo nel capitolo 5, dove lo stesso schema si ripresenta in una forma ancora più netta.

2.3 Il TTL: dividere il prodotto, mai il valore

Il modello è addestrato con il TTL *normalizzato*, cioè ttl/T con $T = 30$ il valore iniziale. Con i numeri interi

$$\frac{\text{ttl}}{30} = 0 \quad \text{per ogni } \text{ttl} < 30,$$

e la feature sparirebbe. La divisione va quindi applicata al *prodotto*:

$$\left\lfloor \frac{\text{ttl} \cdot w_{\text{int}}}{T} \right\rfloor \quad \text{e non} \quad \left\lfloor \frac{\text{ttl}}{T} \right\rfloor \cdot w_{\text{int}}.$$

Nel C generato si legge esattamente così:

```
(((__s64)_ttl * 11LL) / 30LL)
```

Le classi non sono porte

3.1 Il problema

La rete produce sette numeri; il più grande vince. Ma *che cosa significa* la classe vincente?

All'inizio di settembre la risposta era sparsa e incoerente. In punti diversi del progetto convivevano quattro convenzioni su quale classe significasse "scarta il pacchetto":

Convenzione	Dove
la classe 6 è DROP	in un punto
la classe 5 è DROP	in un altro
$\text{DROP} = n_{\text{out}} - 1$	in un terzo
$\text{DROP} = \max(\text{etichette}) + 1$	dedotto dai dati

E sotto ce n'era una quinta, implicita e più insidiosa: che la classe k volesse dire "manda fuori dall'interfaccia k ". Funzionava per caso, perché nel modello depositato le porte sono numerate come le classi.

3.2 La soluzione: una catena esplicita

Adesso il significato è **dichiarato**, mai dedotto, e passa per una catena di quattro passi, ognuno con un responsabile diverso:



- **classe**: quello che il modello ha calcolato;
- **azione**: FORWARD, DROP o UNUSED — una classe mai addestrata esiste ed è dichiarata tale;
- **porta logica**: un numero che il *modello* conosce;
- **ifindex**: l'interfaccia vera, che solo il *nodo* conosce e che è diversa su ogni macchina.

Nel modello depositato la dichiarazione è:

classe	azione	porta logica
0-4	FORWARD	0-4
5	DROP	—
6	UNUSED	—

Il punto non è che adesso funziona: funzionava anche prima, per coincidenza numerica. Il punto è che adesso **smetterebbe di funzionare rumorosamente** se il modello cambiasse, invece di continuare a girare dando risposte plausibili e sbagliate.

3.3 Un errore che questa separazione ha fatto emergere

Il datapath teneva un contatore per classe, ma scriveva nella casella della *porta* invece che in quella della *classe*. Sembrava giusto perché le due numerazioni coincidono nel modello depositato.

Con un modello in cui non coincidono, il contatore avrebbe misurato la cosa sbagliata in silenzio. Separare i due spazi di indici ha reso l'errore visibile e correggibile.

Il motore non è lo scenario

4.1 Com'era

Il progetto era nato attorno a una topologia precisa: **Germany50**, una rete di 50 router usata come riferimento in letteratura, con due host attaccati, emulata con **Kathara** (container Docker connessi a formare la rete).

Due numeri erano ovunque nel codice:

$$n_{\text{nodi}} = 52, \quad n_{\text{interfacce}} = 6.$$

Il primo è $50 + 2$. Il secondo è il **grado massimo** della rete: il nodo con più vicini. Non è il grado di un nodo qualsiasi — tutti gli altri riempiono di zeri gli slot che non usano.

Questi numeri determinano la larghezza dell'ingresso:

$$n_{\text{in}} = \underbrace{6}_{\text{link}} + \underbrace{6}_{\text{iface}} + \underbrace{1}_{\text{ttl}} + \underbrace{52}_{\text{nodo}} = 65.$$

Il problema non era che esistessero, ma che il motore li conoscesse. C'era un *default* interno: se nessuno diceva niente, il motore assumeva 6 e 52. Ogni chiamante che dimenticava di specificare lo scenario risultava silenziosamente corretto per Germany50 e silenziosamente sbagliato altrove.

4.2 Com'è adesso: tre strati



La dipendenza punta **solo verso l'alto**. Il motore non sa che cosa sia Germany50.

Le dimensioni si risolvono in ordine: una variabile d'ambiente, poi un file di sistema, poi il blocco `trained_on` del descrittore del modello. Se nessuna delle tre risponde, il motore **si ferma** e dice dove ha cercato.

Un default comodo è il modo più efficace di nascondere un'assunzione. Preferire un errore esplicito a un valore plausibile è una scelta di progetto, non pignoleria: il valore plausibile non si manifesta mai come errore, solo come risultato sbagliato mesi dopo.

4.3 La prova

Non basta dirlo. Il motore genera oggi un datapath corretto per cinque topologie che non hanno niente a che vedere con quella d'origine:

iface	nodì	strati	n_{in}	n_{out}	vettore link
3	8	4-4	15	4	v[3]
4	16	6	25	5	v[4]
5	24	4-4-4	35	6	v[5]
2	6	3-3	11	3	v[2]
6	52	4-4	65	7	v[6]

Nessuna riga di C scritta a mano cambia fra una riga e l'altra.

Dall'emulatore al kernel vero


5.1 Che cosa provavano i test di prima

Fino a settembre ogni misura veniva da una chiamata di sistema, `BPF_PROG_TEST_RUN`: si dà al programma un buffer, lo si esegue N volte, e il kernel riporta quanti nanosecondi in media.

È utile e onesto per confrontare le tre pipeline fra loro. Ma non tocca un'interfaccia, non ha un driver, non consegna niente. Il programma poteva dire "redirigerei sulla porta 3" e nessuno verificava che un pacchetto ne uscisse davvero.

5.2 Il banco nuovo

Kathara è stato sostituito da qualcosa di più semplice e più vicino al vero: coppie di interfacce virtuali (veth) create sull'host.



Si inietta un frame da un capo, il programma XDP gira davvero, e si legge da quale interfaccia è uscito. Questo risponde alla domanda che `BPF_PROG_TEST_RUN` non può porre.

Due dettagli che sembrano minori e non lo sono

Modalità di attacco. XDP si può agganciare in due modi: *native*, dentro il driver, prima che esista la `sk_buff`; oppure *generic*, dopo. Il progetto usava sempre *generic*, e il motivo era scritto nel codice: serviva per le interfacce dentro i container dell'emulatore. Tolto l'emulatore, quel motivo cade. Adesso il default è *native*, la modalità *davvero in effetto* viene riletta dal kernel dopo l'aggancio, e un fallimento è un errore, non una retrocessione silenziosa.

Il vincolo delle veth. Redirigere *verso* una veth funziona solo se il lato ricevente ha a sua volta un programma XDP agganciato: il kernel alloca le code necessarie solo in quel caso. Senza, il redirect fallisce in silenzio e il pacchetto sparisce — indistinguibile da un modello che decide di scartare tutto. Il banco aggancia quindi un programma minimo a ogni capo.

5.3 Tre difetti del test, trovati misurando

Il banco nuovo ha trovato più difetti nei *test* che nel prodotto. Vale la pena elencarli, perché il motivo per cui erano invisibili è sempre lo stesso.

1. Il TTL non muove questo modello

La prima versione del test variava il TTL da 2 a 8 e riportava *"7 verifiche su 7 superate"*. Misurando lo spazio raggiungibile si scopre che con tutti i link attivi il modello risponde **sempre classe 2**, per qualsiasi TTL. Quel 7 su 7 era **un caso solo, ripetuto sette volte**.

È `link_state` la feature che sposta la decisione. Il test adesso *cerca* un ingresso per ogni classe, invece di spazzare alla cieca.

2. Un pacchetto del kernel contato come risultato

Su una veth appena creata il kernel manda del traffico suo (IPv6 multicast). Una volta è stato catturato e contato come la risposta della pipeline. È passato per caso, perché era sulla porta giusta.

Adesso la cattura filtra sui campi che il datapath non riscrive, e IPv6 viene disabilitato sulle interfacce del banco.

3. La porta 0 era invisibile per costruzione

L'ingresso era anche la porta logica 0. Una classe che inoltrava su quella porta rimandava il frame fuori dall'interfaccia da cui era entrato — dove la cattura non lo distingue da quello appena iniettato. Una decisione *corretta* sulla porta 0 non era osservabile.

Il banco ha adesso un ingresso dedicato, separato da tutte le porte.

Un test che non può fallire non è un test. In tutti e tre i casi il risultato era verde e privo di contenuto, e in tutti e tre il difetto è emerso solo mettendo in mezzo un kernel vero.

5.4 Il risultato

Tutte e tre le pipeline superano oggi la verifica end-to-end su un datapath reale: XDP native, redirect vero, pacchetto ripreso sulla porta d'uscita, e scarto verificato dal *contatore* e non dal silenzio — perché "non è arrivato niente" è anche ciò che si osserva quando il redirect si perde.

La feature che non c'era

6.1 Il sintomo


Il modello ha quattro ingressi. Uno di questi è *da quale interfaccia è arrivato il pacchetto*, codificato *one-hot*: un vettore di sei posizioni con un solo uno.

Il datapath leggeva l'indice dell'interfaccia dato dal kernel — l' *ifindex* — e lo usava direttamente come posizione nel vettore, con un controllo di validità:

$$1 \leq \text{ifindex} \leq n_{\text{interfacce}}.$$

Gli *ifindex* però li assegna il kernel, in ordine di creazione. Su un container appena avviato valgono 2, 3, 4. Su una macchina che ha creato qualche interfaccia virtuale valgono 205, 217, 229.

Il controllo falliva sempre. **Nessun bit veniva acceso.** Il modello girava di fatto su tre ingressi invece di quattro.




6.2 Perché nessun test lo vedeva

Perché nessun test controllava che quella feature *contribuisse* qualcosa. Riferimento e datapath la ignoravano entrambi, quindi **concordavano** — e l'accordo veniva registrato come successo.

Una pipeline aveva in effetti una tabella di traduzione, ma compilata dentro il programma come [2, 3, 4, 5, 6, 7]: la stessa assunzione, scritta in un altro modo. Le altre due usavano l'indice grezzo. Le tre pipeline sceglievano quindi *colonne diverse* per lo stesso pacchetto — una discrepanza documentata in un commento e mai risolta.

6.3 La correzione

La traduzione è diventata una **tabella a runtime**, riempita dal piano di controllo leggendo le interfacce del nodo:



È il **simmetrico** della tabella già usata in uscita: là "quale interfaccia realizza la porta che il modello ha scelto", qui "quale porta è l'interfaccia da cui il pacchetto è arrivato". Entrambe sono fatti del nodo, entrambe si risolvono quando il nodo esiste.

6.4 La prova che adesso è viva

Prima e dopo la correzione, gli ingressi che raggiungono ciascuna classe **cambiano**:

classe	prima (feature morta)	dopo (feature viva)
0	100110, ttl 27	100111, ttl 20
1	010000, ttl 2	010000, ttl 14
5	000000, ttl 2	000000, ttl 12

Stesso stato dei link, TTL diverso per ottenere la stessa classe: l'ingresso in più contribuisce. E il TTL ora sposta la decisione, cosa che prima non faceva.

6.5 Il prezzo, misurato

Una lettura di tabella in più per pacchetto:

	prima	dopo
letture per pacchetto (P1)	4,0	5,0
letture per pacchetto (P3)	26,0	28,0
istruzioni (P1)	997	971

Le istruzioni di P1 *calano*: la tabella ha sostituito un blocco switch a sei casi, e una lettura costa meno di un salto.

Una lettura in più arriverà poco dopo, per la stessa ragione applicata a un altro ingresso: è il capitolo che segue. Le cifre finali sono 6,0 letture per P1 e 29,0 per P3.

Il nodo non sapeva di essere un nodo

7.1 L'ingresso più grande di tutti


Dei quattro ingressi del modello, quello che pesa di più è *quale nodo sta elaborando il pacchetto*. Su Germany50 sono 52 nodi, quindi un vettore one-hot di 52 posizioni: **208 dei 319 pesi** della rete, quasi due terzi.

7.2 Il sintomo

Il datapath riempiva quel vettore con il campo `model_id` preso dall'intestazione IPA del pacchetto.

Sono due cose diverse. `model_id` dice *quale modello* il pacchetto chiede di usare; il vettore vuole sapere *quale nodo* lo sta elaborando. E il `model_id` non cambia lungo il percorso: è scritto dal mittente e viaggia identico fino alla destinazione.

Con un solo modello registrato — il caso normale — **ogni nodo della rete accendeva la stessa identica posizione**. Due terzi dei pesi della rete non distinguevano nulla.



7.3 La correzione, e perché una tabella e non un array

Stessa forma della correzione precedente: una **tabella letta a runtime**, riempita quando il nodo viene messo in servizio, dalla variabile d'ambiente `IPA_NODE_ID` o dall'indice del nodo nella topologia.

Un dettaglio che sembra tecnico e non lo è: la tabella è di tipo *hash* e non *array*. Un array in questo ambiente è preallocato e riempito di zeri, quindi una lettura riesce **sempre**: "non configurato" e "sono il nodo 0" tornerebbero lo stesso valore, indistinguibili. Sarebbe esattamente il difetto che la tabella serve a togliere. Con un hash, finché nessuno scrive non c'è voce: il vettore resta spento, ed è la risposta onesta.

Questo errore è stato commesso e corretto: la prima versione usava un array, e un test su un'architettura alternativa è fallito 5 volte su 5 prima che se ne capisse il motivo.

7.4 Una pipeline ha resistito un giorno

P1 e P2 hanno accettato la modifica subito. P3 no: il verificatore del kernel ha **rifiutato il programma**, dodici configurazioni di fila.

Il motivo è controintuitivo e vale la pena averlo scritto. Il verificatore non misura quanto è lungo il programma: esplora i *cammini* possibili, e il numero di stati che deve tenere è il **prodotto** dei valori indipendenti che segue dentro un ciclo srotolato, non la loro somma.

$$\text{stati} \sim v_1 \times v_2 \times \cdots \times v_k$$

L'unica versione che caricava era quella in cui l'indice del nodo *non era un valore indipendente*: `nodo = model_id`, cioè lo stesso registro che il verificatore stava già seguendo. Un valore, non due.

Escluse una a una, ognuna con la sua prova: il tipo di tabella, la sua dichiarazione, il valore, il tipo del dato, il numero di letture, la larghezza in bit. Nessuna era la causa.

Quello che ha liberato spazio non toccava il nodo: un **tetto** di tutt'altra feature. Il programma teneva in vita otto posizioni per un vettore di occupazione delle code che il modello depositato *non dichiara nemmeno*. Portato quel tetto da 8 a 1, il programma ha caricato — e più piccolo di prima.

Questi limiti sono **scogliere, non pendenze**. Nello stesso giro, ridurre *anche* un secondo tetto — cioè chiedere *meno* — ha fatto fallire di nuovo il caricamento. Un tetto qui si cambia e **si rimisura**; non si ragiona.

7.5 La prova che il nodo è vivo

Stesso programma compilato, due esecuzioni che differiscono solo per la tabella del nodo:

esecuzione	esito sul pacchetto
senza indice di nodo	scartato
indice di nodo = 7	non scartato

Nient'altro è cambiato fra le due. L'ingresso sposta la decisione.

Il verificatore non conta le istruzioni

8.1 Due monete diverse

Il tetto sulle code portato a 1 era una perdita vera: a 1, un modello che dichiara davvero quella feature viene *rifiutato*. Per recuperarlo serviva margine di verifica, e il margine è arrivato da una riscrittura che non toglie niente.

8.2 Il ciclo era girato dalla parte sbagliata

Il primo strato della rete si calcola così: per ogni neurone, si sommano i contributi di ogni feature dichiarata nel descrittore.

Il codice lo faceva nell'ordine ovvio — neuroni fuori, feature dentro:

```
per ogni neurone j (8 volte)
  per ogni feature f (4 volte)
    di che tipo e' f?      <- catena a 5 rami
    di che larghezza e' f? <- controllo per ogni posizione
  accumula
```

Ma *di che tipo* e *di che larghezza* è una feature non dipende dal neurone. Quella catena a cinque rami veniva quindi rivalutata $8 \times 4 = 32$ volte per pacchetto, e il controllo sulla larghezza di un vettore denso $8 \times 8 = 64$ volte, per ottenere ogni volta la stessa risposta.

Girato al contrario — feature fuori, neuroni dentro — diventa:

```
per ogni feature f (4 volte)
  di che tipo e' f?      <- 4 volte, non 32
  di che larghezza e' f? <- 8 volte, non 64
  per ogni neurone j (8 volte)
    accumula              <- nessun ramo qui dentro
```

8.3 Perché il risultato non cambia di un bit

Cambia solo l'ordine in cui i termini vengono sommati. I termini sono gli stessi, calcolati allo stesso modo. E la somma fra interi a 64 bit in complemento a due è associativa e commutativa — anche in caso di traboccamento, che si comporta identicamente nei due ordini:

$$(a + b) + c = a + (b + c).$$

Ogni accumulatore finisce quindi **bit per bit identico**. Non "circa uguale": identico.

8.4 Il risultato, che sembra un errore

	prima	dopo
P2, programma principale	16 144	14 587
P3, primo strato	6 417	6 850
P3, tetto sulle code caricabile	1	8

P3 è **cresciuto** di 433 istruzioni ed è diventato molto più economico da verificare. Prima della riscrittura, col tetto delle code a 8 non caricava niente; dopo, carica a 10 207 istruzioni.

Dimensione del programma e complessità di verifica sono **monete diverse**. Il verificatore paga i cammini.

8.5 Un effetto collaterale che vale una riga di tabella

Contare quante letture di tabella fa un programma per pacchetto richiede di ricompilarlo con un contatore su ogni punto di lettura. Le versioni strumentate di P2 e P3 **sforavano il verificatore**: per questo la riga "letture di tabella" riportava *n.d.* per entrambe.

Con il margine liberato dalla riscrittura, tutte e due caricano. La misura che era impossibile è diventata una riga di tabella — 11 letture per P2, 29 per P3 — senza che nessuno abbia riscritto il contatore.

I numeri, e che cosa dicono davvero

9.1 La tabella

Misure su una macchina virtuale a 4 processori, modello 65-4-4-7, scala 24.

	baseline	P1	P2	P3
istruzioni caricate	155	1 026	14 628	12 031
salto fra programmi	0	1	1	3
letture di tabella	3,0	6,0	11,0	29,0
memoria delle tabelle	280 B	2 356 B	10 416 B	19 508 B
latenza (minimo di 7)	29 ns	73 ns	262 ns	421 ns

Il *baseline* è un programma che analizza il pacchetto e lo rimanda fuori senza alcuna inferenza: è il pavimento contro cui si legge tutto il resto.

Tutte le colonne vengono dalla **stessa esecuzione**, sulla stessa macchina, nello stesso minuto. La riga "letture di tabella" è piena per la prima volta: fino alla riscrittura del capitolo precedente, per P2 e P3 diceva *n.d.*

9.2 Primo risultato: la dimensione non predice la velocità


P3 ha il 18% di istruzioni in meno di P2 ed è il 61% più lento.

Il motivo sta nelle due righe centrali: tre salti fra programmi invece di uno, e ventinove letture di tabella per pacchetto invece di undici.

Il conteggio delle istruzioni misura quanto è *grande* il programma caricato, non quanto *lavoro* fa per pacchetto. In questo regime a dominare sono le letture di memoria e i salti, non l'aritmetica.

Perché P2 è più grande, pur essendo più veloce

Le due cose hanno la stessa causa: **P3 non tiene la rete intera in un programma.**



P3 srotola **un** solo strato denso generico e ci rientra, con un salto fra programmi, a ogni passo della rete. Così la *profondità* del modello non costa dimensione: un modello a quattro

strati gira sullo stesso identico binario. P2 deve srotolarli tutti, perché è un programma solo — e un modello più profondo richiede un altro binario.

Quel riuso è esattamente ciò che P3 paga in latenza: ogni rientro è un salto più le letture che servono a ricostruire il contesto perduto.

La stessa scelta di progetto spiega *entrambi* i numeri: P3 è più piccolo **perché** riusa un pezzo, ed è più lento **perché** riusarlo costa un salto e delle letture ogni volta.

9.3 Secondo risultato: quanto valgono le latenze assolute

Ogni cifra di latenza in tabella è il **minimo di sette misure** indipendenti. Guardando come sono distribuite quelle sette, dentro una singola esecuzione:

	baseline	P1	P2	P3
minimo	29 ns	73 ns	262 ns	421 ns
mediana	30 ns	88 ns	278 ns	453 ns
massimo	32 ns	99 ns	327 ns	476 ns
dispersione	10%	36%	25%	13%

Il 36% di P1 è *dentro* una sola esecuzione, sullo stesso binario, in pochi secondi. Le **istruzioni sono identiche** fra esecuzioni diverse: sono deterministiche. Le latenze no.

Su questa macchina virtuale una differenza di latenza sotto il 20%–30% **non significa nulla**, nemmeno dentro la stessa esecuzione. Valgono i rapporti fra le colonne, non le cifre.
Ogni valore assoluto va letto come ordine di grandezza su questa VM, mai come prestazione del sistema.

Un caso in cui la regola è servita

Il tetto sulle code di P3, riportato da 1 a 8, aggiunge **3 357 istruzioni** al programma:

	tetto 1	tetto 8
istruzioni (P3)	8 674	12 031
letture per pacchetto	29,0	29,0
latenza	419 ns	421 ns

Il 39% di istruzioni in più costa **2 nanosecondi**, cioè niente, e le letture non si muovono di una. Il motivo è semplice: il modello depositato non dichiara la feature delle code, quindi quel ramo del programma *non viene mai eseguito*. Cresce la dimensione statica; il percorso eseguito è lo stesso.

Una metrica che si sposta del 39% senza che cambi nulla di ciò che gira **non è una misura di costo**. Il numero di istruzioni va letto come "quanto è grande il binario", mai come "quanto lavora".

Questo ha reso necessario rifare la tabella dei risultati: la versione precedente presentava tre esecuzioni etichettate come ripetizioni, ma venivano in realtà da *stati diversi del codice*.

9.4 Terzo risultato: la genericità ha un costo di verifica

P2 serve qualsiasi modello che stia sotto certi tetti dichiarati a priori (numero massimo di neuroni, di ingressi, di feature). È il suo pregio: non ricompila mai.

Il conto però lo paga il verificatore del kernel, che percorre ogni cammino del corpo srotolato. Con i tetti larghi il kernel si arrende:

```
processed 1000001 insns (limit 1000000) ... total_states 13864
```

Da notare: il programma è lungo circa 14 900 istruzioni, **ampiamente dentro** il limite di dimensione. Quello che finisce è la *complessità di verifica*, che è un limite diverso e cresce col **prodotto** dei tetti:

$$\text{costo di verifica} \sim H_{\max} \times F_{\max} \times N_{\max}.$$

È la misura concreta di quanto un programma "generico" possa esserlo. La genericità di P2 non è gratis: si paga in stati del verificatore, e il tetto si tocca con numeri ragionevoli (8 neuroni, 4 feature, 128 ingressi).

9.5 Quarto risultato: togliere il compilatore dal nodo

P1 scrive i pesi *dentro* il codice come numeri letterali. È ciò che la rende veloce — il compilatore può far sparire le moltiplicazioni per zero e trasformare in scorrimenti quelle per potenze di due — ma ha un prezzo: ogni volta che il modello cambia, bisogna **rieseguire il compilatore sul nodo**.

Misurato in questa esecuzione: **1 242 ms**. Più di un secondo in cui quel nodo non sta aggiornando niente.

L'alternativa è compilare *prima*, su una macchina qualunque, e spedire al nodo l'oggetto già pronto. Al momento del deploy il nodo apre il file e lo carica, senza compilatore:

	con compilatore sul nodo	oggetto precompilato
costo di messa in servizio	1 242 ms	37 ms
istruzioni	1 026	979
latenza per pacchetto	73 ns	74 ns

Due ordini di grandezza sul costo di aggiornamento, e **nessun costo per pacchetto**: 74 ns contro 73 ns è la stessa cifra, dentro il rumore misurato sopra. La riduzione fatta dal compilatore sui pesi letterali resta dentro l'oggetto.

Una cautela sul numero 37: il costo di caricamento varia molto fra esecuzioni — sono stati osservati 4,7, 6,2, 20,7 e 37,2 ms per lo stesso oggetto. Quello che regge è l'*ordine di grandezza* rispetto al secondo e un quarto del compilatore, non la cifra precisa.

Vale solo quando i modelli sono noti in anticipo, che è l'ipotesi sotto cui P1 esiste.

9.6 Che cosa questi numeri non dicono

BPF_PROG_TEST_RUN esegue il programma in un ciclo sullo stesso buffer. Niente scheda di rete, niente driver, nessuna allocazione, nessuna pressione di cache da traffico vero.

Il valore in "milioni di pacchetti al secondo" è semplicemente $1/\text{latenza}$: un **picco teorico**, non un throughput retto. Per quello serve traffico vero, generato a ritmo, e la misura di quanti pacchetti si perdono.

Come cresce il costo

10.1 La domanda

Fin qui tutto è misurato su *un* modello e *una* topologia. La domanda che manca è come cambia il costo quando la rete o il modello diventano più grandi — e soprattutto se le tre pipeline hanno **pendenze diverse**.

Se le pendenze fossero uguali, averne più di una sarebbe un esercizio. Non lo sono, ed è questo il capitolo che lo mostra.

Le pipeline confrontate sono **quattro**, e formano una scala di *quanto si sa quando il programma viene compilato*:

	compilato dentro	un binario per
P1 specializzata	pesi e indice di questo nodo	nodo
P1.5 hardcoded	pesi; il nodo si legge a runtime	modello
P2 template	solo i soffitti	tutto
P3 modular	anche la profondità è a runtime	tutto

La P1.5 è quella che i capitoli precedenti chiamano semplicemente P1: la *disposizione* delle feature è scritta nel codice, ma l'indice del nodo no. La P1 specializzata congela anche quello — ed è il confronto con cui si chiude il capitolo.

10.2 Come è impostata la misura


Cinque assi, e su ciascuno si muove **una sola** variabile: tutto il resto resta fermo, così una curva si può attribuire a quello che c'è scritto sull'asse delle ascisse e a nient'altro.

asse	valori	si ferma perché
nodi della rete	10, 25, 52, 75, 100	il tetto sugli ingressi è 128
hidden layer	da 1 a 6	—
neuroni per layer	2, 4, 6, 8	il tetto compilato è 8
composizione dell'IV	4 varianti	0, 1 o 2 one-hot
pesi a zero	0% ... 90%	—

Tre accortezze che hanno cambiato i risultati, non solo la forma:

- **Ogni misura in un processo separato.** P1 può far abortire il compilatore in modo non recuperabile; e un rifiuto del verificatore è un *dato*, non un guasto dello strumento.
- **I pesi vengono da un sacchetto fisso**, e un modello più grande *estende* quello più piccolo invece di sostituirne tutti i pesi. Senza questo, spostandosi lungo un asse cambiavano due cose insieme, e parte della curva di P1 era rumore dei pesi travestito da asse x.
- **Un allarme automatico sulle misure sporche:** se una pipeline ha lo stesso identico programma e la latenza varia più del doppio lungo l'asse, lo scarto è la macchina e lo strumento lo dice.


10.3 Profondità: chi paga in spazio e chi in tempo



P2 cresce di circa 780 istruzioni per ogni hidden layer. P3 di zero.

P3 srotola *un* solo strato denso generico e ci rientra a ogni passo della rete, quindi la profondità non entra nel programma: la sua riga è perfettamente orizzontale, da uno a sei strati. P2 deve srotolarli tutti, perché è un programma solo.


Ma la storia non finisce lì:



E P3 lo paga in tempo: circa 70 nanosecondi per strato, contro i 36 di P2. Sono i salti fra programmi, da 2 a 7.

Le due figure hanno la *stessa* causa vista dai due lati. P3 è più piccolo **perché** riusa un pezzo, ed è più lento **perché** riusarlo costa un salto e delle letture ogni volta. È il compromesso della modularità, ridotto a due numeri.

10.4 Aggiornare il modello: due ordini di grandezza



Attenzione alla scala verticale: è **logaritmica**. Su scala lineare le due curve basse sarebbero schiacciate sullo zero e si vedrebbe una curva sola.


Installare un modello nuovo su un nodo già in servizio costa **circa 1,4 secondi** in P1 — che deve rigenerare il C e richiamare il compilatore — e **circa 7 millisecondi** in P2 e P3, che scrivono in una tabella.

È la misura che decide se una pipeline è usabile in una rete che cambia.

10.5 Congelare il nodo: conviene?

L'indice del nodo è una **costante del deployment**: un nodo non cambia di posto. Il codice però lo legge a runtime, e per farlo porta uno switch con un caso per ogni nodo della rete — 52 casi per Germany50, di cui ne esegue *uno*.

Congelandolo a tempo di generazione lo switch sparisce, e con lui la lettura della tabella. Restano quattro numeri costanti, che il compilatore può piegare dentro al conto.



La taglia della rete entra nel programma **solo** nella P1.5, che passa da 746 a 1692 istruzioni fra 10 e 100 nodi.

Congelando il nodo quella dipendenza **sparisce**: la riga viola è piatta, fra 611 e 640 a qualunque taglia.

(La scala è logaritmica: in lineare le due righe P1 resterebbero schiacciate contro le quattordicimila di P2, e il confronto fra loro — che è il punto della figura — non si vedrebbe.)

Ma la velocità non cambia

nodi	10	25	52	75	100
P1 specializzata	58	68	54	55	55 ns
P1.5 hardcoded	61	60	57	59	61 ns


Praticamente identiche, dentro il rumore.

Il motivo per cui la *dimensione* crolla e il *tempo* no è lo stesso: lo switch ha 52 casi ma ne esegue uno. A runtime è un salto indicizzato, che costa poco; quelle 208 assegnazioni sono compilate per eseguirne quattro.

Toglierle libera molto **spazio** e quasi nessun **tempo**.

Il controllo, e perché ci si può fidare

Come si fa a essere sicuri che il divario venga davvero dalla one-hot del nodo e non da qualcos'altro che è cambiato per caso? Si prende un vettore d'ingresso che la feature *non* la contiene:



Nelle due composizioni senza la feature node le due P1 sono **identiche alla cifra** (599 e 599; 575 e 575). In quelle che ce l'hanno, divergono. Il divario è tutto lì e nient'altro.

C'è poi una verifica che viene prima di ogni numero. Congelare il nodo significa scegliere *una colonna* della matrice dei pesi al momento di generare il codice: sceglierne una sbagliata darebbe un programma più piccolo, più veloce, e che calcola **un altro modello** — e nessuna misura di costo se ne accorgerebbe. Ottanta casi, dieci valori di TTL per otto configurazioni di link: la versione congelata decide sempre la stessa classe di quella che legge il nodo dalla tabella.

I due vantaggi non si sommano

pesi a zero	0%	25%	50%	75%	90%
P1 specializzata	614	566	417	294	216
P1.5 hardcoded	1071	939	686	363	224

Al 90% di zeri il divario è sparito. Sparsità e nodo congelato sono **due strade alla stessa riduzione**: se i pesi sono già quasi tutti zero, il compilatore cancella lo switch da solo e non resta niente da congelare.

Il verdetto

Congelare il nodo **non è un'ottimizzazione di velocità**. È ciò che rende la pipeline hardcoded *praticabile su una rete grande*.


Lo switch della P1.5 cresce col numero di nodi moltiplicato per la larghezza del primo strato. Su una topologia da 500 nodi con 8 neuroni sarebbero quattromila assegnazioni srotolate, e c'è una taglia oltre la quale quel programma non si carica più. La specializzata non ci arriva mai.

Il prezzo è **un binario per nodo**: 52 compilazioni e 52 installazioni, una per macchina. Il costo di aggiornamento si moltiplica proprio per la grandezza da cui la specializzazione ha appena liberato la dimensione.

Su Germany50, dove la differenza è fra 614 e 1 071 istruzioni a parità di velocità, è una scelta legittima in entrambe le direzioni. Su una rete dieci volte più grande non lo è più.


10.6 Due larghezze, due risposte opposte

Questa coppia di figure è il risultato che preferisco di tutta l'analisi, perché la risposta non è quella che verrebbe da indovinare.




La taglia della *rete* entra nel programma solo in P1, che passa da 746 a 1 692 istruzioni fra 10 e 100 nodi: è lo switch della one-hot che si srotola. P2 e P3 restano alla cifra esatta a ogni punto, perché il loro codice non nomina mai la forma del modello.

E a runtime?



Piatte tutte e tre. Cento nodi costano quanto dieci. Il motivo è strutturale: una one-hot ha un solo uno, quindi il datapath legge *una sola colonna di pesi* qualunque sia la larghezza del vettore.


Allargare i layer *nascosti*, invece:



La rete può crescere quanto vuole; il modello no.

Allargare l'*ingresso* è gratis a runtime, perché una one-hot legge una colonna sola. Allargare i layer *nascosti* si paga, su tutte e tre le pipeline, perché ogni neurone in più sono pesi in più letti per ogni pacchetto.

10.7 I pesi contano, ma solo per una delle tre



Stessa identica forma in tutti e cinque i punti: cambia solo *quanti* pesi valgono zero.

Con il 90% dei pesi a zero, P1 passa da 1 071 a **224 istruzioni**. P2 e P3 non si muovono di una.

P1 scrive i pesi nel codice come numeri, quindi il compilatore vede una moltiplicazione per zero e la cancella. Per P2 e P3 uno zero è un byte in una tabella come un altro, e il programma è lo stesso.

Lo stesso vale per la composizione dell'ingresso: la figura del controllo, due sezioni più su, mostra che cambiare *quali* feature compongono il vettore d'ingresso ricompila entrambe le P1, mentre P2 e P3 leggono il descrittore da una tabella e non cambiano di una istruzione.

10.8 Il risultato che non cercavamo

Durante lo sweep una configurazione si è fatta rifiutare dal verificatore: quattro hidden layer da quattro neuroni. Le forme intorno caricavano tutte, inclusa quella *più grande* con cinque strati. Nessuna proprietà della profondità può produrre una cosa del genere.

Tenendo ferma la forma e cambiando solo il seme casuale dei pesi:

seme	esito
42	rifiutato
1	carica, 1 119 istruzioni
2	carica, 1 175
7	carica, 1 118
999	carica, 1 075

Il seme 1 carica a 1 119 istruzioni; il 42 viene rifiutato a 1 120. Una istruzione di differenza.

In P1, riaddestrare un modello senza toccare l'architettura può renderlo non caricabile. Stessa rete, stessi iperparametri, pesi nuovi, e il nodo lo rifiuta. P2 e P3 non hanno questo rischio: per loro i pesi sono byte in una tabella, e che il programma si carichi dipende solo dalla forma.

È il rovescio esatto del vantaggio di due pagine fa. La stessa riduzione del compilatore che porta P1 a 224 istruzioni è quella che lo rende imprevedibile. Un compromesso vero, misurato su entrambi i lati.

Il meccanismo preciso — *quale* limite del kernel — non è stato confermato, e non va inventato: il messaggio d'errore parla di un programma troppo lungo e cita un limite di 4096 istruzioni che nella stessa esecuzione P2 supera di quattro volte. È la stessa costante morta già incontrata sul capitolo del verificatore.

10.9 Che cosa questi grafici non dicono

- **Non si confrontano latenze prese da assi diversi.** A programma identico, P2 misura circa 250 ns su due assi e circa 310 sugli altri due: la macchina si è caricata a metà esecuzione. Dentro un asse i confronti reggono. Le istruzioni, che sono deterministiche, si confrontano ovunque.
- La figura sulla larghezza va letta per la *direzione*, non per la pendenza, per lo stesso motivo.
- Oltre circa 115 nodi non si va senza alzare un tetto compilato e **rimisurare**.

Quel che resta

11.1 Fatto

- semantica delle classi dichiarata, mai dedotta; catena classe → azione → porta logica → interfaccia;
- motore indipendente dallo scenario, dimostrato su cinque topologie diverse;
- emulatore rimosso; verifica end-to-end su datapath reale con XDP native;
- errore del bias nell'ultimo strato corretto;
- feature dell'interfaccia d'ingresso resa viva in tutte e tre le pipeline;
- **indice del nodo** letto a runtime da tabella in tutte e tre: era l'ultimo ingresso su cui le pipeline non concordavano, e pesa 208 pesi su 319;
- primo strato riscritto con i cicli invertiti in P2 e P3: stesso risultato bit per bit, un terzo dei rami in meno, e il margine di verifica che ne è uscito ha permesso di **recuperare il tetto sulle code** (da 1 a 8) e di **rimettere la riga delle letture di tabella**, che era n.d.;
- oggetto precompilato (AOT) compilato, caricato e misurato: aggiornamento del modello da 1 242 ms a 37 ms, a parità di costo per pacchetto;
- tabella dei risultati rifatta su uno stato del codice solo;
- **analisi parametrica** su cinque assi e tre pipeline: le pendenze sono diverse, ed è la misura che giustifica l'esistenza di tre pipeline invece di una;
- **versione P1 specializzata**: congela anche l'indice del nodo, e toglie alla pipeline hardcoded la dipendenza dalla taglia della rete — al prezzo di un binario per nodo;
- P2 non è più fissa a due hidden layer: la profondità è diventata un involuppo compilato come già lo erano le larghezze — al prezzo, onesto e misurato, di una ricompilazione per profondità.

11.2 Aperto

- **Throughput reale**: generare traffico a ritmo e misurare pacchetti al secondo, perdite e carico di CPU. È la misura che manca se la metrica principale è la velocità.
- **Versione intermedia fra P1 e P2**: pesi scritti nel codice ma descrittore letto a runtime. Oggi il salto fra P1 e P2 confonde due cambiamenti insieme, e non si può attribuire il costo all'uno o all'altro.
- **Hardware vero**: la scheda di rete di questa macchina virtuale è emulata e non supporta XDP native. I numeri assoluti restano non citabili come prestazioni di sistema.
- **Il tetto sull'uscita di P2**: lo strato finale è srotolato a 32 classi per un modello che ne ha 7, cioè 256 moltiplicazioni dove ne servono 28. Abbassarlo ridurrebbe molto il programma, ma *cambia il comportamento*: restringe l'insieme dei modelli rappresentabili. La strada

pulita è generare quel tetto dall’inviluppo dichiarato dal deployment invece di fissarlo nel sorgente — una ricompilazione per inviluppo, non per modello.

- **I salti fra programmi di P3:** sono tre per pacchetto ed è lì che sta la latenza, non nella dimensione. Ridurli è un lavoro diverso da quello fatto finora.
- **Perché quel modello non si carica:** sappiamo che dipende dai pesi e non dall’architettura, ma non *quale* limite del kernel venga toccato. Il messaggio d’errore ne nomina uno sbagliato. Serve il registro del verificatore, ed è un’ora di lavoro, non una settimana.
- **Rimisurare a macchina scarica:** metà delle latenze dell’analisi parametrica sono state prese mentre la VM era occupata. Le istruzioni no, quelle sono deterministiche.

11.3 Il filo conduttore

Guardando indietro, quasi tutti i problemi trovati a settembre hanno la stessa forma. Non erano calcoli sbagliati: erano **assunzioni non dichiarate** che risultavano vere per caso nell’unica configurazione mai provata.

Assunzione	Vera solo perché
classe k = interfaccia k	le porte erano numerate come le classi
DROP = ultima classe	nel modello depositato capitava così
$n_{\text{odi}} = 52$ di default	si provava una topologia sola
eth0 = ifindex 2	si provava dentro un container pulito
bias dell’uscita $\times s^0$	si provava coi link tutti attivi
one-hot del nodo = model_id	si registrava un modello solo
tabella vuota = nodo 0	l’array è preallocato a zero
si carica $\Rightarrow$ dipende dall’architettura	non si era mai cambiato solo i pesi

E quasi tutte sono emerse allo stesso modo: cambiando *una* condizione che nessun test aveva mai cambiato.

Un test verde dice che il codice si comporta come il test si aspetta. Non dice che il test stia chiedendo qualcosa.