Quaderno di lavoro

Come funziona, e quanto costa

Dal modello al datapath reale

misure della campagna del 6 ottobre 2026
e della campagna su 91 modelli dell'11–12 ottobre

Progetto **IPA/eBPF**

inferenza di una rete neurale dentro il kernel, a bordo del pacchetto

Ogni numero di questo quaderno viene da una misura eseguita,
non da una stima. Dove una cosa non è stata verificata, è scritto.

Indice

1 Di che cosa stiamo parlando **4**
1.1 L'idea in una pagina . . . 4
1.2 Dove gira: XDP . . . 4
1.3 Le tre pipeline . . . 4

2 La matematica che sta dentro il kernel **6**
2.1 Perché i numeri sono interi . . . 6
2.2 I bias vanno riportati nelle unità dell'accumulatore . . . 6
2.3 Il TTL: dividere il prodotto, mai il valore . . . 7

3 Le classi non sono porte **8**
3.1 Che cosa significa una classe . . . 8
3.2 Una catena esplicita . . . 8
3.3 Ogni modello ha la sua semantica . . . 8

4 Il motore non è lo scenario **10**
4.1 Le dimensioni vengono dalla configurazione . . . 10
4.2 La prova . . . 10

5 Il modello non è quello depositato **12**
5.1 La domanda . . . 12
5.2 I modelli sintetici . . . 12
5.3 Il confronto a quattro vie . . . 12
5.4 Il risultato . . . 13

6 Dalla chiamata di sistema al kernel vero **15**
6.1 Due banchi . . . 15
6.2 Come il test evita di essere vuoto . . . 15
6.3 Il risultato . . . 16

7 Gli ingressi che dipendono dal nodo **17**
7.1 L'interfaccia d'ingresso: una porta logica . . . 17
7.2 L'identità del nodo . . . 17
7.3 La prova che contano . . . 17

8 Il verificatore paga i cammini **19**
8.1 Che cosa fa il verificatore . . . 19
8.2 Il primo strato: feature fuori, neuroni dentro . . . 19
8.3 La ReLU: un bivio per neurone . . . 19
8.4 La ReLU senza bivio: il risultato . . . 21
8.5 La ReLU senza bivio: che cosa costa . . . 21

9 I numeri, e che cosa dicono davvero **23**
9.1 La tabella . . . 23
9.2 Primo risultato: la dimensione non predice la velocità . . . 23
9.3 Secondo risultato: quanto valgono le latenze assolute . . . 24
9.4 Terzo risultato: la genericità ha un costo di verifica . . . 25
9.5 Quarto risultato: togliere il compilatore dal nodo . . . 25
9.6 Che cosa questi numeri non dicono . . . 26

10 Come cresce il costo **27**
10.1 La domanda . . . 27
10.2 Come è impostata la misura . . . 27
10.3 Profondità: chi paga in spazio e chi in tempo . . . 28
10.4 Aggiornare il modello: millisecondi per tutte . . . 29
10.5 Larga o profonda? Dipende da chi la esegue . . . 30
10.6 Congelare il nodo: conviene? . . . 32
10.7 Congelare quali porte esistono . . . 34
10.8 Due larghezze, due risposte opposte . . . 36
10.9 I pesi contano, ma solo per una delle tre . . . 37
10.10 Che cosa questi grafici non dicono . . . 38

11 Il costo del programma, misurato da solo **39**
11.1 La campagna sulle architetture . . . 39
11.2 Il problema: le MAC nominali non predicono la latenza . . . 39
11.3 La soluzione: contare le MAC che vengono eseguite . . . 40
11.4 Due banchi, lo stesso programma, lo stesso numero . . . 40
11.5 Il programma sul percorso vero: tre marcature . . . 41

12 Il test reale: quanto costa un pacchetto al nodo **42**
12.1 La domanda, in parole semplici . . . 42
12.2 Com'è fatto il banco . . . 42
12.3 Come si misura, e perché così . . . 43
12.4 Il generatore . . . 43
12.5 Perché un core vero, tutto suo . . . 44
12.6 I limiti del test, con esempi . . . 45
12.7 Il risultato: quanto regge il nodo . . . 46
12.8 Uno scrittore per coda . . . 47
12.9 Al crescere del bit rate . . . 48
12.10 Due core . . . 52
12.11 Il nodo sui core lenti . . . 52
12.12 Gli assi sotto traffico vero . . . 53
12.13 Che cosa questo numero non dice . . . 54

13 La macchina di laboratorio, sotto controllo **55**
13.1 Un processore che non sta fermo . . . 55
13.2 Le condizioni, messe e tolte . . . 55
13.3 La frequenza scritta non è la frequenza vera . . . 56
13.4 Quale frequenza . . . 56
13.5 Il risultato: misure che si ripetono . . . 57
13.6 Come si rifà tutto . . . 57

14 Altri modelli, altre reti **58**
14.1 La domanda . . . 58
14.2 Scenario e modello . . . 58
14.3 Quando un modello può girare su una rete . . . 58
14.4 Come è costruito . . . 59
14.5 Che cosa controllano i test . . . 59
14.6 La prova che la strada generica non cambia niente . . . 60
14.7 I risultati . . . 60
14.8 Che cosa non fa . . . 61

15 Nessun modello privilegiato: la popolazione **62**
15.1 La domanda . . . 62
15.2 La popolazione . . . 62
15.3 Come si misura, e quanto è pulito il dato . . . 63
15.4 Correttezza . . . 63
15.5 Il costo del nodo . . . 64
15.6 P-core, E-core, LP E-core . . . 64
15.7 Sotto traffico crescente, e con due core . . . 65
15.8 Il programma, il trasporto, e due modi di misurare la rete . . . 65
15.9 La legge di costo . . . 65
15.10 La forma del modello . . . 67
15.11 Il programma da solo, e il cambio di modello . . . 67
15.12 Il resto è solido . . . 68
15.13 Le affermazioni, e su che cosa reggono . . . 68
15.14 Che cosa non dice . . . 69
15.15 Come rifarla . . . 69

16 I numeri in una pagina **71**

17 Quel che resta aperto **72**

18 I comandi **73**
18.1 La macchina . . . 73
18.2 Correttezza: il modello fa quello che deve . . . 73
18.3 Kernel: si carica, e quanto costa . . . 73
18.4 Altri modelli, altre reti . . . 74
18.5 Datapath reale: il pacchetto attraversa davvero . . . 74
18.6 Analisi parametrica: come cresce il costo . . . 74
18.7 Il test reale . . . 74
18.8 Costi specifici e oggetto precompilato . . . 75
18.9 L'ordine consigliato . . . 75

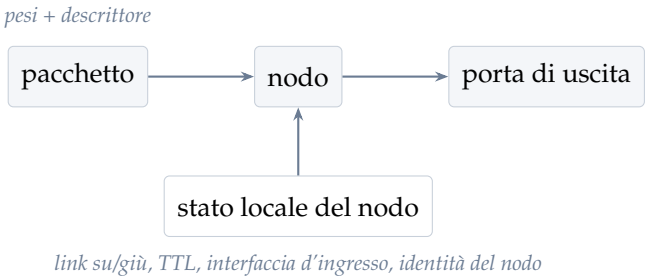
CAPITOLO 1

Di che cosa stiamo parlando

1.1 L'idea in una pagina

Un router normale decide dove mandare un pacchetto consultando una tabella riempita da un protocollo di routing. L'idea di **IPA** (*Intelligent PAckets*) è diversa: il pacchetto **porta con sé** una piccola rete neurale, e ogni nodo che attraversa la esegue per decidere l'uscita.

Niente segnalazione, niente tabella condivisa: la decisione nasce dai dati che il nodo ha sotto mano in quel momento.



Il modello è una rete piccola: quattro tipi di ingresso, due strati nascosti da quattro neuroni, sette uscite. In tutto **319 pesi**. Deve stare in un header ed essere eseguibile in decine di nanosecondi.

1.2 Dove gira: XDP

Il codice gira in **eBPF** agganciato a **XDP**, il punto più precoce in cui il kernel Linux permette di toccare un pacchetto: prima che venga costruita la struttura `sk_buff`, quindi prima di quasi tutto il resto dello stack di rete.

Questo impone un vincolo forte, che spiega metà delle scelte di progetto: un programma eBPF deve essere **dimostrato sicuro** da un componente del kernel chiamato *verificatore* prima di poter girare. Niente cicli di lunghezza ignota, niente accessi non controllati alla memoria, niente ricorsione. Tutto ciò che nel documento sembra contorto — cicli srotolati, tetti dichiarati a priori, tabelle al posto di calcoli — nasce da lì.

1.3 Le tre pipeline

Lo stesso modello è implementato in tre modi, per misurare un compromesso.

	i pesi stanno	**cambiare modello**
P1 hardcoded	scritti nel codice C	ricompilare
P2 template	in una mappa	scrivere la mappa
P3 modular	in una mappa, uno strato per programma	scrivere la mappa

P1 è veloce perché il compilatore vede i pesi e li semplifica; è rigido perché ogni modello nuovo richiede una ricompilazione. P2 e P3 sono l'opposto. Questo quaderno misura il compromesso.

P1 si costruisce **prima** (*ahead of time*, AOT): il C con i pesi scritti dentro si compila con clang su una macchina qualunque, e al nodo arriva l'oggetto pronto, che un piccolo caricatore in C apre e attacca. Il caricatore lascia vuote le tabelle e le «appunta» nel file system del kernel; il piano di controllo in Python le riempie con le interfacce vere del nodo, poi dice al caricatore di attaccare il programma. Ogni cifra di P1 in questo quaderno è di quell'oggetto, attraverso un modulo solo (`ipa/p1_aot.py`), e anche il controllo rapido `execute_pipeline.py -method hardcoded -verify-only` carica quell'oggetto: lo genera, lo fa passare dal verificatore e lo esegue una volta, senza agganciarlo.

CAPITOLO 2

La matematica che sta dentro il kernel

2.1 Perché i numeri sono interi

Nel kernel non ci sono numeri in virgola mobile: eBPF lavora con interi. Il modello però è addestrato in virgola mobile. Serve una conversione, e si chiama **quantizzazione**.

Ogni peso reale w diventa un intero a 8 bit:

$$w_{\text{int}} = \text{round}(w \cdot s)$$

dove s è il **fattore di scala**, uno solo per tutta la rete.

Perché il risultato stia in un byte con segno serve

$$s \cdot \max_i |w_i| \;\leq\; 127.$$

Sul modello depositato $\max|w| = 5{,}098$, quindi $s \leq 24{,}9$. Due scelte convivono nel progetto: $s = 24$ (il massimo intero ammesso) e $s = 16$ (la potenza di due più vicina per difetto, che rende le divisioni degli shift).

> Superare quel limite non dà un errore: dà un *overflow silenzioso*. I pesi grandi si troncano e il modello sbaglia senza che nulla lo segnali. Per questo i test distinguono le scale *rappresentabili* da quelle che saturano, e misurano solo sulle prime.

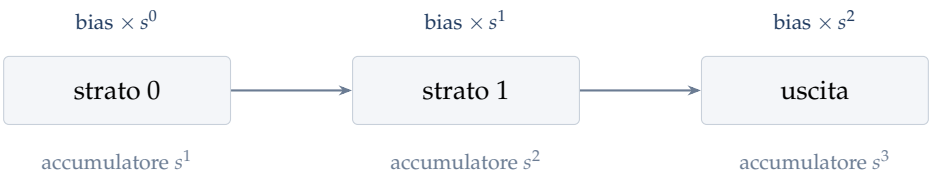
2.2 I bias vanno riportati nelle unità dell'accumulatore

Quando moltiplichiamo un ingresso per un peso quantizzato, il risultato porta un fattore s in più rispetto al valore reale:

$$x \cdot w_{\text{int}} \;=\; x \cdot w \cdot s.$$

Se impiliamo gli strati, quel fattore si accumula. Dopo $\ell + 1$ moltiplicazioni l'accumulatore dello strato ℓ porta $s^{\ell+1}$.

Ma il **bias** è memorizzato come un peso qualsiasi, cioè con un solo fattore s. Sommarlo così com'è significherebbe sommare una quantità sistematicamente troppo piccola. Va riportato nelle unità dell'accumulatore:



La regola è semplice: allo strato ℓ (contando da zero) il bias va moltiplicato per s^ℓ. In P1 il moltiplicatore si calcola alla generazione del codice e il bias entra già scalato come letterale; in P2 e P3 il programma lo calcola a runtime dalla scala del modello.

Perché i test spengono i link

Con **tutti i link attivi** gli accumulatori sono grandi, e anche un bias sottopesato di $s^2 = 576$ volte non sposterebbe mai il massimo. Basta spegnere qualche link perché gli accumulatori si riducano e un errore del genere decida l'esito. Per questo le prove di correttezza variano lo stato dei link, non solo il TTL.

2.3 Il TTL: dividere il prodotto, mai il valore

Il modello è addestrato con il TTL *normalizzato*, cioè ttl/T con $T = 30$ il valore iniziale. Con i numeri interi

$$\frac{\text{ttl}}{30} = 0 \qquad \text{per ogni ttl} < 30,$$

e la feature sparirebbe. La divisione va quindi applicata al *prodotto*:

$$\left\lfloor \frac{\text{ttl} \cdot w_{\text{int}}}{T} \right\rfloor \quad \text{e non} \quad \left\lfloor \frac{\text{ttl}}{T} \right\rfloor \cdot w_{\text{int}}.$$

Nel C generato si legge esattamente così:

```
(((__s64)_ttl * 11LL) / 30LL)
```

La scala T è del **modello**, non del codice: un modello addestrato su ttl/16 va eseguito con 16. Viaggia quindi nel descrittore del modello (il campo `scale` di `struct feat_ent`, un byte); P1 la compila come letterale, P2 e P3 la leggono dalla mappa a ogni pacchetto, e con 0 ricadono sul default compilato.

In P2 e P3 il divisore è quindi una variabile, e **BPF non ha la divisione con segno**: il numeratore invece il segno ce l'ha, perché i pesi possono essere negativi. Il datapath divide il valore assoluto senza segno e rimette il segno, con troncamento verso lo zero — lo stesso arrotondamento del riferimento Python, perché sui negativi le due implementazioni coincidono solo se arrotondano allo stesso modo.

CAPITOLO 3

Le classi non sono porte

3.1 Che cosa significa una classe

La rete produce sette numeri; il più grande vince. Ma *che cosa significa* la classe vincente?

Il significato si può *dedurre* — «la classe 6 è lo scarto», «DROP è l'ultima classe», «la classe k esce dall'interfaccia k» — e sul modello depositato ognuna di queste deduzioni sembrerebbe funzionare, perché lì le porte sono numerate come le classi. Su un altro modello darebbe risposte plausibili e sbagliate, senza alcun errore.

3.2 Una catena esplicita

Il significato è quindi **dichiarato**, mai dedotto, e passa per una catena di quattro passi, ognuno con un responsabile diverso:



- **classe**: quello che il modello ha calcolato;
- **azione**: `FORWARD`, `DROP` o `UNUSED` — una classe mai addestrata esiste ed è dichiarata tale;
- **porta logica**: un numero che il *modello* conosce;
- **ifindex**: l'interfaccia vera, che solo il *nodo* conosce e che è diversa su ogni macchina.

Nel modello depositato la dichiarazione è:

classe	azione	porta logica
0–4	FORWARD	0–4
5	DROP	—
6	UNUSED	—

Classe e porta sono due spazi di indici distinti anche nel datapath: il contatore per classe si scrive con l'indice della classe, la tabella delle uscite si legge con quello della porta. Sul modello depositato coincidono, ma il codice non ci conta.

> Con la semantica dichiarata, un modello diverso da quello depositato **smette di funzionare rumorosamente** invece di continuare a girare dando risposte plausibili e sbagliate.

3.3 Ogni modello ha la sua semantica

In P2 e P3 un solo programma per architettura serve più modelli, caricati come dati. Modelli diversi possono dare alla stessa classe significati diversi, e quindi la chiave della tabella classe → azione è la coppia $(\text{model_id}, \text{classe})$.



- **Una tabella ad accesso diretto, non una tabella hash**: 256 modelli $\times$ 2 banchi $\times$ 32 classi. Una sola lettura per pacchetto, e nessun ciclo sui modelli registrati.
- **Due banchi per modello.** Ricaricare un modello scrive il banco inattivo, poi un'unica scrittura del registro cambia insieme il numero di classi e il banco in uso. Un pacchetto vede la semantica vecchia o quella nuova, mai una tabella scritta a metà.
- **Perché non dentro il registro**, che il programma ha già letto: usare la classe come indice dentro quel valore costringe il verificatore a seguirne il valore esatto attraverso tutto l'argmax, e smette di potare i cammini. Misurato: `layer_hidden` di P3 non si carica.
- **Senza un valore vivo in più.** Il primo strato di P3 sta al limite dei 512 byte di stack nelle sue versioni strumentate: la chiave viaggia allora nella variabile che dice «questo è l'ultimo strato».

La prova. Modelli costruiti in modo che il TTL scelga la classe, così ogni classe di ogni modello è raggiungibile: un modello solo, due con la stessa semantica, due con semantiche opposte su ogni classe a pacchetti alternati, un modello inesistente o rimosso, numeri di classi diversi, un modello ricaricato con un'altra semantica. **53/53** su P2 e P3. Con una tabella condivisa simulata gli stessi test falliscono dove devono: il test distingue le due cose.

Il datapath non se ne accorge: la chiave per modello è una lettura come quella per sola classe, e la latenza non cresce da 1 a 8 modelli registrati. Il prezzo è in memoria: 128 KiB fissi per pipeline, riservati per 256 modelli anche quando ne è caricato uno solo.

CAPITOLO 4

Il motore non è lo scenario

4.1 Le dimensioni vengono dalla configurazione

Il modello depositato è addestrato su **Germany50**, una rete di 50 router usata come riferimento in letteratura, con due host attaccati. Due numeri ne descrivono la forma:

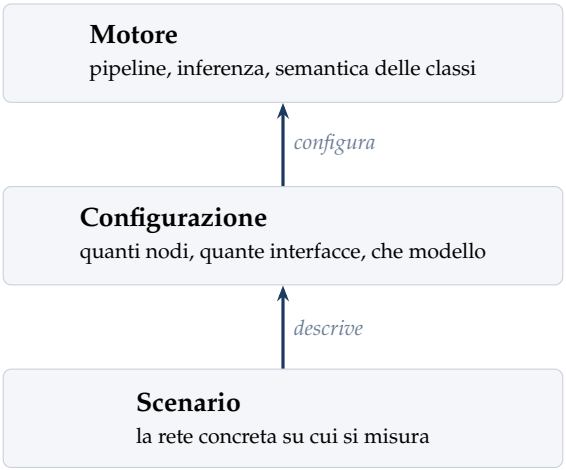
$$n_{\text{nodi}} = 52, \qquad n_{\text{interfacce}} = 6.$$

Il primo è $50 + 2$. Il secondo è il **grado massimo** della rete: il nodo con più vicini. Non è il grado di un nodo qualsiasi — tutti gli altri riempiono di zeri gli slot che non usano.

Questi numeri determinano la larghezza dell'ingresso:

$$n_{\text{in}} = \underbrace{6}_{\text{link}} + \underbrace{6}_{\text{iface}} + \underbrace{1}_{\text{ttl}} + \underbrace{52}_{\text{nodo}} = 65.$$

Il motore non li conosce. Il progetto è diviso in tre strati:



La dipendenza punta **solo verso l'alto**. Il motore non sa che cosa sia Germany50.

Le dimensioni si risolvono in ordine: una variabile d'ambiente, poi un file di sistema, poi il blocco `trained_on` del descrittore del modello. Se nessuna delle tre risponde, il motore **si ferma** e dice dove ha cercato.

> Un default comodo è il modo più efficace di nascondere un'assunzione. Preferire un errore esplicito a un valore plausibile è una scelta di progetto: il valore plausibile non si manifesta mai come errore, solo come risultato sbagliato.

4.2 La prova

Il motore genera un datapath corretto per cinque topologie che non hanno niente a che vedere con Germany50:

iface	nodi	strati	n_{in}	n_{out}	vettore link
3	8	4-4	15	4	`v[3]`
4	16	6	25	5	`v[4]`
5	24	4-4-4	35	6	`v[5]`
2	6	3-3	11	3	`v[2]`
6	52	4-4	65	7	`v[6]`

Nessuna riga di C scritta a mano cambia fra una riga e l'altra. `test_fabric.py -sweep`: **34/34**.

CAPITOLO 5

Il modello non è quello depositato

5.1 La domanda

Un datapath che calcola la cosa giusta su un modello può calcolarla per caso: perché quel modello ha una forma particolare, perché i suoi pesi cadono in un intervallo comodo, o perché una costante scritta nel codice coincide con un suo parametro. Con un modello solo, la differenza fra "corretto" e "corretto qui" non si vede. Servono altri modelli.

5.2 I modelli sintetici

Otto scenari generati, con pesi casuali e nessun rapporto con il checkpoint depositato. Coprono un asse ciascuno:

Scenario	Forma	Pesi	scala del TTL
`ones`	11-2-3	33	8
`small`	15-4-4	84	16
`mixed`	18-6-5	149	30
`ipa_like`	65-4-4-7	319	30
`ipa_ttl16`	65-4-4-7	319	16
`sparse`	65-4-4-7	319	30
`deep`	65-4-4-4-7	339	30
`large`	117-8-8-9	1 097	64

Il generatore non produce solo numeri a caso: rispetta la **struttura** delle feature, che è la parte che un datapath può sbagliare. Ogni feature dichiara il suo tipo — `real` (un valore in un intervallo, che il datapath porta come intero diviso per una scala), `integer`, `binary` (un vettore di 0/1), `onehot` (esattamente un 1) — con i suoi estremi, la sua scala e i suoi vincoli. Ogni scenario porta con sé **1 000 vettori d'ingresso**, nella versione intera e in quella a virgola mobile, e le predizioni attese per entrambe.

Gli artefatti non stanno in git: sono rigenerabili byte per byte a parità di seme, e il test li rigenera da solo se non li trova.

5.3 Il confronto a quattro vie

Compilare e passare il verificatore dimostra che il programma esiste, non *quale classe sceglie*. E due confronti non bastano, perché un disaccordo ha più di una causa possibile e le cause chiedono rimedi diversi. Le vie sono quattro:

Confronto	Che cosa isola
float vs int8 (Python)	l'errore di **quantizzazione**: il modello a interi decide diversamente da quello a virgola mobile. Può legittimamente non essere 100%.
int8 (Python) vs int8 (riferimento)	**controprova**: due implementazioni intere indipendenti del progetto devono concordare fra loro, o non è chiaro quale sia il riferimento.
int8 (riferimento) vs int8 (eBPF)	se il datapath è esatto **rispetto alla configurazione che gli è stata data**.
int8 (Python) vs int8 (eBPF)	l'errore di **implementazione**. Deve valere 100%: un solo disaccordo qui è un difetto del datapath.

C'è anche un quinto confronto che non ha bisogno del kernel: `p1_c_eval.py` legge il C generato per P1 *come testo* e lo valuta con le regole degli interi del C, logit per logit, contro il riferimento Python. I numeri vengono dai letterali del sorgente, mai dalla lista dei pesi: un generatore che emettesse un moltiplicatore sbagliato darebbe un'altra risposta. Fatto girare su codice alterato apposta, se ne accorge.

Perché non i 1 000 vettori depositati

Il datapath non accetta un vettore d'ingresso arbitrario: lo *costruisce* da ciò che ha sotto mano — le mappe dense, il TTL del pacchetto, la porta d'ingresso risolta, l'indice del nodo. Un one-hot `node` diverso a ogni campione vorrebbe dire riconfigurare il nodo a ogni campione.

Si campiona quindi nello spazio che il datapath sa davvero esprimere, e il vettore Python si costruisce allo stesso modo. Confrontare due implementazioni su ingressi che una delle due non potrebbe mai ricevere non direbbe niente su nessuna delle due. Per la stessa ragione il banco comunica al kernel la porta d'ingresso che il riferimento usa: `BPF_PROG_TEST_RUN` senza contesto fa vedere al programma sempre l'interfaccia di prova del kernel.

5.4 Il risultato

Trecento ingressi per scenario, seme fisso.

Scenario	float vs int8	int8 Python vs eBPF (P1)	decisioni
`ones`	100,00 %	**100,00 %**	300/300
`small`	98,00 %	**100,00 %**	300/300
`mixed`	100,00 %	**100,00 %**	300/300
`ipa_like`	97,67 %	**100,00 %**	300/300
`ipa_ttl16`	98,00 %	**100,00 %**	300/300
`sparse`	99,33 %	**100,00 %**	300/300
`deep`	98,67 %	**100,00 %**	300/300
`large`	99,67 %	**100,00 %**	300/300

Equivalenza numerica esatta. P1 la dà su 8 scenari su 8, P2 e P3 su 7 su 7 (`large` non si applica: supera la tabella dei pesi di P2 e le uscite di P3). La colonna di sinistra — fra 97,67 % e 100 % — è la quantizzazione, cioè una proprietà del modello e della scala scelta, non un difetto.

La scala del TTL viene letta davvero. Sugli scenari con scala diversa da 30 la scala dichiarata sposta le decisioni (41 casi su 300 per `ipa_ttl16`, 89 per `small`). Controllo negativo in P2 e P3: riscritta nella mappa del nodo la scala al default, il datapath si stacca dal riferimento *esattamente* su quei casi, e con la scala giusta torna identico.

Un'affermazione di genericità — "il descrittore si legge a runtime, quindi qualunque modello va bene" — va verificata **voce per voce**: la forma, il numero di feature, gli offset e la scala sono quattro affermazioni, e ognuna ha bisogno del suo modello di prova.

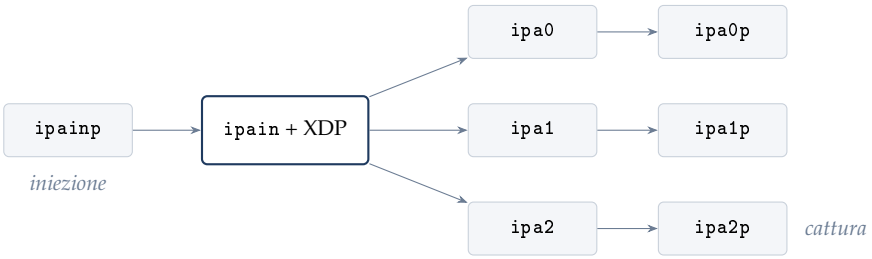
CAPITOLO 6

Dalla chiamata di sistema al kernel vero

6.1 Due banchi

Il primo banco è una chiamata di sistema, `BPF_PROG_TEST_RUN`: si dà al programma un buffer, lo si esegue *N* volte, e il kernel riporta quanti nanosecondi in media. È utile e onesto per confrontare le pipeline fra loro, ma non tocca un'interfaccia, non ha un driver, non consegna niente. Il programma può dire *"redirigerei sulla porta 3"* senza che nessun pacchetto ne esca.

Il secondo banco è fatto di coppie di interfacce virtuali (`veth`) create sull'host: abbastanza vicino al vero da far girare XDP nella modalità in cui gira su un nodo.



Si inietta un frame da un capo, il programma XDP gira davvero, e si legge da quale interfaccia è uscito.

Due dettagli che sembrano minori e non lo sono

Modalità di attacco. XDP si può agganciare in due modi: *native*, dentro il driver, prima che esista la `sk_buff`; oppure *generic*, dopo. Il default è native, la modalità *davvero in effetto* viene riletta dal kernel dopo l'aggancio, e un fallimento è un errore, non una retrocessione silenziosa: una misura fatta in generic senza saperlo non si potrebbe attribuire a niente.

Il vincolo delle veth. Redirigere *verso* una veth funziona solo se il lato ricevente ha a sua volta un programma XDP agganciato: il kernel alloca le code necessarie solo in quel caso. Senza, il redirect fallisce in silenzio e il pacchetto sparisce — indistinguibile da un modello che decide di scartare tutto. Il banco aggancia quindi un programma minimo a ogni capo.

6.2 Come il test evita di essere vuoto

Un test che non può fallire non è un test. Tre scelte del banco servono a questo:

- **Cerca un ingresso per ogni classe**, invece di spazzare alla cieca. Con tutti i link attivi il modello depositato risponde sempre con la stessa classe per qualunque TTL: variare il solo TTL ripeterebbe un caso solo. È `link_state` la feature che sposta la decisione.
- **Filtra la cattura** sui campi che il datapath non riscrive, e disabilita IPv6 sulle interfacce del banco: una veth appena creata manda traffico suo (IPv6 multicast), che altrimenti potrebbe essere contato come la risposta della pipeline.

- **Ha un ingresso dedicato**, separato da tutte le porte: se l'ingresso fosse anche una porta d'uscita, un frame inoltrato su quella porta non si distinguerebbe da quello appena iniettato.

E lo scarto si verifica dal *contatore*, non dal silenzio: "non è arrivato niente" è anche ciò che si osserva quando il redirect si perde.

6.3 Il risultato

Prova	**esito**
consegna su rete di veth, tutte le pipeline, 6 classi su 7	29/29
consegna della P1 come si deploya (oggetto AOT, mappe appuntate)	11/11
cinque topologie diverse	34/34

La settima classe è `UNUSED`: dichiarata, mai addestrata, e non ci sono ingressi che la raggiungano.

CAPITOLO 7

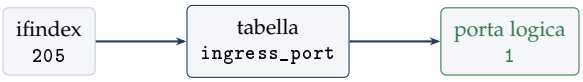
Gli ingressi che dipendono dal nodo

Due dei quattro ingressi del modello non vengono dal pacchetto ma dal nodo: *da quale interfaccia è arrivato* il pacchetto, e *quale nodo* lo sta elaborando. Tutti e due si risolvono con una tabella scritta dal piano di controllo quando il nodo entra in servizio.

7.1 L'interfaccia d'ingresso: una porta logica

L'ingresso è un one-hot di sei posizioni. Il kernel però identifica le interfacce con un `ifindex` assegnato in ordine di creazione: su un sistema appena avviato valgono 2, 3, 4; su una macchina che ha creato qualche interfaccia virtuale 205, 217, 229. Usarlo come posizione nel vettore non accenderebbe mai un bit.

Il datapath lo traduce allora in **porta logica** con una tabella a runtime, riempita dal piano di controllo leggendo le interfacce del nodo:



È il **simmetrico** della tabella usata in uscita: là "quale interfaccia realizza la porta che il modello ha scelto", qui "quale porta è l'interfaccia da cui il pacchetto è arrivato". Entrambe sono fatti del nodo, entrambe si risolvono quando il nodo esiste. Un'interfaccia che non è una porta del modello non ha voce, e il one-hot resta spento.

7.2 L'identità del nodo

L'ingresso più grande del modello è *quale nodo sta elaborando il pacchetto*: su Germany50 un one-hot di 52 posizioni, **208 dei 319 pesi**.

Non si può prendere dal pacchetto. Il campo `model_id` dell'intestazione dice *quale modello* il pacchetto chiede di usare, e viaggia identico dal mittente alla destinazione: usato come indice del nodo, ogni nodo della rete accenderebbe la stessa posizione.

L'indice sta quindi in una tabella `node_id`, scritta quando il nodo entra in servizio: dalla variabile d'ambiente `IPA_NODE_ID`, o dalla tabella nome $\rightarrow$ indice della topologia. L'indice deve seguire l'ordine dei nodi usato in addestramento, perché le decisioni significhino qualcosa sulla rete vera.

La tabella è di tipo *hash* e non *array*, e non è un dettaglio. Un array in questo ambiente è preallocato e riempito di zeri, quindi una lettura riesce **sempre**: "non configurato" e "sono il nodo 0" tornerebbero lo stesso valore. Con un hash, finché nessuno scrive non c'è voce: il vettore resta spento, ed è la risposta onesta.

7.3 La prova che contano

Stesso programma compilato, due esecuzioni che differiscono solo per la tabella del nodo:

esecuzione	**esito sul pacchetto**
senza indice di nodo	scartato
indice di nodo $= 7$	non scartato

Nient'altro cambia fra le due: l'ingresso sposta la decisione. Per l'interfaccia d'ingresso lo stesso lo mostra la consegna su veth, dove gli ingressi che raggiungono ciascuna classe dipendono dalla porta da cui il pacchetto entra.

Il prezzo sono due letture di tabella per pacchetto: P1 ne fa 6 in tutto, P3 29. In P1 la tabella dell'interfaccia costa meno istruzioni dello `switch` a sei casi che sostituisce: una lettura costa meno di una catena di salti.

CAPITOLO 8

Il verificatore paga i cammini

8.1 Che cosa fa il verificatore

Prima di accettare un programma eBPF, il kernel lo fa controllare dal **verificatore**. Il verificatore non esegue il programma su un pacchetto vero: lo percorre *su tutte le strade possibili*, per essere sicuro che nessuna faccia qualcosa di proibito. Ogni `if` è un bivio, e il verificatore prende tutti e due i rami. Ha però un budget: **un milione di passi**. Finito il budget rifiuta il programma, per quanto corto sia:

```
BPF program is too large. Processed 1000001 insn
```

Dimensione del programma e costo di verifica sono quindi **monete diverse**. Due scelte del codice servono a spendere poco della seconda.

8.2 Il primo strato: feature fuori, neuroni dentro

Il primo strato si calcola sommando, per ogni neurone, i contributi di ogni feature dichiarata nel descrittore. L'ordine ovvio — neuroni fuori, feature dentro — chiederebbe *di che tipo* e *di che larghezza* è ogni feature una volta per neurone, cioè $8 \times 4 = 32$ volte per pacchetto, e ogni domanda è un bivio. Ma tipo e larghezza non dipendono dal neurone. Il codice di P2 e P3 gira quindi i cicli al contrario:

```
per ogni feature f (4 volte)
    di che tipo e' f?            <- 4 volte, non 32
    di che larghezza e' f?       <- 8 volte, non 64
    per ogni neurone j (8 volte)
        accumula                 <- nessun ramo qui dentro
```

Il risultato non cambia di un bit: cambia solo l'**ordine** in cui i termini si sommano, e la somma fra interi a 64 bit in complemento a due è associativa e commutativa, anche quando trabocca. È questo margine che permette a P3 di compilare il tetto sulle code a 8 e alle versioni strumentate di P2 e P3 (quelle che contano le letture di tabella) di caricarsi.

8.3 La ReLU: un bivio per neurone

Il verificatore paga ogni `if` due volte. Una ReLU scritta con un `if` ne mette uno in ogni neurone nascosto, e con quella scrittura due cose non si caricherebbero:

- **P2 con tre o più strati nascosti**;
- **P1 oltre qualche centinaio di pesi**, e prima la forma larga.

Non per la lunghezza: il programma P2 a tre strati ha circa 16 000 istruzioni, ma il verificatore ne percorrerebbe un milione, rileggendo gli stessi pezzi di codice molte volte, una per ogni strada.

Dove stanno i bivi

Ogni neurone nascosto applica la ReLU: *se il valore è positivo tienilo, altrimenti metti zero*. Scritta nel modo più diretto:

```
h = a > 0 ? a : 0;        // un if: due strade
```

Un bivio per neurone. Con tre neuroni in fila le strade sono

$$2 \times 2 \times 2 = 8,$$

una per ogni combinazione di "positivo / negativo":

neurone 1	neurone 2	neurone 3	
$+$	$+$	$+$	strada 1
$+$	$+$	$-$	strada 2
$+$	$-$	$+$	strada 3
	$\dots$		$\dots$
$-$	$-$	$-$	strada 8

Con i 16 neuroni del modello largo di P1 sono $2^{16} = 65\,536$ strade. Il verificatore ha un meccanismo per riconoscere due strade "equivalenti" e percorrerne una sola (la *potatura*), ma qui riesce a riunirne poche: i numeri qui sotto dicono che la gran parte delle strade viene percorsa per intero.

Il verificatore scrive quanti passi ha fatto, se glielo si chiede (`diag_verifier.py`, statistiche con `log_level = 4`, che prova ogni forma con le due scritture della ReLU). Con il bivio il P1 largo, 3 486 istruzioni, arriva al milione: **287 volte** la sua lunghezza. P2 a *uno* strato è già a 799 563 passi, l'80% del budget: un margine così piccolo che una differenza qualsiasi fra due kernel basta a superarlo.

La ReLU senza bivio

La ReLU si può calcolare con sola aritmetica, senza `if`:

```
m = a >> 63;              // tutti 1 se a e' negativo, tutti 0 altrimenti
h = a & ~m;               // a se positivo, 0 se negativo
```

Lo spostamento a destra di 63 posizioni di un intero con segno a 64 bit "ricopia" il bit del segno su tutti i bit. Due esempi, mostrati su 8 bit per leggibilità (a 64 bit è identico):

	$a = 5$	$a = -3$
a in bit	00000101	11111101
$m = a \gg 63$	00000000	11111111
$\sim m$	11111111	00000000
$a \& \sim m$	$00000101 = 5$	$00000000 = 0$

Con a positivo la maschera lascia passare tutto e resta a; con a negativo la maschera azzera tutto. È la ReLU, **bit per bit la stessa**, ma senza bivio: il verificatore ha una strada sola da percorrere.

Il dettaglio che la fa funzionare

Scritta così e basta, non cambia niente: clang riconosce che `a & ~(a >> 63)` è "il massimo fra a e 0" e, per ottimizzare, **rimette il bivio**. Nel bytecode compilato i salti tornano tutti (136 contro 120 nel P1 largo). Serve una riga che impedisca a clang di vedere dentro la maschera:

```
static __always_inline long long ipa_relu(long long a) {
    long long m = a >> 63;
    asm volatile("" : "+r"(m));   // barriera: nessuna istruzione, m invariato
    return a & ~m;
}
```

L'`asm` è vuoto: non produce nessuna istruzione e non cambia m. Dice solo a clang "di m non sai niente", e clang non può più riconoscere il massimo. La funzione è la stessa in P1 (`gen_full_c.py`), in P2 (il leaf di `ebpf_template_arch.py`) e in P3 (`ebpf_modular.py`). P3 si caricherebbe anche con il bivio, perché ripete un solo strato generico: usa la stessa funzione perché le tre pipeline calcolino l'attivazione con le stesse istruzioni, e il confronto fra loro resti alla pari.

8.4 La ReLU senza bivio: il risultato

Passi del verificatore, su un budget di 1 000 000:

	ReLU con bivio	**ReLU senza bivio**
P2, 1 strato	799 563	120 452
P2, 2 strati	417 292	120 557
P2, 3 strati	*rifiutata*	127 906
P2, 6 strati	*rifiutata*	136 642
P2, 20 strati	*rifiutata*	201 528
P1 larga, 1×16 (∼1 200 pesi)	*rifiutata*	5 698
P1 profonda, 8×9 (∼1 300 pesi)	229 039	8 516
P3, `layer_first`	27 183	26 755
P3, `layer_hidden`	186 489	27 979

Senza bivio P2 carica fino a venti strati, e a sei ne usa il 14% del budget. P1 carica il tier da ∼1 200 pesi in tutte le forme. Lo strato che P3 ripete (`layer_hidden`) costa al verificatore 17 volte la sua lunghezza invece di 117. `layer_first` quasi non cambia, perché la sua ReLU è una parte piccola di un programma dominato dalla lettura degli ingressi.

Il limite di P2 non è il verificatore

Oltre venti strati è **clang** a fermarsi, prima ancora del kernel:

```
LLVM ERROR: Branch target out of insn range
```

Un salto eBPF può arrivare al massimo a 32 767 istruzioni di distanza. I controlli all'inizio del programma (*se il pacchetto non va bene, esci*) saltano fino in fondo, e ogni strato allunga il programma di circa mille istruzioni: a venti strati il programma ne ha 32 388, appena sotto. Il terzo limite è la tabella dei pesi, 1 024 posti: 37 strati al massimo a larghezza 4, 7 a larghezza 8.

8.5 La ReLU senza bivio: che cosa costa

Il calcolo della rete è identico: i test che confrontano il C di P1 con il riferimento Python danno gli stessi logit su ogni modello sintetico (`test_synth.py`), e `p1_c_eval.py` valuta anche `ipa_relu` leggendone il corpo. Cambiano invece le istruzioni: circa tre per neurone, sempre eseguite, al posto di un salto. Nel banco a pacchetto ripetuto un salto sarebbe quasi gratis, perché lo stesso pacchetto passa milioni di volte e il processore indovina sempre da

che parte va: lì le tre istruzioni in più si vedono, soprattutto in P1, il programma più corto. In P2 e P3 la ReLU è una parte minima di un programma molto più grande. In cambio P1 carica modelli fino a quattro volte più grandi, P2 fino a venti strati, e le tre pipeline calcolano l'attivazione con le stesse istruzioni.

Il verificatore non paga le istruzioni ma le **strade**: togliere un bivio vale più che togliere cento istruzioni. E un programma che lavora all'80% del budget di verifica si carica su un kernel e non su un altro: il margine va misurato, non presunto.

CAPITOLO 9

I numeri, e che cosa dicono davvero

9.1 La tabella

Modello 65-4-4-7, scala 24, `test_suite --only kernel`. P1.5 è l'oggetto AOT che va sui nodi, quello che i capitoli precedenti chiamano semplicemente P1; P1 è la specializzata, presentata nel capitolo seguente, con anche l'indice del nodo (7) compilato dentro. Misurato sulla macchina di laboratorio, il core del programma fisso a 3 490 MHz misurati e isolato dal resto (capitolo 13).

	baseline	P1	P1.5	P2	P3
istruzioni caricate	135	606	1 019	15 089	12 288
salti fra programmi	0	1	1	1	3
letture di tabella	3	5	6	11	29
memoria delle tabelle	1 960 B	4 196 B	4 196 B	147 624 B	177 452 B
latenza (minimo di 7)	14 ns	46 ns	52 ns	194 ns	318 ns

Il *baseline* è un programma che analizza il pacchetto e lo rimanda fuori senza alcuna inferenza: è il pavimento contro cui si legge tutto il resto.

P1 costa 6 ns meno di P1.5: senza l'indice del nodo da leggere sparisce lo switch sui 52 nodi (413 istruzioni) e una lettura di tabella. La memoria delle tabelle comprende le copie per core dei contatori (22 CPU), per questo la baseline occupa 1 960 byte: i contatori per core evitano gli incrementi atomici.

Tutte le colonne vengono dalla **stessa esecuzione**, sulla stessa macchina, nello stesso minuto.

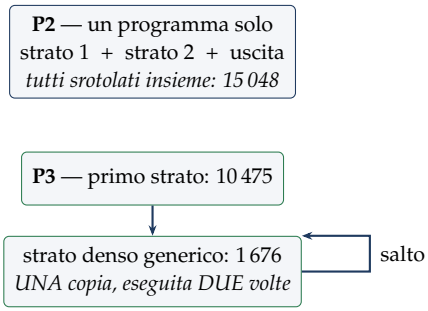
9.2 Primo risultato: la dimensione non predice la velocità

P3 ha il 19% di istruzioni in meno di P2 ed è il 64% più lento.
Il motivo sta nelle due righe centrali: tre salti fra programmi invece di uno, e ventinove letture di tabella per pacchetto invece di undici.

Il conteggio delle istruzioni misura quanto è *grande* il programma caricato, non quanto *lavoro* fa per pacchetto. In questo regime a dominare sono le letture di memoria e i salti, non l'aritmetica.

Perché P2 è più grande, pur essendo più veloce

Le due cose hanno la stessa causa: **P3 non tiene la rete intera in un programma**.



P3 srotola **un** solo strato denso generico e ci rientra, con un salto fra programmi, a ogni passo della rete. Così la *profondità* del modello non costa dimensione: un modello a sei strati gira sullo stesso identico binario. P2 deve srotolarli tutti, perché è un programma solo.

Quel riuso è esattamente ciò che P3 paga in latenza: ogni rientro è un salto più le letture che servono a ricostruire il contesto perduto. Il salto in sé costa quasi niente — misurato da solo, **un nanosecondo** — quindi quello che pesa sono le letture.

> La stessa scelta di progetto spiega *entrambi* i numeri: P3 è più piccolo **perché** riusa un pezzo, ed è più lento **perché** riusarlo costa delle letture ogni volta.

9.3 Secondo risultato: quanto valgono le latenze assolute

Ogni cifra di latenza in tabella è il **minimo di sette misure** indipendenti. Guardando come sono distribuite quelle sette, dentro la singola esecuzione:

	baseline	P1	P1.5	P2	P3
minimo	14 ns	46 ns	52 ns	194 ns	318 ns
mediana	15 ns	47 ns	52 ns	195 ns	324 ns
massimo	15 ns	47 ns	52 ns	196 ns	327 ns
dispersione	7%	2%	0%	1%	3%

La dispersione sta fra lo 0 e il 7%: su 14 ns un nanosecondo è il 7%. È il risultato del condizionamento della macchina (capitolo 13): frequenza fissa e misurata, stati di sonno profondi spenti, il core del programma lasciato solo.

> Le cifre assolute valgono **a quella frequenza**: il core del banco è fisso a 3,5 GHz, su un P-core. A un'altra frequenza cambiano quasi in proporzione; i **rapporti** fra le pipeline no. Su un core di tipo diverso cambiano anche i rapporti (capitolo 12).

Un caso in cui la regola è servita

Sull'asse dei nodi dell'analisi parametrica (capitolo seguente), P1.5 passa da 731 a 1 673 istruzioni fra 10 e 100 nodi, e la latenza resta a 45–47 ns in tutti e cinque i punti. E il tetto sulle code di P3, portato da 1 a 8, aggiunge 3 525 istruzioni al primo strato (da 7 003 a 10 528) senza cambiare niente di ciò che gira: il modello depositato non dichiara la feature delle code, quindi quel ramo non viene mai eseguito.

Una metrica che si sposta del 50% senza che cambi nulla di ciò che gira **non è una misura di costo**. Il numero di istruzioni va letto come "quanto è grande il binario", mai come "quanto lavora".

9.4 Terzo risultato: la genericità ha un costo di verifica

P2 serve qualsiasi modello che stia sotto certi tetti dichiarati a priori (numero massimo di neuroni, di ingressi, di feature). È il suo pregio: non ricompila mai.

Il conto però lo paga il verificatore del kernel, che percorre ogni cammino del corpo srotolato. Con i tetti larghi il kernel si arrende:

```
processed 1000001 insns (limit 1000000) ... total_states 13864
```

Da notare: il programma è lungo circa 14 900 istruzioni, **ampiamente dentro** il limite di dimensione. Quello che finisce è la *complessità di verifica*, che è un limite diverso e cresce col **prodotto** dei tetti:

$$\text{costo di verifica} \;\sim\; H_{\max} \times F_{\max} \times N_{\max}.$$

È lo stesso limite che una ReLU con il bivio farebbe toccare a P2 già a tre strati nascosti, e a P1 oltre qualche centinaio di pesi (capitolo 8).

È la misura concreta di quanto un programma "generico" possa esserlo. La genericità di P2 non è gratis: si paga in stati del verificatore, e il tetto si tocca con numeri ragionevoli.

9.5 Quarto risultato: togliere il compilatore dal nodo

P1 scrive i pesi *dentro* il codice come numeri letterali. È ciò che la rende veloce — il compilatore può far sparire le moltiplicazioni per zero e trasformare in scorrimenti quelle per potenze di due — ma ogni volta che il modello cambia bisogna ricompilare.

Per questo la P1 si compila *prima*, su una macchina qualunque, e al nodo si spedisce l'oggetto già pronto. Al momento del deploy il nodo apre il file e lo carica, senza compilatore:

oggetto precompilato (AOT)	
compilazione, una volta, fuori dal nodo	78 ms
messa in servizio sul nodo (apri, verifica, JIT)	**1,06 ms**
istruzioni	1 019
latenza per pacchetto	52 ns

Il nodo non ha bisogno di un compilatore, e il costo per pacchetto è lo stesso di tutte le altre misure: **ogni cifra di P1 in questo quaderno è dell'oggetto AOT**. La riduzione fatta dal compilatore sui pesi letterali resta dentro l'oggetto.

Vale solo quando i modelli sono noti in anticipo, che è l'ipotesi sotto cui P1 esiste.

9.6 Che cosa questi numeri non dicono

`BPF_PROG_TEST_RUN` esegue il programma in un ciclo sullo stesso buffer. Niente scheda di rete, niente driver, nessuna allocazione, nessuna pressione di cache da traffico vero.

Il valore in "milioni di pacchetti al secondo" è semplicemente 1/latenza: un **picco teorico**, non un throughput retto. Per quello serve traffico vero, generato a ritmo, e la misura di quanti pacchetti si perdono (capitolo 12).

CAPITOLO 10

Come cresce il costo

10.1 La domanda

Fin qui tutto è misurato su *un* modello e *una* topologia. La domanda che manca è come cambia il costo quando la rete o il modello diventano più grandi — e soprattutto se le pipeline hanno **pendenze diverse**.

Se le pendenze fossero uguali, averne più di una sarebbe un esercizio. Non lo sono, ed è questo il capitolo che lo mostra.

Le pipeline confrontate sono **quattro**, e formano una scala di *quanto si sa quando il programma viene compilato*:

	compilato dentro	**un binario per**
P1 specializzata	pesi *e* indice di questo nodo	**nodo**
P1.5 hardcoded	pesi; il nodo si legge a runtime	modello
P2 template	solo i soffitti	tutto
P3 modular	anche la profondità è a runtime	tutto

La P1.5 è quella che i capitoli precedenti chiamano semplicemente P1: la *disposizione* delle feature è scritta nel codice, ma l'indice del nodo no. La P1 specializzata congela anche quello.

10.2 Come è impostata la misura

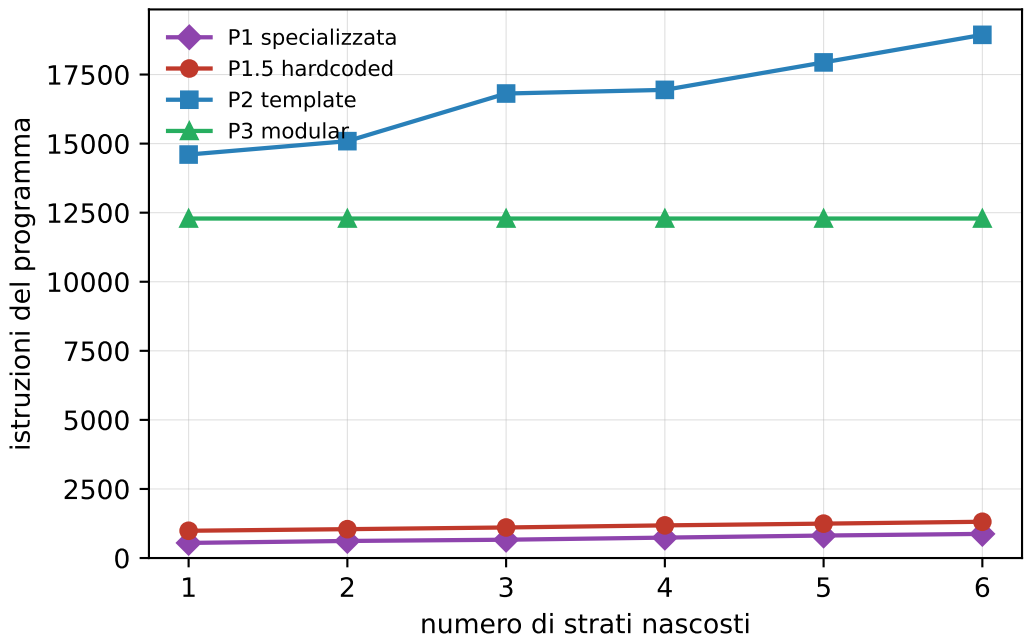
Sette assi, e su ciascuno si muove **una sola** variabile: tutto il resto resta fermo, così una curva si può attribuire a quello che c'è scritto sull'asse delle ascisse e a nient'altro.

asse	**valori**	**si ferma perché**
nodi della rete	10, 25, 52, 75, 100	il tetto sugli ingressi è 128
hidden layer	da 1 a 6	—
a parametri fermi	da 1 a 5 strati, 592 pesi	—
neuroni per layer	2, 4, 6, 8	il tetto compilato è 8
composizione dell'IV	4 varianti	0, 1 o 2 one-hot
pesi a zero	0% ... 90%	—
porte presenti	da 2 a 6	—

Tre accortezze che cambiano i risultati, non solo la forma:

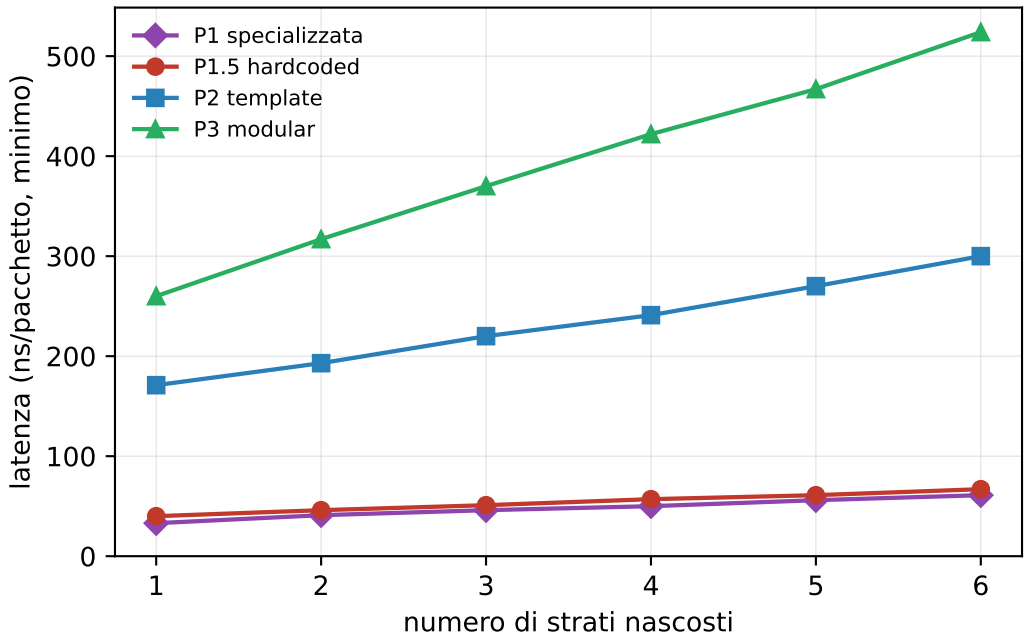
- **Ogni misura in un processo separato.** P1 può far abortire il compilatore in modo non recuperabile; e un rifiuto del verificatore è un *dato*, non un guasto dello strumento.
- **I pesi vengono da un sacchetto fisso**, e un modello più grande *estende* quello più piccolo invece di sostituirne tutti i pesi: in P1 il numero di istruzioni dipende dai valori dei pesi, e cambiarli tutti a ogni punto mescolerebbe il loro effetto con quello dell'asse.
- **Un allarme automatico sulle misure sporche**: se una pipeline ha lo stesso identico programma e la latenza varia più del doppio lungo l'asse, lo scarto è la macchina e lo strumento lo dice.

10.3 Profondità: chi paga in spazio e chi in tempo



P3 ha la stessa dimensione da uno a sei strati: 12 288 istruzioni in ogni punto. **P2 cresce** di circa 870 istruzioni per strato, da 14 604 a 18 937.

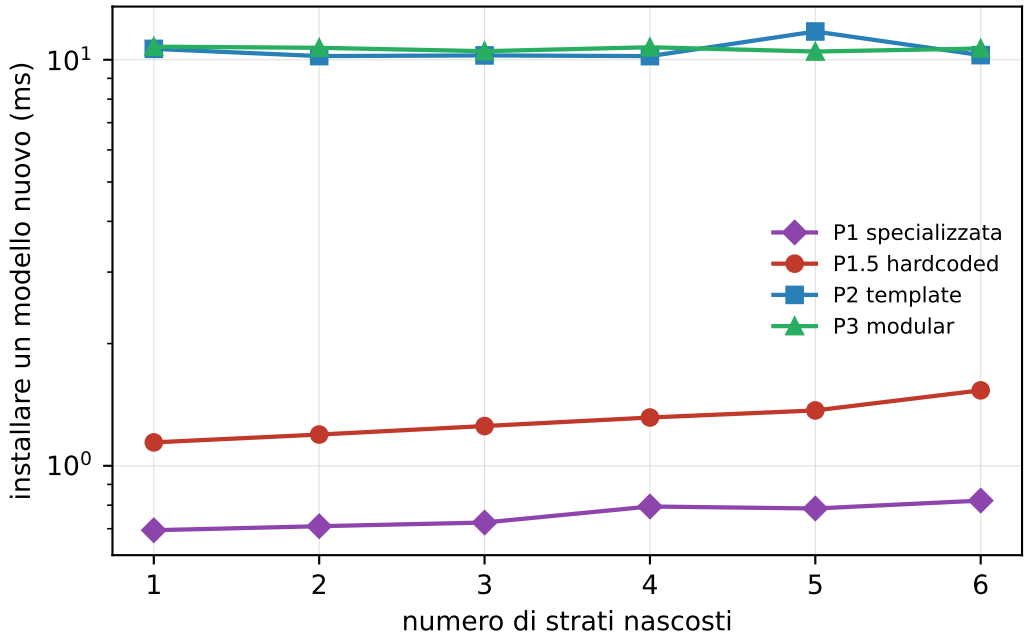
P3 srotola *un* solo strato denso generico e ci rientra a ogni passo della rete, quindi la profondità non entra nel programma. P2 deve srotolarli tutti, perché è un programma solo; ci riesce fino a venti strati grazie alla ReLU senza bivio (capitolo 8).



E P3 lo paga in tempo: circa 53 nanosecondi per strato (260 → 524 ns da uno a sei strati), a istruzioni identiche. **P2 ne paga circa 26** (171 → 300 ns): lo strato in più è codice in linea, niente salti e niente letture per ricostruire il contesto. Le due P1 crescono di circa 6 ns per strato (33 → 61 la specializzata, 40 → 67 la P1.5). Sul traffico vero lo stesso andamento: P3 circa 60 ns per strato (capitolo 12).

Le due figure hanno la *stessa* causa vista dai due lati. P3 è più piccolo **perché** riusa un pezzo, ed è più lento **perché** riusarlo costa un salto e delle letture ogni volta. È il compromesso della modularità, ridotto a due numeri. La differenza vera sulla profondità resta un'altra: P3 cambia profondità senza ricompilare, P2 deve ricompilare il programma.

10.4 Aggiornare il modello: millisecondi per tutte



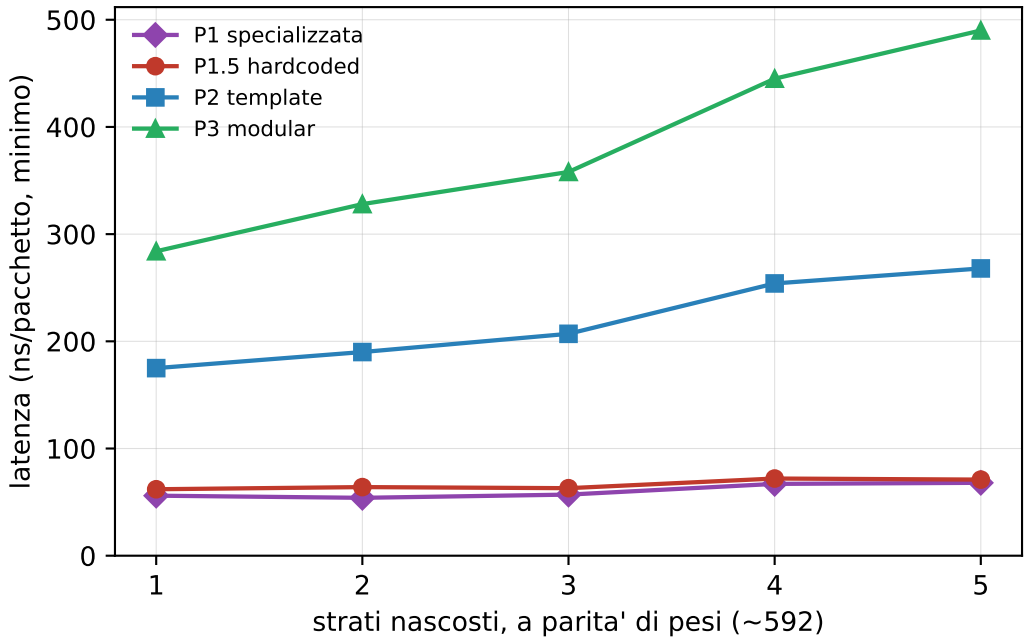
Con P1 costruita come oggetto precompilato, installare un modello nuovo su un nodo già in servizio costa **0,4–2,2 millisecondi** in P1 — il nodo apre e carica un file pronto — e **10–12 millisecondi** in P2 e P3, che scrivono in una tabella (pesi e semantica delle classi).
Contando anche il lavoro di P1 fuori dal nodo — generare il C, compilarlo con clang — si sta fra 57 e 121 ms. P2 e P3 compilano con BCC una volta sola, all'avvio del nodo (1,2–1,8 s), e mai più.

La differenza che resta fra le pipeline non è quindi il tempo di aggiornamento, ma *dove* serve il compilatore: P1 ne vuole uno per ogni modello nuovo, su qualche macchina; P2 e P3 no.

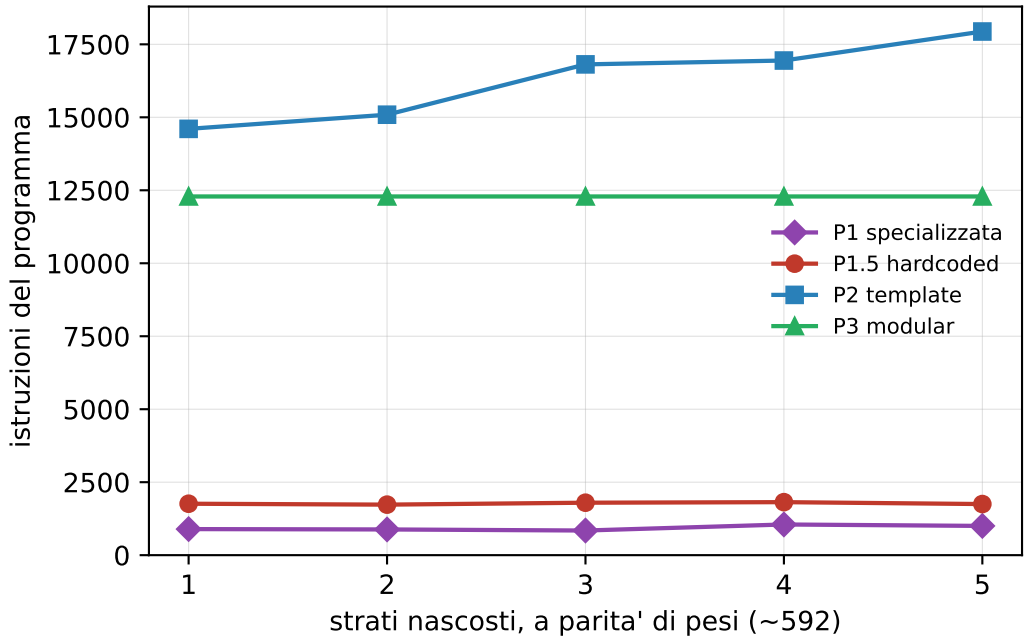
10.5 Larga o profonda? Dipende da chi la esegue

Dato un numero di parametri da spendere, conviene metterli in *un* layer largo o in *molti* stretti? È una domanda che si fa di solito parlando del modello, come se la risposta fosse una proprietà della rete neurale. Qui non lo è.

Cinque forme, tutte con lo stesso budget — 592 pesi, con uno scarto del 2% — disposto in modo diverso: da un solo strato da otto neuroni a cinque strati stretti.



A parità di parametri le due versioni hardcoded cambiano poco e non in modo monotono (54–68 ns la specializzata, 62–72 la P1.5). P2 perde il **53%** da uno a cinque strati (175 → 268 ns), P3 il **73%** (284 → 490 ns). Sul traffico vero P2 +35% e P3 +60%, con il costo fisso del nodo in più.
La stessa scelta di architettura costa poco o costa molto, a seconda della pipeline su cui finisce.



P3 ha la riga **perfettamente orizzontale** — 12 288 istruzioni a tutti e cinque i punti — e perde comunque il 73% di velocità.

> **Dimensione costante e tempo crescente** è la firma di un costo di transizione, non di calcolo. In P3 si vede allo stato puro: ciò che cresce non è il lavoro, è il numero di volte che il programma deve rientrare in sé stesso.

Con budget diversi, e ingressi diversi

Il banco dedicato (`bench_depth_vs_width`) prova tre budget e quattro vettori d'ingresso, sulla sola P1:

	larga	**2 strati**	**4 strati**		**8 strati**
~300 pesi					
ingresso con due one-hot (65 valori)	39 ns	44	48	62	(+59%)
ingresso denso (11 valori)	93 ns	90	85	83	(−11%)
~1 200 pesi					
ingresso con due one-hot (65 valori)	105 ns	145	165	211	(+101%)
ingresso denso (11 valori)	*stack*	*stack*	330	295	(−11%)

P1 come oggetto AOT. *stack*: clang non compila, la forma chiede più dei 512 byte di stack di eBPF.

Con un ingresso **grande e dominato da una one-hot** — il caso di IPA, 52 dei 65 valori — allargare batte approfondire, e a 1 200 pesi la rete a otto strati costa il doppio di quella larga. Con un ingresso **piccolo e denso** vince la rete profonda: più veloce dell'11% a 300 pesi e anche più piccola (1 323 contro 1 490 istruzioni). Il motivo: una one-hot larga costa poco per pacchetto, perché il datapath ne legge *una colonna sola*; un ingresso denso invece fa moltiplicare le letture per la larghezza del primo strato.

Il limite di P1 è lo stack

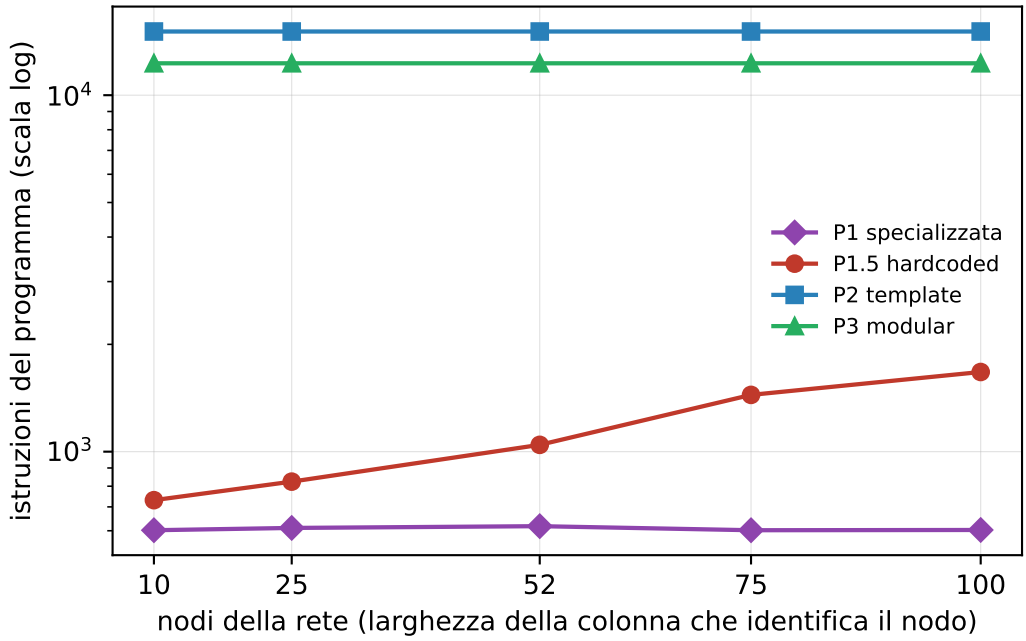
Con la ReLU senza bivio (capitolo 8) il verificatore accetta tutto il tier da ∼1 200 pesi sull'ingresso di IPA. Il limite che resta non è del verificatore: lo **stack** di eBPF, 512 byte. Con l'ingresso denso a 1 200 pesi la forma larga (un solo strato da 63 neuroni) e quella a due strati da 26 chiedono più spazio per i valori intermedi di quanto il programma ne abbia, e clang si ferma prima di produrre l'oggetto. A ∼4 700 pesi succede a tutte le forme.

> La frase giusta non è "le reti larghe sono preferibili a quelle profonde". È: *con un ingresso dominato da feature one-hot, allargare batte approfondire; con un ingresso piccolo e denso vince la rete profonda; e oltre qualche centinaio di pesi, in P1, è la forma larga a esaurire per prima lo stack.*

10.6 Congelare il nodo: conviene?

L'indice del nodo è una **costante del deployment**: un nodo non cambia di posto. Il codice però lo legge a runtime, e per farlo porta uno switch con un caso per ogni nodo della rete — 52 casi per Germany50, di cui ne esegue *uno*.

Congelandolo a tempo di generazione lo switch sparisce, e con lui la lettura della tabella. Restano quattro numeri costanti, che il compilatore può piegare dentro al conto.



> La taglia della rete entra nel programma **solo** nella P1.5, che passa da 731 a 1 673 istruzioni fra 10 e 100 nodi.
> Congelando il nodo quella dipendenza **sparisce**: la riga della specializzata è piatta, fra 602 e 618 a qualunque taglia.

(La scala è logaritmica: in lineare le due righe P1 resterebbero schiacciate contro le quindicimila di P2.)

E la velocità

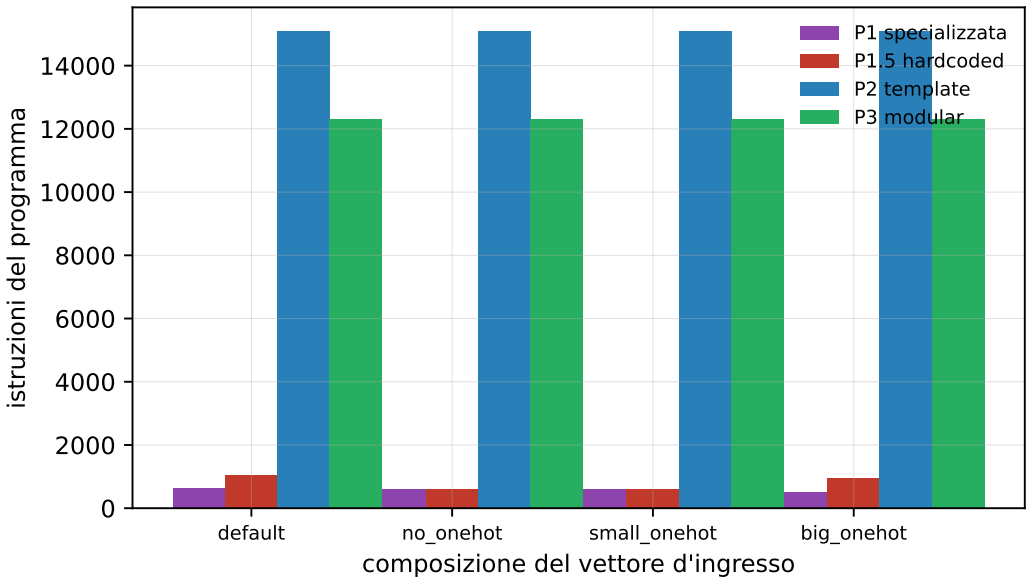
nodi	10	25	52	75	100
P1 specializzata	40	40	41	42	39 ns
P1.5 hardcoded	46	45	46	47	46 ns

La specializzata è più veloce di 4–7 ns, l'11–15%, a ogni taglia: la lettura della tabella del nodo e lo switch costano poco, ma si vedono. Entrambe sono piatte: a runtime lo switch è un salto indicizzato, qualunque sia il numero dei casi.

> Il motivo per cui la *dimensione* crolla e il *tempo* cala poco è lo stesso: lo switch ha 52 casi ma ne esegue uno. Quelle 208 assegnazioni sono compilate per eseguirne quattro. Toglierle libera molto **spazio** e un po' di **tempo**.

Il controllo, e perché ci si può fidare

Come si fa a essere sicuri che il divario venga davvero dalla one-hot del nodo e non da qualcos'altro? Si prende un vettore d'ingresso che la feature *non* la contiene:



Nelle due composizioni senza la feature `node` le due P1 sono **identiche alla cifra** (611 e 611; 604 e 604). In quelle che ce l'hanno, divergono. Il divario è tutto lì e nient'altro.

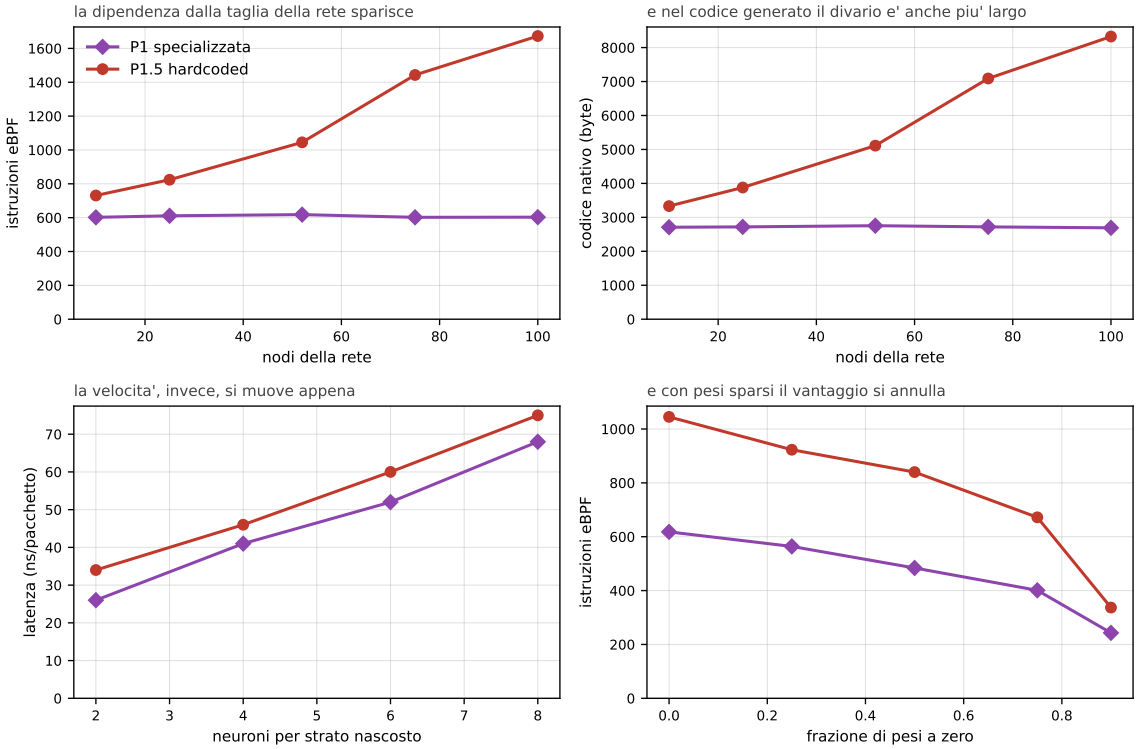
C'è poi una verifica che viene prima di ogni numero. Congelare il nodo significa scegliere *una colonna* della matrice dei pesi al momento di generare il codice: sceglierne una sbagliata darebbe un programma più piccolo, più veloce, e che calcola **un altro modello**. Ottanta casi, dieci valori di TTL per otto configurazioni di link: la versione congelata decide sempre la stessa classe di quella che legge il nodo dalla tabella.

I due vantaggi non si sommano

pesi a zero	0%	25%	50%	75%	90%
P1 specializzata	618	564	484	401	**243**
P1.5 hardcoded	1 045	923	840	672	**337**

Al 90% di zeri il divario scende da 427 a 94 istruzioni. Sparsità e nodo congelato sono **due strade alla stessa riduzione**: se i pesi sono già quasi tutti zero, il compilatore cancella lo switch da solo e non resta niente da congelare.

Le quattro risposte in una figura



Qui ci sono solo le due P1: in tutte le altre figure P2 e P3 stanno un ordine di grandezza più su e schiacciano questo confronto sul fondo del grafico. La dimensione crolla e smette di dipendere dalla rete; il codice nativo crolla ancora di più (2 692 byte contro 8 325 a cento nodi); la velocità migliora di poco; e con i pesi sparsi le due curve si toccano.

Il verdetto

Congelare il nodo **non è soprattutto un'ottimizzazione di velocità**. È ciò che rende la pipeline hardcoded *praticabile su una rete grande*.
Lo switch della P1.5 cresce col numero di nodi moltiplicato per la larghezza del primo strato. Su una topologia da 500 nodi con 8 neuroni sarebbero quattromila assegnazioni srotolate, e c'è una taglia oltre la quale quel programma non si carica più. La specializzata non ci arriva mai.
Il prezzo è **un binario per nodo**: 52 compilazioni (circa 70 ms ciascuna) e 52 installazioni.

10.7 Congelare quali porte esistono

La sezione precedente congela *dove* il nodo si trova. Questa congela *quante interfacce ha*.

Il modello riserva sei colonne per `link_state` perché sei è il grado del nodo più connesso della rete. Ma su un nodo di grado 3 le tre colonne restanti non sono link caduti: dietro non c'è alcuna interfaccia. Valgono zero, sempre.

> Non si congela il **valore** della feature, si congela la sua **struttura**. Se un link sia su o giù resta letto a runtime; quello che diventa noto alla compilazione è *quali posizioni possono esistere*.

Il generatore non emette le colonne che restano fuori. Il termine che sparisce è $\texttt{link_state}[i] \cdot w[j][i]$ con $\texttt{link_state}[i]$ nullo: la somma è fra interi a 64 bit, quindi togliere un addendo nullo non cambia un bit.

porte presenti	2	3	4	5	6
istruzioni eBPF	**534**	554	570	594	618
latenza	37	38	39	39	40 ns

Circa 21 istruzioni per porta, in modo lineare, e **3 ns** fra grado 6 e grado 2, con la latenza che sale in modo monotono. Diversamente dal nodo, qui le moltiplicazioni tolte vengono eseguite davvero a ogni pacchetto, e la misura le vede: circa un nanosecondo per porta.

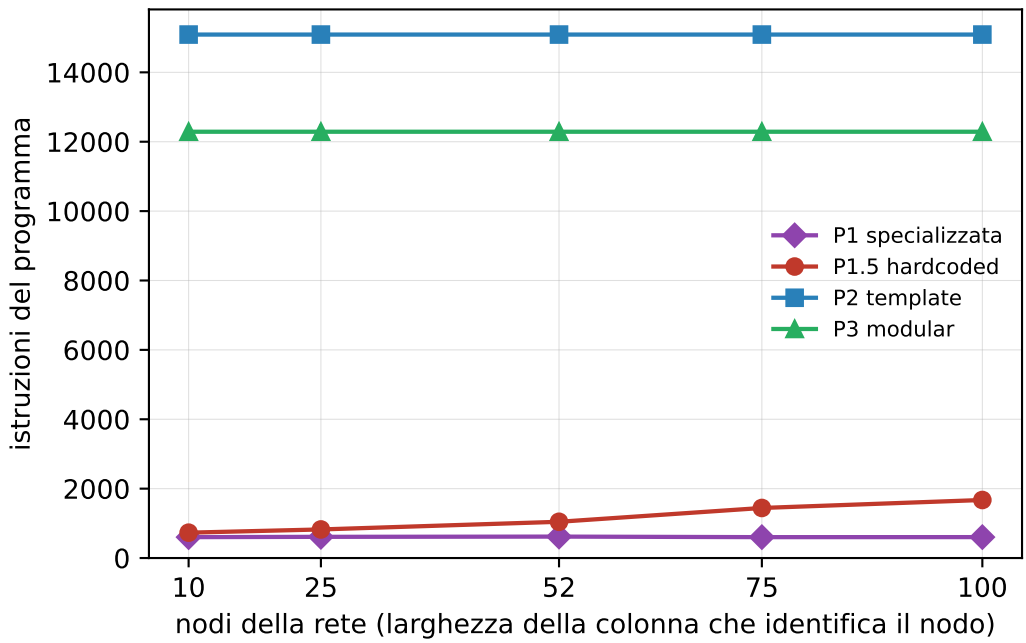
Le altre tre pipeline, che non specializzano niente, restano ferme lungo l'asse (1 045, 15 089 e 12 288 istruzioni, latenze piatte): la pendenza della specializzata viene dalle porte e da nient'altro.

Il controllo, che è servito davvero

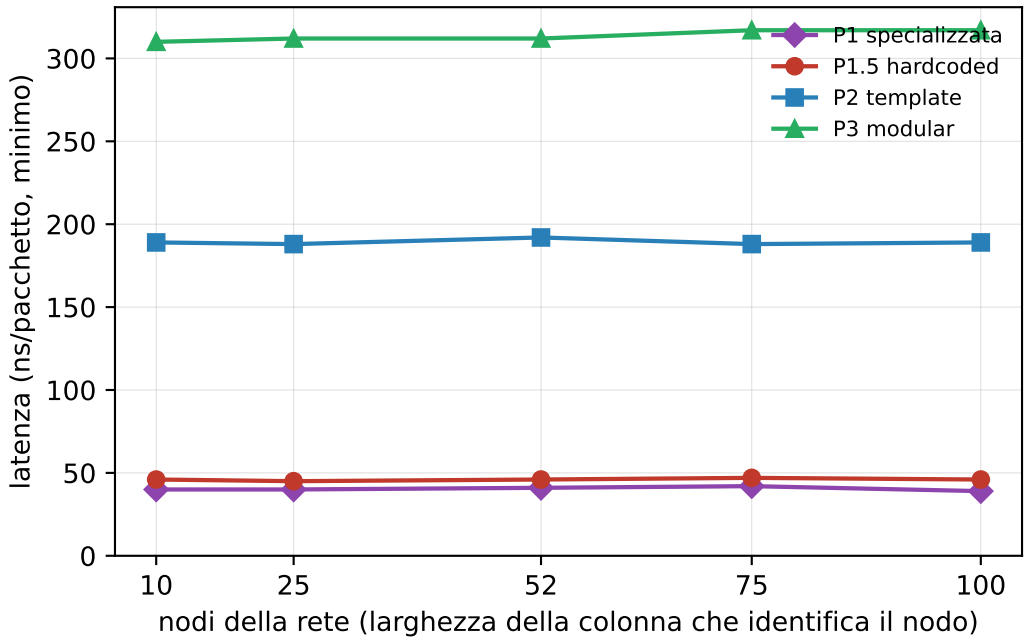
Ottanta casi — dieci valori di TTL per otto configurazioni di link realizzabili — danno la stessa classe fra la versione specializzata e quella a larghezza piena. Ma quel numero, da solo, non dimostra niente: se quelle colonne non spostassero mai la decisione, «le due versioni concordano» sarebbe vero anche per una specializzazione **sbagliata**. Serve un controllo al contrario: accendere uno slot che sul nodo non esiste, e pretendere che a quel punto le due divergano. Su alcuni pesi quel controllo resta muto — una colonna contribuisce $1 \cdot w$ a un accumulatore che ne somma 65 — e il banco cerca fra più semi finché non morde: 29 divergenze.

> Un test che passa anche quando la sua ipotesi è violata non sta verificando l'ipotesi.

10.8 Due larghezze, due risposte opposte

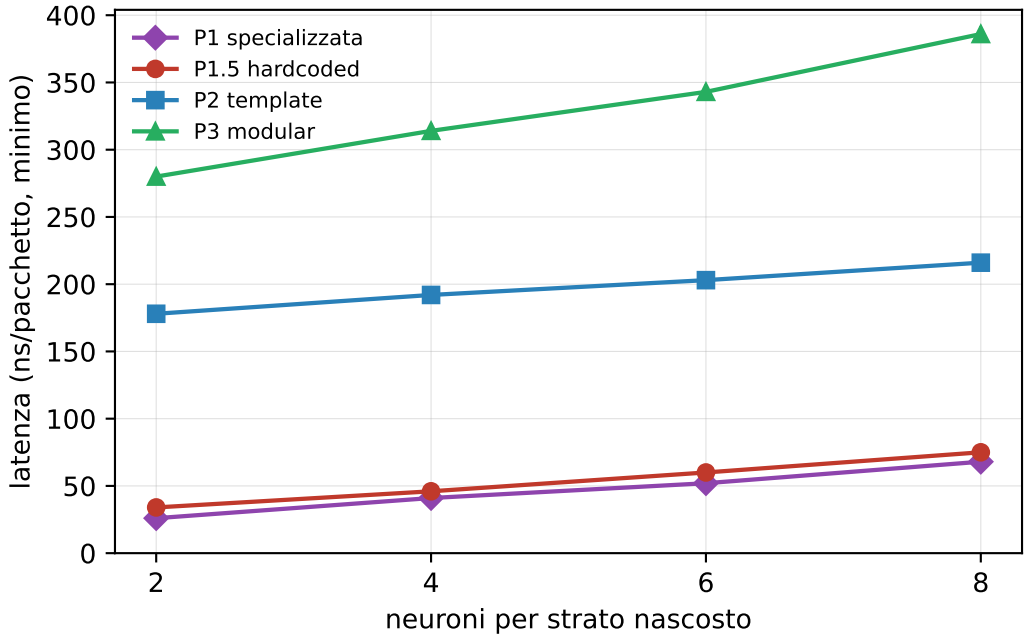


La taglia della *rete* entra nel programma solo in P1.5: è lo switch della one-hot che si srotola. P2 e P3 restano alla cifra esatta a ogni punto.



Piatte tutte. Cento nodi costano quanto dieci: una one-hot ha un solo uno, quindi il datapath legge *una sola colonna di pesi* qualunque sia la larghezza del vettore.

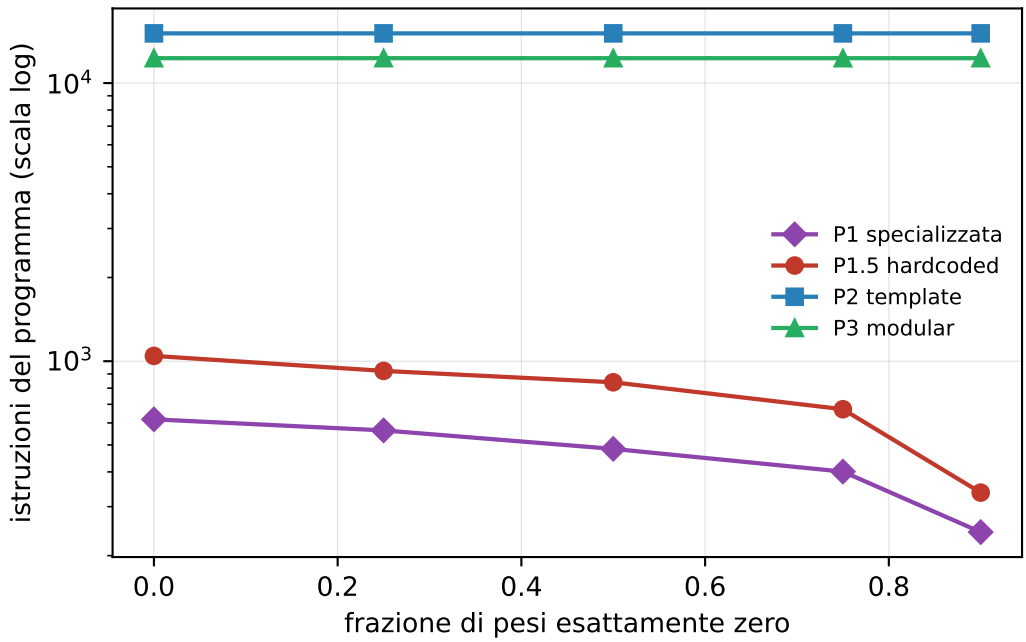
Allargare i layer *nascosti*, invece:



Da 2 a 8 neuroni: P1 specializzata 26 → 68 ns, P1.5 34 → 75, P2 178 → 216, P3 280 → 386. Sul traffico vero P1 104 → 145 e P3 391 → 496 ns di CPU per pacchetto (capitolo 12).

La rete può crescere quanto vuole; il modello no.

10.9 I pesi contano, ma solo per una delle tre



Con il 90% dei pesi a zero, P1.5 passa da 1 045 a **337 istruzioni** e da 45 a 25 ns. P2 e P3 non si muovono di una istruzione, e di un paio di nanosecondi al massimo. Sul traffico vero P1.5 scende da 120 a 106 ns di CPU, P2 e P3 restano fermi.

P1 scrive i pesi nel codice come numeri, quindi il compilatore vede una moltiplicazione per zero e la cancella. Per P2 e P3 uno zero è un byte in una tabella come un altro. È l'unico asse su cui dimensione e tempo scendono insieme.

10.10 Che cosa questi grafici non dicono

- Sono tutti `BPF_PROG_TEST_RUN`: il programma, non il nodo sotto traffico. Gli stessi assi sotto traffico vero sono nel capitolo 12.
- Oltre circa 115 nodi non si va senza alzare un tetto compilato e **rimisurare**.
- Che i *pesi*, a forma fissa, possano decidere se P1 si carica è possibile (il codice generato dipende dai valori), ma variando il solo seme dei pesi non è stato misurato. Con la ReLU senza bivio il verificatore ha molto margine (capitolo 8), quindi è poco probabile.

CAPITOLO 11

Il costo del programma, misurato da solo

Prima di mettere un programma in una rete conviene sapere quanto costa da solo. Qui lo strumento è `BPF_PROG_TEST_RUN`: il kernel esegue il programma su un pacchetto preparato, in un ciclo, senza schede di rete, code o altri programmi di mezzo. È come cronometrare un cassiere mentre batte sempre lo stesso scontrino: misura il gesto, non la fila. La fila è l'argomento del capitolo 12.

11.1 La campagna sulle architetture

Per rispondere a *come cresce il costo quando il modello cresce* servono più modelli misurati con la stessa metodologia: quattro assi, un solo parametro che si muove per asse, minimo su sette prove.

Asse	Valori	Che cosa muove
`iv_dense`	n_{in} 5, 9, 13, 17	colonne d'ingresso tutte *dense*: ognuna è letta da una mappa e moltiplicata
`iv_onehot`	n_{in} 16, 32, 65	colonne d'ingresso in una *one-hot*
`width_camp`	65-*v*-*v*-7, *v* 4, 8, 16, 32	neuroni per strato nascosto
`depth_camp`	65-8. . .8-7, 1–4 strati	profondità, a larghezza fissa 8

I muri, tutti dichiarati

Larghezza 16 e 32 su Pipeline 2 e 3. I soffitti compilati valgono 8. E Pipeline 3 non rifiuta il caricamento: risponde `XDP_PASS` a runtime. Una cella a larghezza 16 *si caricherebbe, girerebbe, e restituirebbe una latenza* — di un programma che non calcola niente. Il banco controlla i soffitti *prima* di compilare e segna la cella RIFIUTATO.

Larghezza 32 su Pipeline 1. La compilazione con clang fallisce (lo stack di eBPF non basta). Ogni cella gira nel proprio sottoprocesso: la cella esce CRASH e lo sweep continua. P1 a larghezza 16 carica (166–171 ns), e P2 carica tutti i punti di `depth_camp`, grazie alla ReLU senza bivio (capitolo 8).

11.2 Il problema: le MAC nominali non predicono la latenza

Il modo naturale di mettere in relazione complessità e tempo è contare le moltiplicazioni-accumulo dalla forma del modello: $n_{in} \times h_1$ per il primo strato, e così via. Fatto così, non funziona: con le MAC nominali sull'asse delle ascisse la retta spiega il 63% della varianza per la P1 specializzata, il 24% per P2 e il 10% per P3.

Il sintomo più chiaro sta sull'asse `iv_onehot`, dove il vettore d'ingresso quadruplica:

n_{in}	pesi	p1_static	hardcoded	template	modular
16	271	65 ns	65 ns	169 ns	361 ns
32	399	63 ns	63 ns	168 ns	364 ns
65	663	64 ns	64 ns	170 ns	367 ns

n_{in} per quattro, pesi per 2,4, e la latenza **non si muove su nessuna delle quattro**. Le istruzioni di Pipeline 1 intanto salgono da 1 099 a 1 587: la taglia statica cresce, il percorso eseguito no.

11.3 La soluzione: contare le MAC che vengono eseguite

La causa è nel datapath, ed è una riga sola. Il ramo che tratta una feature one-hot è questo:

```
} else if (code == FEAT_INGRESS_IF) {
    if (_raw_iface >= 1 && _raw_iface <= sz) {
        __u32 c = coff + (_raw_iface - 1);
        for (int j = 0; j < ML1_MAX_H1; j++)
            out[j] += LW_W(LW, woff + j * n_in + c);
    }
}
```

Una one-hot occupa `sz` colonne nella matrice dei pesi, ma nel datapath ne attiva *una*: il costo è h_1 addizioni, e non dipende da `sz`. Contarla come $sz \times h_1$ moltiplicazioni sovrastima, e di quanto dipende da quanta one-hot c'è nell'ingresso — cioè cambia da asse ad asse.

Il banco calcola quindi due colonne: `macs`, nominali, e `macs_eff`, che conta le one-hot per quello che eseguono. Con la seconda sull'asse delle ascisse:

	MAC eseguite		MAC nominali	
Pipeline	**ns/MAC**	r^2	**ns/MAC**	r^2
p1_static	0,287	**0,99**	0,071	0,63
hardcoded	0,292	**0,98**	0,076	0,69
template	0,574	0,71	0,092	0,24
modular	1,195	**0,92**	0,106	0,10

Per Pipeline 3 si passa da $r^2 = 0{,}10$ a $r^2 = 0{,}92$, e `p1_static` da 0,63 a 0,99. Quattro assi costruiti in modi diversi collassano sulla stessa retta, una per pipeline. P2 si ferma a $r^2 = 0{,}71$: ha un costo fisso grande rispetto alla pendenza, e il suo residuo più grande sta sull'asse della larghezza, dove i neuroni oltre la larghezza del modello vengono calcolati comunque fino al soffitto compilato.

> **Il costo per MAC eseguita è una proprietà misurabile della pipeline**: circa 0,29 ns quando i pesi sono compilati come letterali, circa 1,2 ns quando vengono letti da una tabella (P3). Un fattore 4,2×: il prezzo della genericità espresso in una costante invece che in un aneddoto.

Il pavimento della `baseline`, che di MAC ne esegue zero, sta a 14–15 ns: è il costo del framework XDP che ogni pipeline paga prima di moltiplicare qualunque cosa.

11.4 Due banchi, lo stesso programma, lo stesso numero

I due banchi a `BPF_PROG_TEST_RUN` misurano lo stesso programma, e devono dare lo stesso numero. Sul modello 65-4-4-7:

Pipeline	`test_suite`	campagna	scarto
baseline	14 ns	14 ns	0%
hardcoded	52 ns	45 ns	−13%
template	194 ns	187 ns	−4%
modular	318 ns	308 ns	−3%

Concordano entro qualche nanosecondo, e i programmi non sono identici: `test_suite` usa i pesi veri del modello (1 019 istruzioni per P1), la campagna pesi sintetici a sparsità nulla (1 045).

Il dettaglio che lo rende vero: un pacchetto nuovo ogni 200 giri

Il kernel, dentro `BPF_PROG_TEST_RUN`, non ripristina il pacchetto fra una ripetizione e l'altra. Il datapath decrementa il TTL: riusando lo stesso pacchetto, dopo una quarantina di esecuzioni il TTL resterebbe inchiodato a 1, e da lì in poi ogni ripetizione prenderebbe il ramo

```
if (ip->ttl <= 1) { /* ... */ return XDP_PASS; }
```

che sta **dopo** l'inferenza — il modello girerebbe comunque, e le curve scalerebbero in modo regolare — ma salta la coda di inoltro: decremento, checksum, contatori, `mac_table`, `bpf_redirect`. Tutti i banchi rinfrescano quindi il pacchetto ogni 200 esecuzioni partendo da TTL 255 ($255 - 200 = 55$): nessuna ripetizione arriva alla scadenza.

> Un difetto che lascia il modello girare è il più difficile da vedere: le curve restano belle. Si vede solo confrontando due banchi che devono dare lo stesso numero.

11.5 Il programma sul percorso vero: tre marcature

Con traffico vero si può cronometrare il programma *dentro* il percorso: il dispatcher marca T_1 all'ingresso, il programma marca T_2 subito prima di inoltrare, il contatore all'altro capo marca T_3.

	baseline	P1	P1.5	P2	P3
$T_2 - T_1$ (il programma)	26 ns	60	69	216	331
$T_3 - T_2$ (redirect, veth, ricezione)	206	207	208	218	222
$T_3 - T_1$ a 50 000 pacchetti/s	221	259	274	442	609

Con `xdp_gen`, nodo su un P-core. $T_2 - T_1$ è piatto sul carico, da 0,5 a 3 milioni di pacchetti al secondo; $T_3 - T_2$ è un costo comune di circa 210 ns che non dipende dalla pipeline; $T_3 - T_1$ a basso carico è la latenza minima dall'arrivo alla ripartenza. Sopra la baseline il solo programma costa +34 / +43 / +190 / +305 ns. Su un E-core $T_2 - T_1$ vale 28 / 72 / 84 / 266 / 434 ns e $T_3 - T_2$ circa 245. La versione strumentata aggiunge due letture dell'orologio per pacchetto: se qualcosa, questi numeri sono gonfiati. E il throughput di questa versione non è una capacità: l'uscita resta sullo stesso core del nodo.

CAPITOLO 12

Il test reale: quanto costa un pacchetto al nodo

12.1 La domanda, in parole semplici

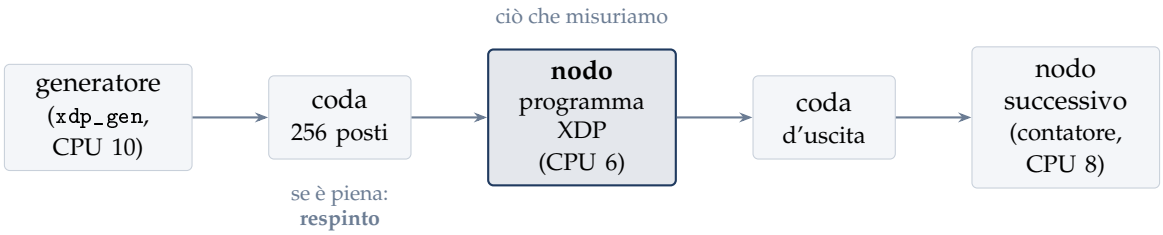
Un nodo della rete riceve pacchetti, per ognuno esegue la rete neurale, decide da quale porta farlo uscire, e lo spedisce. La domanda è: **quanti pacchetti al secondo regge il nodo**, e **quanto tempo spende su ognuno**?

Un'immagine per tutto il capitolo: la cassa del supermercato

Il nodo è un **cassiere**. I pacchetti sono i **clienti**. Il generatore di traffico è la porta da cui entrano i clienti, e il collegamento virtuale fra generatore e nodo è il **nastro** su cui i clienti aspettano: ha 256 posti, e quando è pieno chi arriva viene mandato via.
Per sapere quanto spende il cassiere per cliente si fanno arrivare più clienti di quanti ne riesca a servire, così che il nastro non sia mai vuoto, e si conta quanti ne serve in un secondo. Se ne serve 5 milioni al secondo, spende 1/5 000 000 di secondo a cliente, cioè 200 nanosecondi.

12.2 Com'è fatto il banco

Tutto sta sulla macchina di laboratorio, e ogni parte ha il suo core fisico, a frequenza fissa (capitolo 13):



- **Il generatore** (`xdp_gen`, sezione 12.4) crea pacchetti uguali a quelli veri: stesso formato, stesso header IPA, stesso modello da eseguire. Un thread, che scrive nell'unica coda del nodo. Generatore e nodo successivo stanno su P-core; il nodo su un P-core, un E-core o un LP E-core, secondo la domanda (sezione 12.11).
- **La coda d'ingresso** è quella di un *veth*, il cavo virtuale di Linux: 256 posti, e la dimensione non si può cambiare.
- **Il nodo** è una delle pipeline caricata in XDP. È l'unica cosa che si vuole misurare.
- **Il nodo successivo** conta i pacchetti arrivati e li butta, su un core suo, così che sul core del nodo resti solo il lavoro del nodo.

Oltre alle cinque pipeline il banco misura, nella stessa sessione, `rxonly`: un programma che prende il pacchetto dalla coda e lo butta senza guardarlo. Dice quanto costa *soltanto ricevere*: è il pavimento sotto il quale nessuna pipeline può scendere.

12.3 Come si misura, e perché così

Un numero affidabile richiede quattro accortezze. Nessuna riguarda le pipeline: senza, tutte farebbero sembrare il nodo diverso da com'è.

1. La finestra stazionaria

Il banco avvia il generatore, aspetta che stia trasmettendo, lascia assestare la coda, legge i contatori, aspetta 300 ms, li rilegge, e solo allora ferma il generatore. Il rate è la differenza fra le due letture divisa per il tempo fra le due letture: l'avvio e l'arresto restano fuori.

2. Letture brevi

Ogni lettura (generatore più nodo) deve durare meno di 3 ms; se dura di più viene rifatta, e le si attribuisce l'istante a metà. Un processo interrotto a metà lettura attribuirebbe ai contatori un istante sbagliato di tutta l'interruzione. Un test senza kernel lo verifica con un generatore simulato.

3. I respinti contano

Quando la coda d'ingresso è piena il collegamento rifiuta il pacchetto («respinto»). Un pacchetto respinto è un pacchetto che il nodo non ha preso, perché non svuotava la coda abbastanza in fretta: **è una perdita del nodo**. Il banco conta separatamente i **respinti** (mai entrati) e i **persi dopo l'ingresso** (entrati ma non usciti).

4. Il tempo di CPU, non il tempo che passa

Il banco misura anche quanto il core del nodo è occupato, nella stessa finestra in cui conta i pacchetti, e dà il costo come **tempo di CPU per pacchetto**: occupazione per il tempo diviso i pacchetti. Se il nodo lavora il 100% del tempo coincide con 1 diviso la capacità; se a tratti aspetta, toglie l'attesa. Con `xdp_gen` il nodo lavora al 100%, e le due misure coincidono.

Nella stessa lettura il banco legge anche i **contatori hardware** del core del nodo: istruzioni e cicli. Divisi per i pacchetti dicono quante istruzioni costa un pacchetto e quante ne esegue il core per ogni ciclo (l'IPC). Il tempo di CPU dice *quanto* costa un pacchetto; istruzioni e IPC dicono *perché*.

12.4 Il generatore

`xdp_gen`: pacchetti come da una scheda di rete

Il generatore (`ipa/test/xdp_gen.py`) consegna al cavo virtuale pacchetti già nel formato di XDP, con `BPF_PROG_TEST_RUN` in modalità *live frames*: il kernel li prepara in una sua riserva di pagine, con i 256 byte liberi davanti che XDP vuole, e li spedisce davvero. Niente skb e niente copia: il pacchetto arriva al nodo come arriverebbe da una scheda di rete con XDP nativo, e il nodo paga solo il proprio lavoro. Un solo thread offre fino a circa 19 milioni di pacchetti al secondo, ed è così che si usa: un thread per ogni coda del nodo (sezione 12.8).

Ogni misura è **una sola chiamata** al kernel, interrotta da un segnale a fine finestra. Ogni chiamata, infatti, parte e finisce con una pausa del generatore di circa 12 ms dentro il kernel: con più chiamate per finestra il generatore tacerebbe una parte del tempo, e il nodo svuoterebbe la coda e dormirebbe. Le statistiche di scheduling del thread del nodo lo controllano: a coda piena lavora il 100% del tempo.

Il ritmo e il timbro

Per il test al crescere del traffico (sezione 12.9) serve un ritmo fissato, e `xdp_gen` non ne ha uno suo: spinge al massimo. Il ritmo lo tiene il suo programma, che a ogni giro guarda l'orologio: se non è ancora il momento scarta il pacchetto (la pagina torna subito alla riserva) e riprova; quando è il momento lo spedisce, e fissa il prossimo istante un intervallo più in là. I pacchetti partono a distanza regolare, non a raffiche: una raffica da 256 riempirebbe da sola la coda e farebbe perdere pacchetti sotto capacità. Nello stesso istante il programma scrive nel pacchetto un timbro con l'ora di partenza, e il nodo successivo misura il ritardo. Il ritmo è esatto fino a circa 11 milioni di pacchetti al secondo (a 12 ne parte il 98%).

L'alternativa: `pktgen`

`pktgen` è il generatore del kernel: fabbrica i pacchetti come lo stack di rete, in una *skb* con 64 byte liberi davanti, e il cavo virtuale li **ricopia** in una pagina nuova prima di consegnarli al nodo. La copia la paga il nodo, e su una scheda vera non esisterebbe.

Per questo il banco usa `xdp_gen`, e tutte le cifre di questo capitolo sono con `xdp_gen`; `pktgen` resta disponibile per i percorsi che lo richiedono.

12.5 Perché un core vero, tutto suo

Il nodo deve avere un core fisico suo, che non gli venga mai tolto, e il conto che lo spiega è semplice. La coda d'ingresso ha 256 posti. A 1,5 milioni di pacchetti al secondo un pacchetto arriva ogni $1/1{,}5 \cdot 10^6 \approx 0{,}67$ microsecondi, quindi la coda si riempie in

$$256 \times 0{,}67\ \mu\text{s} \;\approx\; 170\ \mu\text{s}.$$

Se il core del nodo si ferma per più di 170 microsecondi — perché il sistema lo dà a un altro processo, o perché si addormenta — la coda trabocca e i pacchetti vengono respinti, *per quanto veloce sia il programma*. Nell'immagine del supermercato: il cassiere è bravissimo, ma se ogni tanto esce dalla cassa per qualche secondo il nastro si riempie e i clienti vengono mandati via. Una macchina virtuale, i cui core sono thread dell'ospite che possono sparire per qualche millisecondo, non può fare questo banco.

Per questo:

- **Core veri, ognuno col suo compito.** Generatore sul core 10, nodo sul core 6 (o 12, o 20), nodo successivo sull'8. Nessun altro processo, nessuna interruzione e nessun thread del kernel sul core del nodo (capitolo 13).
- **Il core del nodo non dorme mai.** Gli stati di sonno profondi sono spenti: il risveglio dal più profondo costa 310 microsecondi, più dei 170 che la coda concede. Sotto capacità il nodo non respinge niente.
- **Frequenza fissa e misurata**: 3 472–3 507 MHz sul core del nodo durante ogni misura di traffico (2 500 sul LP E-core), letta dai contatori del processore.

- **Generatore e nodo su core separati**, quindi il generatore non è dentro la misura: il ritmo a cui il nodo satura è quello del nodo.

Il risultato si vede ripetendo: cinque giri allo stesso punto danno lo stesso inoltro in genere entro lo 0,1%, al massimo entro il 6% vicino al punto in cui la pipeline smette di reggere; la stessa pipeline misurata in quattro modi diversi nella stessa sessione dà lo stesso costo entro il 2%.

12.6 I limiti del test, con esempi

Il condizionamento della macchina toglie il rumore. Non toglie i limiti di un banco che sta tutto su un portatile: vanno conosciuti, perché ognuno dice quali numeri si possono citare e quali no.

1. Il generatore può non bastare, o intralciare

Se il nodo è più veloce di quanto il generatore riesca a produrre, il banco misura il generatore. Un thread di `xdp_gen` offre circa 19 milioni di pacchetti al secondo a massima spinta, circa 12 a ritmo fissato e circa 9 a ritmo fissato quando i pacchetti vengono inoltrati: per questo su un core `rxonly` non arriva mai al suo limite, la baseline ci arriva appena, e sulle curve del bit rate la baseline non lo raggiunge (da 9 milioni perde l'1% con il nodo al 60%: è il banco, e il test lo riconosce dall'occupazione del nodo). Aggiungere thread sembra la soluzione, ma più thread che scrivono nella *stessa* coda si intralciano, e rallentano anche il nodo che la svuota: è la sezione 12.8.

2. Contare all'uscita può sottostimare il nodo

Il nodo successivo, che conta i pacchetti arrivati, ha i suoi core e i suoi tetti. Se si misura il nodo contando *ciò che arriva dall'altra parte*, quando il nodo è più veloce dell'uscita si misura l'uscita.

Esempio: la baseline che sembrerebbe lenta

Un core d'uscita spende circa 70 ns per ricevere, contare e restituire un pacchetto: regge al più una dozzina di milioni di pacchetti al secondo. Se due core del nodo gli mandano 25 milioni di pacchetti al secondo, la baseline ne *elabora* 25 ma all'altra parte ne arrivano 12; P2 ne elabora 6 e arrivano tutti. Contando gli arrivi, la baseline sembrerebbe più lenta di P2 — impossibile, perché fa strettamente meno lavoro.
Per questo il controllo di validità del banco ("la baseline dev'essere la più veloce") conta i pacchetti *elaborati dal nodo*, la stessa misura con cui il banco calcola il costo, e non quelli arrivati all'uscita.

Con un solo scrittore per coda anche all'uscita il nodo successivo tiene il passo: con due core sul nodo serve una coda d'uscita per ciascun core, e un core d'uscita per ciascuna coda; allora arrivano tutti, anche 29 milioni al secondo (sezione 12.10).

3. Il cavo è virtuale, e tutto sta su un processore

Il "ricevere" misurato è prendere il pacchetto dalla coda di un cavo virtuale, non dalla memoria di una scheda di rete; "inoltrare" è accodarlo sul cavo successivo, non scrivere un descrittore di trasmissione. Generatore, nodo e nodo successivo sono core dello stesso chip

e condividono cache e memoria. Il portatile non ha una scheda di rete cablata che supporti XDP nativo.

Esempio: i 66 ns per pacchetto della baseline sono il prezzo *di questo percorso*. Su una scheda vera sarebbero altri numeri, e le cifre assolute di questo capitolo con loro. I **confronti** fra pipeline no: il percorso è lo stesso per tutte, e si sottrae.

4. Un solo tipo di pacchetto per volta

In una misura tutti i pacchetti sono uguali: stesso modello, stesso TTL, stessa classe decisa. Il processore impara in fretta un flusso così (il predittore dei salti, la cache), e un traffico misto costerebbe un po' di più. Le classi si misurano una alla volta, ed è così che si è visto che scartare costa più che inoltrare.

5. Il ritardo a basso carico contiene il generatore

`xdp_gen` spedisce a lotti di 256 frame, e il nodo viene svegliato a fine lotto: a basso carico un pacchetto può aspettare fino a una dozzina di microsecondi prima che il nodo lo veda, e la mediana del ritardo, 17–19 µs sul P-core, contiene quell'attesa. Lotti più piccoli la tolgono, ma il generatore regge ritmi più bassi. Il salto del ritardo a coda piena, che è ciò che il test cerca, non cambia.

6. Il punto esatto in cui comincia la perdita è instabile

Al confine fra "regge" e "perde" basta un'esitazione di pochi microsecondi per perdere un pacchetto: lo stesso punto, ripetuto, varia fino al 6%, mentre la saturazione varia di 1–3%. Si citano quindi la saturazione e i gradini della scala, non il confine esatto.

7. Il portatile scalda

Oltre 3,5 GHz non regge una misura intera, e anche a 3,5 capita che il processore nel suo insieme tocchi per un attimo la soglia di temperatura, di solito mentre clang compila sugli altri core. Il banco lo registra e conta le finestre disturbate (anche il funzionamento a batteria è un disturbo): nelle misure di traffico di questo capitolo nessuna finestra ha avuto throttling, e il core del nodo è rimasto a 3 500 MHz.

12.7 Il risultato: quanto regge il nodo

Con `xdp_gen`, un core del nodo (un P-core a 3,5 GHz), pacchetti da 64 byte, tre giri:

Pipeline	Mpps	ns per pacchetto	sopra la baseline	cicli	istruzioni	IPC
solo ricezione (`rxonly`)	19,47	≈ 41	—	161	384	2,4
baseline (nessuna rete)	15,27	66	—	225	606	2,7
P1 statica	8,56	117	+51 ns	402	1 220	3,0
P1.5 (hardcoded)	8,04	124	+58 ns	432	1 426	3,3
P2 (template)	3,45	290	+224 ns	1 013	4 556	4,5
P3 (modular)	2,36	425	+359 ns	1 483	6 573	4,4

Nodo occupato al 100% (79% per `rxonly`, che non satura: il suo valore è indicativo). La baseline satura appena: il generatore ne offre 15,3 milioni al secondo. Cicli e istruzioni sono per pacchetto, dai contatori hardware del core del nodo.

La **baseline** riceve, legge l'intestazione, decrementa il TTL e inoltra. Tutto ciò che le pipeline aggiungono sopra è **il costo della rete neurale**: circa 50–60 ns quando i pesi sono scritti nel programma (P1, P1.5), circa 225 ns quando la forma della rete è letta da una tabella (P2), circa 360 ns quando anche la profondità lo è (P3).

Come si legge la colonna dei nanosecondi, con un esempio. La baseline regge 15,27 milioni di pacchetti al secondo, cioè spende $10^9/15{,}27 \cdot 10^6 = 66$ ns per pacchetto; P2 ne regge 3,45 milioni, cioè 290 ns. La differenza, $290 - 66 = 224$ ns, è il tempo che P2 spende a eseguire la rete neurale: tutto il resto — ricevere, leggere l'intestazione, inoltrare — lo fanno tutte e due allo stesso modo. I cicli confermano: a 3,5 GHz 66 ns sono 231 cicli, e il contatore ne conta 225. P3 varia più delle altre fra una misura e l'altra: lo stesso modello dà 416–445 ns nella stessa giornata.

Le istruzioni per pacchetto dicono un'altra cosa che il programma da solo non dice: P3 *esegue* più istruzioni di P2 (6 573 contro 4 556), pur caricandone di meno. E l'IPC delle pipeline con i pesi in tabella è alto, oltre 4: è aritmetica in fila, senza bivi, che il core esegue molte istruzioni per volta.

E sotto la capacità? Sulle curve del bit rate (sezione 12.9), finché il traffico resta sotto la capacità di una pipeline **nessun pacchetto viene respinto** (al massimo lo 0,05%). Un nodo sotto la sua capacità consegna tutto.

P1 e P1.5 si separano

8,56 contro 8,04 milioni al secondo: congelare il nodo vale circa 7 nanosecondi sul percorso vero (117 contro 124 ns per pacchetto), e 206 istruzioni in meno per pacchetto. Piccolo, ma fuori dal rumore.

Da che cosa il costo non dipende

- **La taglia del pacchetto non conta**: a 64, 512 e 1 514 byte il costo è lo stesso entro l'1%. Il nodo guarda solo l'intestazione.
- **La porta d'uscita conta poco**: le cinque classi che inoltrano costano uguale entro il 2–3% per P1, P1.5 e P3, entro il 12% per P2.
- **Scartare costa di più che inoltrare**: la classe DROP costa circa 50 ns in più delle altre (P1 166 contro 118–120, P1.5 176 contro 124–127, P3 467 contro 416–426). Quando il pacchetto viene scartato la sua pagina di memoria si restituisce sul core del nodo; quando viene inoltrato, su quello del nodo successivo. È un effetto del banco, non della pipeline.

12.8 Uno scrittore per coda

Il generatore usa **un thread per coda** del nodo, e non di più. Più thread che scrivono nella stessa coda da 256 posti devono passarsi un lucchetto e le stesse righe di cache; il core del nodo, che dalla stessa coda legge, ne subisce il rallentamento, e il nodo elabora *meno* pacchetti invece di più. È come una cassa dove tre fornitori scaricano merce nello stesso punto: il cassiere non lavora peggio, ma gli spazi sono contesi. Il danno è grande per i programmi leggeri e quasi nullo per quelli il cui limite è davvero il programma.

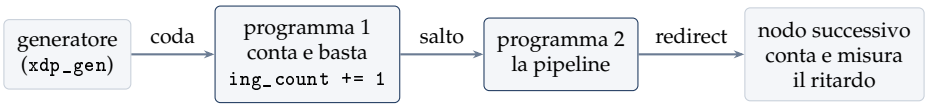
Un solo scrittore per coda, in ingresso e in uscita: più thread di generatore non aiutano, peggiorano. Con una scheda di rete vera la regola è rispettata da sé: la coda di ricezione la riempie la scheda, un solo scrittore, e i pacchetti degli altri host arrivano in fila sul cavo. Resta quello che conta, la coda piena davanti a un nodo troppo lento.

12.9 Al crescere del bit rate

La domanda: al crescere del traffico offerto la coda si riempie, il tempo di attraversamento cresce, e poi si perde. Se si perde *all'ingresso* del programma, il collo di bottiglia è il programma; se si perde *dopo*, è la trasmissione. Per saperlo bisogna contare quanti pacchetti il programma riceve e quanti ne rilancia.

Due programmi sullo stesso aggancio

Un'interfaccia porta un solo programma XDP. Due programmi sullo stesso aggancio si ottengono in **catena**, con lo stesso salto fra programmi che le pipeline usano già:



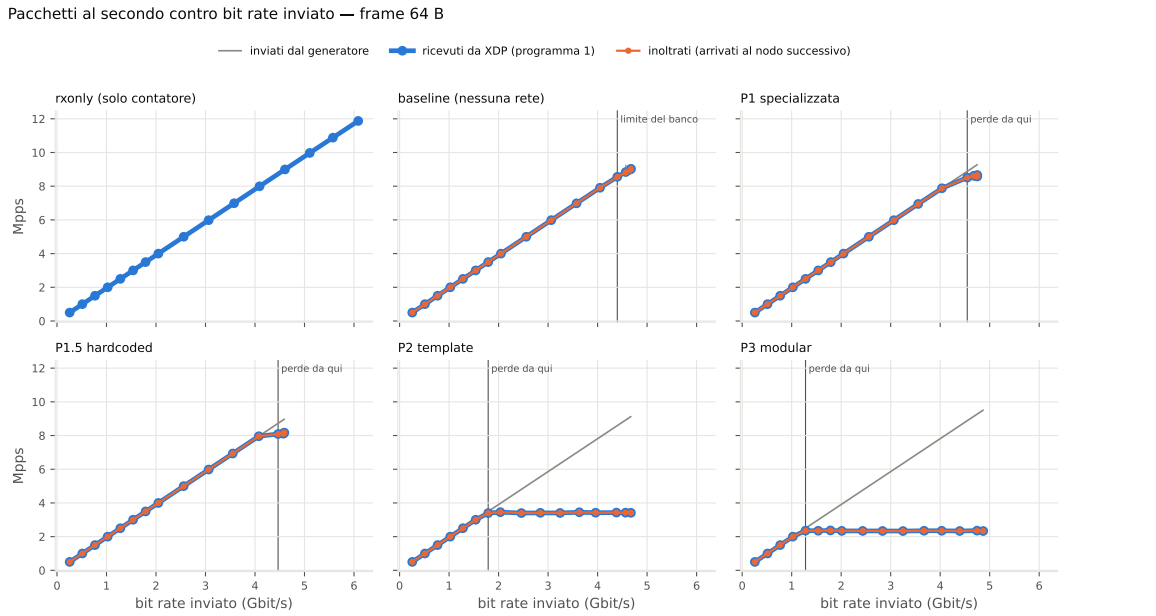
Il primo programma è attaccato all'interfaccia, conta ogni pacchetto e salta al secondo, che è il dispatcher della pipeline, identico a quello di produzione.

Perché in catena. Il kernel tiene, per ogni interfaccia, *un* programma XDP nell'aggancio nativo: è come è fatto XDP, non un limite di questo progetto. I modi di averne più di uno sono tutti catene. Quello standard è `libxdp`, che aggancia un programma *dispatcher* con alcuni posti liberi e ci inserisce gli altri; quello usato qui è il salto fra programmi (*tail call*) che le pipeline già usano, senza dipendenze in più. Il salto in più costa da -3 a $+2$ ns, dentro la variazione fra le ripetizioni: il kernel tiene il tempo di ogni programma attaccato, e lo si misura con e senza il contatore davanti.

Così si hanno tre conteggi per ogni valore di traffico: **inviati** (dal generatore), **ricevuti** (dal programma 1) e **inoltrati** (arrivati al nodo successivo). Inviati meno ricevuti è la perdita *prima* del programma; ricevuti meno inoltrati quella *dopo*. Un terzo metodo, `rxonly`, è il contatore da solo: dice quanto regge la sola ricezione allo stesso ritmo, e separa il collo del programma da quello del banco.

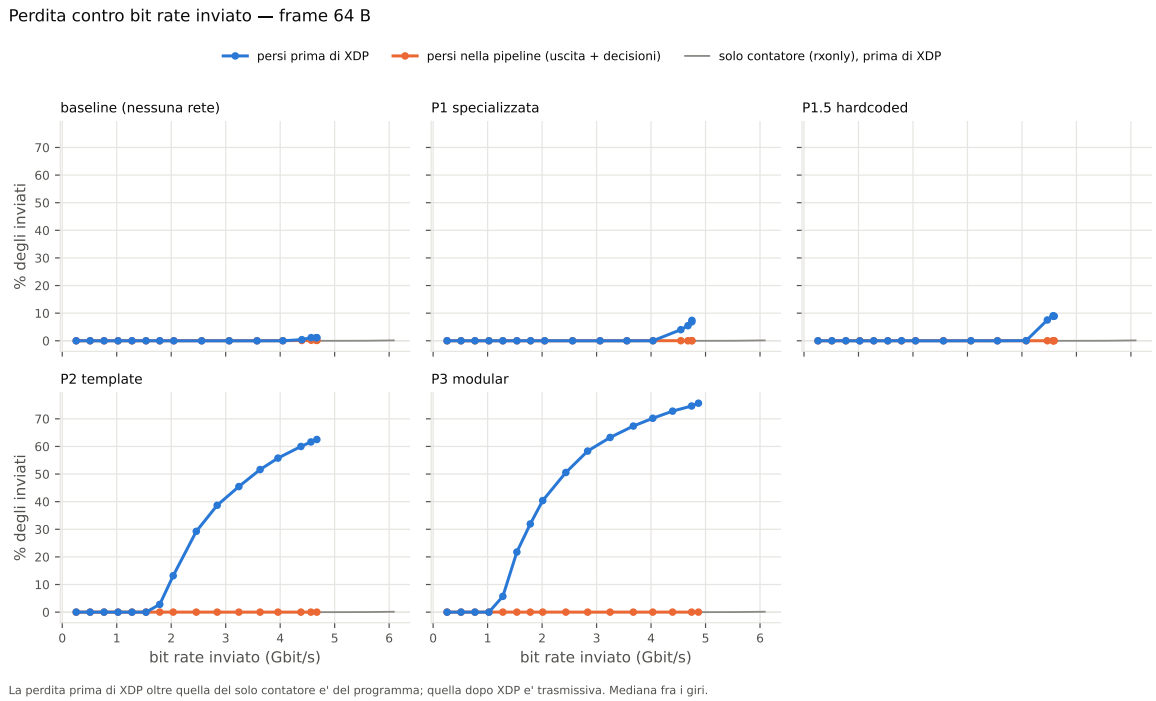
Il banco misura sedici valori di traffico, da 0,5 a 12 milioni di pacchetti al secondo (da 0,26 a 6,1 Gbit/s a pacchetti da 64 byte), cinque giri ciascuno. Il ritardo è quello di tutto il percorso: dal timbro che `xdp_gen` scrive nel pacchetto quando lo spedisce all'arrivo al nodo successivo.

Ricevuti e inoltrati



Inviati sopra i ricevuti: si perde prima di XDP (coda d'ingresso piena, collo il programma o la ricezione). Ricevuti sopra gli inoltrati: si perde dopo XDP (uscita, collo trasmissivo) o il modello scarta. Barre: min-max fra i giri.

Ogni pannello ha tre curve. Finché il nodo regge sono sovrapposte: tutto ciò che si invia viene ricevuto e inoltrato. Oltre il suo limite la linea grigia (inviati) continua a salire e le altre due si fermano **insieme**, alla capacità della pipeline: 8,66 milioni al secondo per P1, 8,17 per P1.5, 3,45 per P2, 2,37 per P3, la stessa cifra del test di saturazione (8,56, 8,04, 3,45 e 2,36) entro il 2%; al ginocchio il nodo lavora il 99,5–100% del tempo. La baseline è un caso a parte: da 9 milioni al secondo perde circa l'1,3%, ma con il nodo al 60%. Il nodo ha tempo libero, quindi il limite è del banco: quando i pacchetti vengono inoltrati `xdp_gen` non ne manda più di circa 9 milioni al secondo. La capacità della baseline resta quella del test di saturazione, 15,3 milioni. Che ricevuti e inoltrati restino sovrapposte è la risposta alla domanda: **il programma rilancia tutto ciò che riceve**, e ciò che manca non è mai entrato.



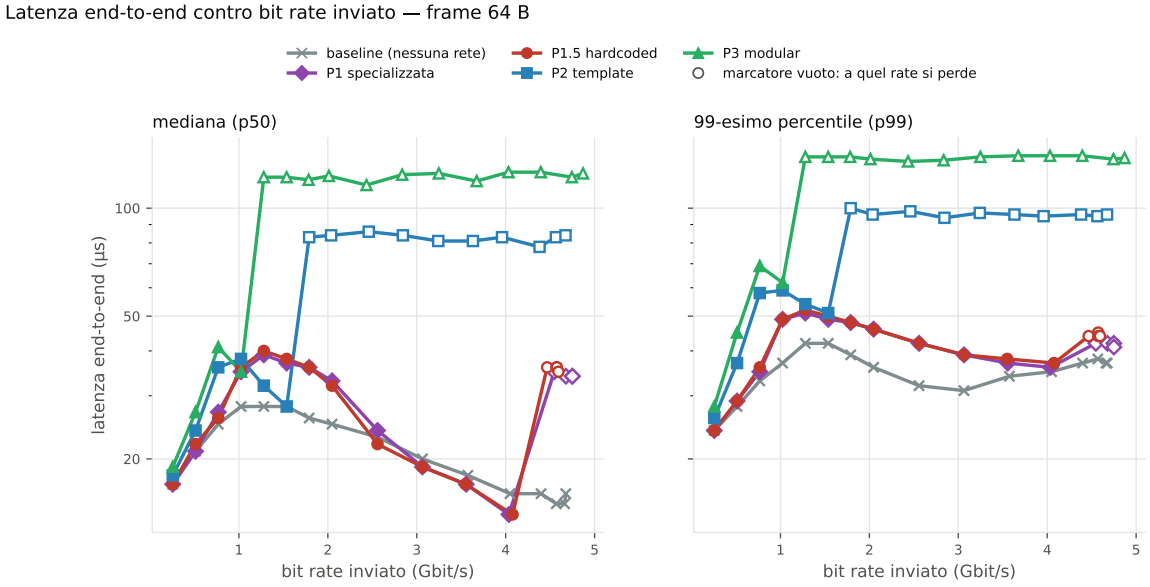
La stessa cosa come perdita: la curva dei persi prima di XDP sale, quella dei persi dentro la pipeline o all'uscita resta a zero, al massimo lo 0,04% degli inviati. Il solo contatore non perde fino a 11 milioni al secondo: la perdita delle pipeline non è della ricezione ma del programma.

Pipeline	**pulita fino a**	**perde da**	**inoltro massimo**
baseline	4,05 Gbit/s	—*	9,02* M/s
P1 statica	4,04	4,56	8,66
P1.5	4,08	4,56	8,17
P2	1,54	1,79	3,45
P3	1,02	1,28	2,37

pacchetti da 64 byte; bit rate misurato sul collegamento; nodo su un P-core. * baseline: oltre 8 M/s il limite è del banco, non del programma

Le prime due colonne sono **gradini**, non soglie esatte: "pulita fino a 1,54, perde da 1,79" vuol dire che la perdita comincia da qualche parte fra i due. Esempio: P2 inoltra al massimo 3,45 milioni di pacchetti al secondo, cioè $3{,}45 \cdot 10^6 \times 64 \times 8 \approx 1{,}77$ Gbit/s, proprio fra i due gradini.

Il ritardo



Timbro di xdp_gen all'invio -> nodo successivo, nessuna correzione; mediana fra i giri. Scala logaritmica.

Il ritardo fa quello che la domanda prevede: resta di qualche decina di microsecondi finché il nodo regge, poi **salta** esattamente dove la pipeline comincia a perdere (marcatori vuoti), e da lì resta piatto. Il salto è la coda d'ingresso che si riempie: 256 posti davanti a un programma che serve un pacchetto ogni 117 ns (P1), 124 (P1.5), 290 (P2) o 425 (P3) fanno 30, 32, 74 e 109 microsecondi di attesa; le curve si fermano a circa 35, 36, 82 e 122 µs, e il resto è il percorso fino al nodo successivo. La baseline non riempie mai la coda. Oltre, la coda non può crescere: è piena, e ciò che arriva in più viene respinto. Il ritardo si ferma e cresce la perdita. A basso carico la mediana contiene l'attesa nel generatore (sezione 12.6, punto 5).

Perché il collo di bottiglia è il programma

È quello che ci si deve aspettare, per come funziona XDP. Il programma non ha una coda sua: gira dall'inizio alla fine su ogni pacchetto, sul core che riceve, e finché non ha finito quel core non prende il pacchetto successivo. Se i pacchetti arrivano più in fretta di quanto il core li finisca, si accumulano nella coda *davanti* al programma, e quando è piena vengono respinti. La perdita all'ingresso è quindi il segno di un nodo più lento del traffico, e il nodo è il suo programma.

Resta da escludere che il limite sia la sola ricezione, che gira sullo stesso core. Lo dice `rxonly`, il contatore da solo: fino a 11 milioni di pacchetti al secondo **non perde niente**, perché la sola ricezione regge circa 19 milioni. Al traffico più alto P1 perde il 7%, P1.5 il 9%, P2 il 63%, P3 il 76%: la perdita è del programma, e cresce con il suo costo. L'uscita invece non limita: dopo il programma si perde lo 0,04% al massimo, ed è rumore di lettura.

Due precisazioni. Per la baseline il "programma" è quasi solo lettura dell'intestazione e redirect: il suo limite è il costo fisso di un nodo XDP, non una rete neurale. E il nodo ha **una sola coda e un solo core** per scelta, per misurare il costo per core: una scheda di rete vera distribuisce i pacchetti su più code e più core (RSS), e la capacità del nodo cresce con il numero di core, mentre il costo per pacchetto resta quello misurato qui.

12.10 Due core

Perché la capacità cresca davvero con i core, i core non devono contendersi niente di scritto a ogni pacchetto. Per questo i contatori delle pipeline (pacchetti inoltrati, persi, scartati, e uno per classe) sono **per-core**: ogni core incrementa la sua copia, senza istruzioni atomiche, e chi legge somma le copie. E ogni core del nodo ha la sua coda d'ingresso, il suo thread di `xdp_gen`, la sua coda d'uscita e il suo core d'uscita: il cavo virtuale sceglie la coda d'uscita dal numero del core che inoltra, e con una coda sola i due core del nodo scriverebbero nello stesso anello, svuotato da un solo core del nodo successivo (l'esempio della sezione 12.6, punto 2).

	P-core			E-core		
Programma	**1 core**	**2 core**	**del doppio**	**1 core**	**2 core**	**del doppio**
baseline	15,27	29,11	95%	9,39	19,09	102%
P1	8,56	17,46	102%	6,35	12,74	100%
P1.5	8,04	16,19	101%	5,84	11,71	100%
P2	3,45	6,63	96%	2,83	5,60	99%
P3	2,36	4,60	98%	1,94	3,84	99%

Milioni di pacchetti elaborati al secondo, alimentatore. Due P-core: 6 e 8, uscite su 3 e 5. Due E-core: 12 e 16, uno per modulo, uscite su 6 e 8.

Con due core ogni programma elabora il doppio (95–102%): il secondo core non rallenta il primo, e il costo per core è quello di un core solo entro una decina di nanosecondi. Per un nodo con N code vale quindi N volte la capacità misurata su un core, finché generatore e scheda reggono.

Per tutte e cinque la perdita è **all'ingresso**: il collo di bottiglia è il programma eBPF, non la trasmissione, e la sola ricezione non perde affatto. Il ritardo cresce fino a una perdita, come previsto, e si ferma al livello della coda piena.

12.11 Il nodo sui core lenti

Il processore del portatile ha tre tipi di core: sei **P-core** veloci (Redwood Cove), otto **E-core** efficienti (Crestmont, in due moduli da quattro che dividono la cache L2 e la frequenza) e due **LP E-core**, che stanno su un'altra parte del chip, fuori dalla cache L3. Che cosa succede se il nodo gira su un core lento?

Per rispondere cambia *solo* il core del nodo. Generatore e nodo successivo restano su P-core a 3,5 GHz, così il generatore satura sempre il nodo e l'uscita non diventa il collo di bottiglia. L'E-core gira anche lui a 3,5 GHz (il suo massimo è 3,8): a parità di frequenza, la differenza di capacità è tutta nel numero di cicli per pacchetto. Il LP E-core gira al suo massimo, 2,5 GHz. Gli altri tre core del modulo dell'E-core restano a riposo: dividono con lui cache e frequenza.

	milioni di pacchetti/s			E/P	istruzioni	IPC
Pipeline	**P-core**	**E-core**	**LP E-core**		**per pacchetto**	**P / E / LP E**
baseline	15,27	9,39	3,29*	0,61	606	2,7 / 1,7 / 0,8
P1	8,56	6,35	3,10	0,74	1 220	3,0 / 2,3 / 1,5
P1.5	8,04	5,84	2,91	0,73	1 426	3,3 / 2,4 / 1,7
P2	3,45	2,83	1,57	0,82	4 556	4,5 / 3,7 / 2,9
P3	2,36	1,94	1,10	0,82	6 573	4,4 / 3,7 / 2,9

Tre giri, alimentatore, 64 byte. Le istruzioni per pacchetto sono le stesse sui tre tipi di core entro il 2%. * Sul LP E-core la baseline non satura (nodo al 93%): il generatore non riesce a offrire di più, e la cifra è un limite inferiore.

Il codice eseguito è lo stesso su ogni core: **cambia l'IPC**, cioè quante istruzioni il core completa per ciclo. E non cambia allo stesso modo per tutte le pipeline.

L'E-core rallenta soprattutto la **parte fissa** del nodo: ricevere il pacchetto dalla coda, inoltrarlo, restituire la pagina. È lavoro del kernel, con salti e accessi alla memoria, e l'E-core lo fa a IPC 1,7 invece di 2,7: la baseline costa 106 ns invece di 66, il 60% in più. L'aritmetica della rete neurale, invece, è una fila di moltiplicazioni senza bivi, e l'E-core la esegue quasi altrettanto bene (IPC 3,7 contro 4,4 per P3): l'inferenza di P3 sopra la baseline costa 409 ns invece di 359, solo il 14% in più. Per questo il rapporto di capacità sale con il peso della pipeline: 0,61 per la baseline, 0,82 per P2 e P3.

Il LP E-core paga anche la memoria: sta fuori dalla L3, e i pacchetti scritti dal generatore gli arrivano da lontano, con 14–19 mancate dell'ultimo livello di cache per pacchetto (zero sugli altri core). Fra la frequenza più bassa e l'IPC più basso regge dal 36 al 47% del P-core sulle pipeline.

Esempio: la saturazione sull'E-core

Le curve del bit rate sull'E-core hanno la stessa forma di quelle del P-core: inoltro pieno fino alla capacità, poi piatto, perdita sempre all'ingresso. Il ginocchio sta più in basso: 6,2 milioni al secondo per P1, 5,8 per P1.5, 2,8 per P2, 1,9 per P3. E a coda piena il ritardo è più lungo, perché ogni pacchetto costa di più: 45 µs per P1, 148 per P3.

12.12 Gli assi sotto traffico vero

Le analisi del capitolo sul costo che cresce — larghezza, profondità, pesi fermi, pesi a zero — sono fatte con il programma da solo. Lo stesso banco di questo capitolo le rifà con traffico vero: diciotto modelli sintetici, uno per punto, con lo stesso descrittore del modello depositato, sul P-core e sull'E-core.

strati da 4 neuroni	1	2	3	4	5	6
P1	113	116	119	124	125	132
P1.5	121	128	131	132	134	138
P2	264	287	329	344	368	396
P3	351	421	486	545	595	652
P3, istruzioni per pacchetto	5 488	6 576	7 663	8 759	9 856	10 952

Nanosecondi di CPU per pacchetto, nodo su un P-core; la baseline resta a 64–67 ns in ogni punto.

Gli andamenti sono quelli del programma da solo, più il costo fisso del nodo. P3 paga circa 60 ns per strato, e i contatori hardware dicono perché: ogni strato aggiunge **esattamente 1 096 istruzioni eseguite**, su P-core e su E-core. Sono le letture che ricostruiscono il contesto a ogni rientro, sempre le stesse. A pesi fermi P2 sale del 35% e P3 del 60% da uno a cinque strati, mentre le P1 restano fra 125 e 135 ns; con il 90% dei pesi a zero P1 passa da 113 a 95 ns e P1.5 da 120 a 106, mentre P2 e P3 non si muovono, con le stesse istruzioni. Sull'E-core ogni punto costa il 20–35% in più.

La sola rete neurale. Il tempo di CPU contiene anche il costo fisso del nodo. Per isolare la rete neurale si usano le tre marcature della build strumentata: T2−T1, meno la stessa misura della baseline, con il traffico a 0,3 e 0,6 milioni di pacchetti al secondo. Il **minimo** per finestra, cioè il pacchetto che trova tutto in cache, coincide con il programma da solo: P3 da 1 a 6 strati 262 → 508 ns contro 246 → 510. La **media**, il costo tipico, sta sopra di 10–40 ns per P1 e P1.5 e di 40–110 ns per P2 e P3 (P3 a 6 strati 610 ns), con gli stessi andamenti su ogni asse; sull'E-core lo scarto è circa doppio. Sul modello depositato la media sopra la baseline (P1 44, P2 229, P3 364 ns) coincide con il tempo di CPU meno la baseline (51, 224, 359): due misure indipendenti dello stesso costo.

strati da 4 neuroni	1	2	3	4	5	6
P2, da solo	157	179	206	227	256	286
P2, media T2−T1	214	252	264	267	324	356
P3, da solo	246	303	356	408	453	510
P3, media T2−T1	322	348	436	509	560	610

Nanosecondi di rete neurale per pacchetto (baseline sottratta), nodo su un P-core. Da solo: `BPF_PROG_TEST_RUN`, minimo su 7 prove.

La rete e l'ingresso. Con una rete diversa per punto, da 10 a 100 nodi, il costo della rete neurale (tempo di CPU meno la baseline) resta piatto su tutte le pipeline: P1 45–52 ns, P2 221–237, P3 351–366, con le stesse istruzioni eseguite. Lo stesso per una one-hot d'ingresso da 16 a 65 colonne; gli ingressi densi invece costano (da 5 a 17 colonne P3 sale di 72 ns). Contando le moltiplicazioni davvero eseguite, ingressi densi, one-hot e larghezza cadono su una retta: circa 0,2 ns per moltiplicazione con i pesi compilati e 0,7 ns per P3 (r^2 0,71–0,94); P2 no, perché il suo costo di partenza cambia con la composizione dell'ingresso.

12.13 Che cosa questo numero non dice

I limiti del banco sono nella sezione 12.6. Uno in più riguarda il modello:

- **Modelli sintetici sugli assi.** Sul traffico vero il modello depositato è misurato in ogni configurazione; le variazioni di forma (sezione 12.12) usano modelli sintetici con lo stesso descrittore, un giro di tre misure per punto.
- **Due tipi di core lenti, a una frequenza.** L'E-core è misurato a 3,5 GHz, non al suo massimo di 3,8; il LP E-core solo al suo massimo.

CAPITOLO 13

La macchina di laboratorio, sotto controllo

Tutte le misure di questo quaderno sono fatte sulla macchina di laboratorio, senza strati di mezzo: un portatile Lenovo IdeaPad Slim 5 con un **Intel Core Ultra 7 155H**, Ubuntu 24.04 installato direttamente sul disco (dual boot), kernel 6.8. Questo capitolo spiega che cosa serve perché le misure si ripetano.

13.1 Un processore che non sta fermo

Il 155H è **ibrido**: tre tipi di core diversi sullo stesso chip.

tipo	CPU	frequenza	note
P-core (prestazioni)	0–11	base 1,4, turbo 4,5–4,8 GHz	6 core fisici, due thread ciascuno
E-core (efficienza)	12–19	base 0,9, turbo 3,8 GHz	
LP E-core	20–21	base 0,7, turbo 2,5 GHz	fuori dalla cache condivisa

Lasciato a sé stesso, un banco su questa macchina finisce dove capita: una regola generica per scegliere i processori (un terzo al nodo, il resto al generatore) darebbe quattordici thread di generatore e metterebbe il nodo sui core di efficienza, e il desktop girerebbe sul gemello del core misurato. La frequenza va da 0,4 a 4,8 GHz secondo il carico, e i core si addormentano in uno stato da cui il risveglio costa 310 microsecondi: più di quanto la coda d'ingresso da 256 posti copra a un milione di pacchetti al secondo.

E il portatile **scalda**. Un solo P-core salito a 4,5–4,8 GHz porta il processore da 51 a 99 °C in due secondi, e il chip riduce la frequenza per difendersi (*throttling*).

13.2 Le condizioni, messe e tolte

`ipa/test/host_conditions.py` mette la macchina in condizioni note per la durata di un banco, e le riporta com'erano alla fine.

- **Ruoli**: nodo, nodo successivo e generatore su core fisici *diversi*, un thread per core; il gemello di ciascuno resta a riposo; il core della CPU 0 resta al sistema. Qui: nodo sulla CPU 6, nodo successivo sull'8, generatore sulla 10. Quando il nodo va su un E-core (la 12) restano a riposo anche gli altri tre core del suo modulo (13–15), che dividono con lui la cache L2 e la frequenza.
- **Frequenza fissa** sui core del banco (governor *performance*, minimo uguale al massimo), e **misurata** dai contatori del processore (APERF/MPERF).
- **Tetto sui core del sistema** (2,5 GHz): il turbo del desktop scalderebbe il chip fino a rallentare anche i core del banco.
- **Niente sonno profondo** sui core del banco: spenti gli stati con risveglio oltre un microsecondo.

- **Isolamento**: desktop, servizi, interruzioni e thread del kernel spostabili confinati sulle CPU del sistema.
- **Frequenza della cache condivisa fissa**, profilo energetico *performance*, watchdog spento.

Ogni valore si salva *prima* di cambiarlo, in un file in memoria. A fine run — anche con Ctrl-C o un errore — si riscrive tutto all'indietro; un run ucciso lascia il file, e il run successivo ripristina per primo. Un test sul kernel vero (`test_host_kernel.py`, 25 controlli) applica le condizioni, le rilegge dal kernel, verifica che un processo del desktop giri solo sulle CPU del sistema, misura la frequenza sotto carico, ripristina e confronta la macchina valore per valore con com'era — anche dopo aver ucciso il processo a condizioni applicate.

Durante ogni misura un **monitor** legge gli interventi di throttling, la temperatura, la frequenza vera del nodo e le interruzioni del firmware. Una finestra misurata fuori dalle condizioni dichiarate viene marcata e contata, non scartata in silenzio.

13.3 La frequenza scritta non è la frequenza vera

La frequenza *base* del processore, 1,4 GHz, è l'unica garantita. Il sistema la accetta e la rilegge: 1 400 minimo, 1 400 massimo. I contatori del processore dicono un'altra cosa:

> Con 1 400 MHz scritti nel sistema, il core gira a **circa 2 000 MHz** — fisso e stabile, ma non a quella frequenza. Da 3 000 MHz in su scritto e vero coincidono entro 10 MHz.

Se il monitor si fidasse del numero scritto, a 1,4 GHz marcherebbe come disturbate 38 finestre su 39. La frequenza di riferimento è quindi quella **misurata** all'avvio, su ogni core del banco; il numero scritto resta accanto, per confronto.

13.4 Quale frequenza

Più alta la frequenza, più alto il throughput — finché il portatile regge. La risposta si è misurata, con un giro corto di `bench_bitrate` per frequenza e due run completi di cinque minuti:

frequenza vera	macchina
2,0–3,5 GHz, 30 s	pulita
4,0 GHz, 30 s	pulita
4,5 GHz, 30 s	throttling su 28 finestre su 39
4,0 GHz, run completo	fino a 98 °C, il core del nodo in throttling
3,5 GHz, run completo	massimo 85 °C, una finestra disturbata su 390

A 4,5 GHz il throughput smette di crescere: il chip si difende. A 4 GHz un run corto è pulito, uno da cinque minuti porta il processore a 98 °C e il core del nodo stesso in throttling. **3,5 GHz** è la frequenza più alta che la macchina regge per un run intero, ed è la frequenza di default del banco.

> La frequenza pesa quasi in proporzione, ma non del tutto: da 3 a 4 GHz il throughput sale del 23% invece del 33%, perché la cache condivisa e la memoria non accelerano con il core. Quello che non si muove è il **rapporto fra pipeline**. Le cifre assolute si citano con la loro frequenza, e con il tipo di core (sezione 12.11).

13.5 Il risultato: misure che si ripetono

banco	variazione
programma da solo (`test_suite`, fra sette prove)	0–7%
throughput a saturazione, quattro misure diverse della stessa sessione	entro il 2%
inoltro allo stesso punto della curva (fra cinque giri)	in genere 0,1%

E i pacchetti respinti con il nodo sotto capacità sono **zero**: il core del nodo non dorme, e nessun altro lavoro gli viene dato.

13.6 Come si rifà tutto

Uno script rifà ogni misura di questo quaderno, nelle stesse condizioni, in circa un'ora. CSV, condizioni della macchina e registri vanno in `results/campagna_<data>/`, con una sintesi delle tabelle; i grafici del quaderno si rigenerano in `docs/figures/`:

```
bash ipa/test/remeasure_campagna.sh        # tutto: traffico su P-, E-, LP E-core, assi,
    kernel
bash ipa/test/remeasure_campagna.sh pcore  # solo una parte
bash ipa/test/remeasure_all.sh             # solo programma, correttezza, analisi
    parametrica
```

CAPITOLO 14

Altri modelli, altre reti

14.1 La domanda

Quasi ogni numero dei capitoli precedenti viene da un modello solo, il 65-4-4-7 addestrato su Germany50. Un banco che funziona solo su quel modello potrebbe avere la sua forma scritta dentro senza che nessuno se ne accorga: gli strati di P3 elencati a mano, sei bit di stato dei link, il significato delle classi letto sempre dalla scheda del checkpoint. Un modello diverso girerebbe allora con i pesi, o con le classi, di un altro. L'obiettivo di questo capitolo: **lo stesso test, per qualsiasi modello e qualsiasi rete**, e un errore chiaro quando la combinazione non ha senso.

14.2 Scenario e modello

Le due parole hanno un significato preciso.

- **Lo scenario è la rete**: quattro numeri in `topologies/<nome>/topology_config.json`, cioè quante interfacce ha al massimo un nodo, quanti nodi ha la rete, quante code ha ogni interfaccia e con che TTL i pacchetti ci entrano.
- **Il modello è la rete neurale**: pesi, forma, ingressi (ognuno con la sua larghezza e la sua scala) e significato di ogni classe.

Scenario	interf.	nodi	code	TTL	modelli che ci girano
`germany50`	6	52	4	30	checkpoint, ipa_like, deep, sparse, sparse_hetero_11
`germany50_ttl16`	6	52	4	16	ipa_ttl16
`synth_small`	3	8	–	16	small
`synth_ones`	3	4	–	8	ones
`synth_large`	8	100	–	64	large
`synth_mixed`	4	12	1	30	mixed

Oltre a Germany50 ci sono le reti dei modelli sintetici. Non sono topologie reali: sono le dimensioni per cui ciascun modello sintetico è stato generato.

14.3 Quando un modello può girare su una rete

Ogni ingresso del modello prende la sua larghezza da una dimensione della rete: lo stato dei link e la porta d'ingresso dalle interfacce, l'identità del nodo dai nodi, l'occupazione delle code dalle code. E il TTL il modello lo legge diviso per il TTL iniziale con cui è stato addestrato (sezione 2.3 nel capitolo sulla matematica). Quindi:

> Un modello gira su una rete solo se **ogni suo ingresso è largo quanto la dimensione della rete da cui dipende** e se **la scala del suo TTL è il TTL iniziale della rete**.

Esempio: il checkpoint ha il one-hot del nodo largo 52. Su una rete da 30 nodi metà delle sue colonne non corrisponderebbe a nessun nodo, e il test si ferma subito con

```
nodi: il modello ne vuole 52, la rete ne ha 30
```

Esempio con il TTL: `ipa_ttl16` ha la stessa forma del checkpoint, ma è addestrato con il TTL diviso per 16. Su Germany50, dove i pacchetti partono da 30, vedrebbe valori fino a quasi 2 invece che fino a 1, fuori da tutto ciò su cui è stato addestrato. Per questo gira sulla sua rete, `germany50_ttl16`.

C'è poi un secondo filtro, fra modello e *pipeline*. Ogni pipeline ha dei tetti fissati quando il programma viene compilato:

- **P2**: al massimo 8 neuroni per strato, strati dal terzo in poi larghi come il secondo, 1 024 pesi in tutto;
- **P3**: al massimo 8 neuroni per strato, 16 strati, 2 048 pesi;
- **P1**: nessuno, perché il programma si genera per quel modello.

Il modello `large` (117-8-8-9) ha 1 097 pesi e un primo strato da 117 per 8: P2 e P3 non lo possono caricare. Non è un errore del test: la combinazione è **non applicabile**, ed è contata a parte.

14.4 Come è costruito

Quattro pezzi, ognuno con un compito solo.

1. `model_source.py` **carica qualsiasi modello nello stesso formato**: il checkpoint, un altro `.pt`, un preset sintetico (`synth:deep`) o una cartella. Il significato delle classi è quello che il modello dichiara. Contiene anche il controllo modello contro rete.
2. `pipeline_limits.py` **dice se una pipeline regge una forma**, con i numeri presi dai moduli che compilano i programmi, così i due non possono divergere.
3. `pipeline_setup.py` **carica un modello in una pipeline**: baseline, P1, P1.5, P2, P3. Sono gli stessi costruttori del confronto a tre vie.
4. `model_under_test.py` **legge** `-model` **e** `-topology` e li passa ai processi figli con due variabili d'ambiente.

Senza `-model` si usa il checkpoint; con `-model checkpoint` si usa lo stesso checkpoint per la strada generica, e il risultato è identico (sezione 14.6).

```
sudo python3 ipa/test/test_suite.py --only kernel --model synth:deep
sudo python3 ipa/test/test_fabric.py --model synth:small
sudo python3 ipa/test/bench_throughput.py --mode compare --generator xdp --model synth:deep
sudo python3 ipa/test/bench_throughput.py --mode compare --generator xdp \
     --model ipa/synth/traffic/depth_3
```

Senza `-topology` viene scelta la rete compatibile (Germany50 se lo è).

14.5 Che cosa controllano i test

Passare un modello diverso chiede controlli precisi in tre punti.

L'azione, non solo la classe. Col checkpoint, fra TTL 2 e 6, la classe è sempre un inoltro; un altro modello può decidere DROP proprio lì. Il test controlla che il programma abbia scelto la classe del riferimento *e* ne abbia eseguito l'azione: redirect per un inoltro, `XDP_DROP` per uno scarto, `XDP_PASS` per una classe inutilizzata.

Tutte le classi che il modello sa decidere. Il fabric cerca un caso per ogni classe cambiando stato dei link e TTL; per le classi che così non trova cambia anche porta d'ingresso,

nodo e code, e ogni caso scrive i suoi valori nelle mappe prima di spedire il pacchetto. Col checkpoint basta lo stato dei link; coi pesi casuali dei sintetici conta anche il resto. Classi consegnate:

Modello	classi consegnate
checkpoint	0, 1, 2, 3, 4, 5
ipa_like, ipa_ttl16	2, 3, 4, 5
small, mixed	0, 1, 2, 3
large	1, 4, 6, 8
deep / sparse / ones	0, 1, 4 / 1, 5 / 0

Le classi che mancano il modello non le decide mai: su 200 000 ingressi casuali `deep` sceglie solo 0, 1 e 4, e `ones`, che ha tutti i pesi uguali a 1, sceglie sempre la classe 0. È una proprietà del modello, non un limite del test.

Il traffico misura un inoltro. I generatori mandano pacchetti con TTL 32. Col checkpoint, con tutti i link attivi, quel pacchetto viene inoltrato; con `large` invece viene scartato, e il banco misurerebbe lo scarto chiamandolo inoltro. Il banco allora cerca lo stato dei link che porta a un inoltro, lo scrive nella mappa e lo stampa:

```
traffico di large con link_state=00111000, TTL 32 -> classe 4 (FORWARD)
```

Se nessuno stato dei link porta a un inoltro, la pipeline non si misura. Fra i modelli degli assi sotto traffico (sezione 12.12) tre, con il seme comune, decidevano lo scarto in tutti i 64 stati: il generatore dei modelli fa lo stesso controllo e, in quei casi, passa al seme successivo.

14.6 La prova che la strada generica non cambia niente

Il checkpoint passato esplicitamente, `-model checkpoint`, va per la strada generica. Confrontato con il checkpoint senza `-model`:

- pesi, scala e significato delle classi identici; il riferimento Python dà la stessa classe e lo stesso logit su 3 000 ingressi;
- il sorgente di P1 e la foglia di P2 sono identici *byte per byte*;
- il riferimento generico coincide con quello scritto per il 65-4-4-7 su 20 000 ingressi.

E la correttezza sui modelli nuovi:

- nel kernel, ogni scenario per ogni modello compatibile per ogni pipeline, 40 ingressi a testa, sotto due identificativi di modello: **110 su 110**, più `large` non applicabile a P2 e P3;
- suite kernel su nove modelli: tutto PASS.

14.7 I risultati

Nel kernel, con `BPF_PROG_TEST_RUN`, nanosecondi per pacchetto (minimo su sette prove; baseline 14–15 ns ovunque):

Modello	forma	P1	P1.5	P2	P3
checkpoint	65-4-4-7	46	51	197	318
ipa_like	65-4-4-7	47	51	194	309
ipa_ttl16	65-4-4-7	40	46	197	310
sparse	65-4-4-7	31	38	197	314
deep	65-4-4-4-7	52	56	226	375
small	15-4-4	30	37	139	226
mixed	18-6-5	36	43	155	257
ones	11-2-3	23	28	129	217
large	117-8-8-9	71	76	—	—

Tre cose si leggono subito.

- **P2 e P3 costano per la forma, P1 per i valori dei pesi.** Checkpoint, `ipa_like`, `ipa_ttl16` e `sparse` hanno la stessa forma: P2 e P3 costano uguale per tutti (194–197 e 309–318 ns), mentre P1 va da 31 ns (`sparse`, pesi a zero tolti in compilazione) a 47.
- **Uno strato in più costa a P2 e P3**: `deep` ha uno strato più del checkpoint e costa +29 ns su P2, +57 ns su P3, +6 ns su P1.
- **Ingressi più piccoli abbassano P2 e P3** di 40–100 ns: il primo strato, che è il più largo, scorre meno colonne.

Sul traffico vero gli stessi effetti — profondità, larghezza, pesi a zero — sono misurati sugli assi, con diciotto modelli sintetici dal descrittore del checkpoint (sezione 12.12).

> Il confronto fra le pipeline non è una proprietà del checkpoint: su nove modelli l'ordine P1 $<$ P1.5 $<$ P2 $<$ P3 resta lo stesso, e i costi si spostano come ci si aspetta dalla forma. La profondità pesa su P2 e P3, l'ampiezza dell'ingresso su tutte, e su P1 più che altrove.

14.8 Che cosa non fa

- **Nessun modello sintetico è addestrato**: servono a provare le pipeline su forme diverse, non a dire qualcosa sull'instradamento.

CAPITOLO 15

Nessun modello privilegiato: la popolazione

15.1 La domanda

Una misura su un modello dice quanto costa *quel* modello. La domanda della tesi è un'altra: quanto costa ciascuna delle quattro pipeline, con qualunque modello ragionevole le si dia. Per rispondere, ogni test delle slide gira qui su una **popolazione di 91 modelli sintetici**, e ogni conclusione ha una di queste quattro forme:

- un **intervallo**: la mediana sulla popolazione e, fra parentesi quadre, il minimo e il massimo, dal modello più leggero al più pesante;
- un **conteggio**: su quanti modelli un'affermazione regge ("85 modelli su 85");
- una **legge**: costo $= a + b \times$ MAC eseguite $+ c \times$ strati, stimata con i minimi quadrati su tutti i modelli densi, con l'errore che fa su modelli lasciati fuori dalla stima;
- un **rapporto modello per modello**: per esempio la capacità sull'E-core divisa quella sul P-core dello stesso modello.

> In questo capitolo nessuna cifra è di un modello solo. Le cifre vengono da `results/popolazione_2026-10/`, raccolte l'11–12 ottobre 2026, e le tira `population_report.py`.

15.2 La popolazione

La genera `ipa/test/model_population.py` (tier `base`), con un seme fisso: rigenerata, è identica byte per byte. Ogni modello ha il suo seme, e un seme si scarta se il modello non inoltra il pacchetto di prova o non raggiunge almeno due classi.

Famiglia	modelli	che cosa varia
base	53	7 composizioni dell'ingresso × profondità 1, 2, 3, 4, 6 × larghezza 2, 4, 8 (metà delle combinazioni), 3–7 uscite
replica	20	6 forme, 3 semi in più ciascuna (uno con pesi a distribuzione normale): quanto il costo dipende dai pesi estratti
sparsità	8	4 forme con il 50 e il 90 % dei pesi esattamente a zero
imbuto	10	5 forme con circa 592 pesi distribuiti su 1–5 strati, su 2 composizioni
totale	91	5–117 ingressi, 1–6 strati, 2–8 neuroni per strato, 21–1 349 pesi, 16–480 MAC eseguite

Le sette composizioni dell'ingresso mettono insieme in modi diversi le feature dense (stato dei link, occupazione delle code, TTL) e le one-hot (interfaccia d'ingresso, identità del

nodo): `dense5` e `dense17` solo dense, `onehot105` quasi solo one-hot, `ipa17`, `ipa65`, `ipa117` e `mixed33` miste, con reti da 10, 24, 52 e 100 nodi.

Sei modelli superano il tetto sui pesi di P2 (`MAX_WEIGHT_ENTRIES`): restano nella popolazione, e per P2 le cifre sono su 85 modelli. Le altre pipeline li eseguono tutti.

I test lunghi girano su sottoinsiemi scelti dal modello più leggero al più pesante: 6 modelli per le curve a traffico crescente e per le taglie del pacchetto, 14 per il LP E-core, 8 per i due core e per le classi, 12 per i TTL misti.

15.3 Come si misura, e quanto è pulito il dato

Tutto lo fa `ipa/test/remeasure_popolazione.sh`, con lo stesso disegno dei core delle altre campagne: cambia solo il core del nodo (P-core cpu6, E-core cpu12, LP E-core cpu20), il generatore e l'uscita restano su P-core, i core del banco a 3,5 GHz (2,5 il LP E-core).

Sezione	che cosa misura
`corretto`	riferimento intero contro eBPF, ogni modello e ogni pipeline (`BPF_PROG_TEST_RUN`, 200 ingressi)
`rif`	rxonly e baseline senza modello, una volta per tipo di core
`pop`	ogni modello su P-core ed E-core: capacità, tempo di CPU, istruzioni e cicli per pacchetto, programmi caricati; e $T_2 - T_1$, $T_3 - T_2$ a 0,25 e 0,5 milioni di pacchetti al secondo
`lpe`, `carico`, `core2`	i sottoinsiemi: LP E-core, traffico crescente, due core
`classi`, `mix`, `taglie`	una sessione per classe, TTL diversi a ogni pacchetto, 64/512/1 514 byte

La campagna dura 3 h 54 min e riprende da dove si è fermata: una misura il cui CSV c'è già si salta. Ogni misura scrive accanto ai numeri le condizioni della macchina, e `population_report.py` lascia fuori da ogni intervallo e da ogni legge quelle in cui la macchina non è rimasta nelle condizioni dichiarate o che il controllo di validità del banco ha bocciato; le elenca in `escluse.csv`, e `POP_RIFAI_DISTURBATE=1` le rifà.

Il throttling del portatile

Con l'alimentatore collegato e a 57–72 °C, su questo portatile un evento di throttling di pacchetto arriva circa una volta al minuto, comunque si usi la macchina: lo decide il firmware. Una misura corta (25–70 s) lo prende di rado, e si rifà. Una curva a traffico crescente dura circa 160 s e lo prende quasi sempre: rifarla non converge. Per le curve il report tiene allora le finestre pulite, purché ogni punto ne conservi almeno 2 su 3, e ricalcola la curva con la stessa funzione del banco.

Alla fine: **una sola misura fuori su 435**, e 8 curve tenute senza le finestre colpite (17 finestre su 1 920).

15.4 Correttezza

Su ogni modello il riferimento intero e il programma eBPF decidono la stessa classe, pacchetto per pacchetto: **P1 su 91 modelli su 91, P2 su 85 su 85, P3 su 91 su 91**. I 6 modelli fuori da P2 sono quelli oltre il suo tetto sui pesi: un limite della pipeline, non un errore.

15.5 Il costo del nodo

	baseline	P1 statica	P1.5	P2	P3
P-core, 64 byte, nodo saturo: mediana [minimo–massimo]					
ns di CPU per pacchetto	67	119	126	291	486
	[64–69]	[85–221]	[86–222]	[196–512]	[307–918]
costo della rete (ns)	—	52	59	225	420
		[19–155]	[19–156]	[129–446]	[240–852]
milioni di pacchetti al secondo	15,0	8,4	8,0	3,4	2,1
	[14,5–15,3]	[4,5–11,7]	[4,5–11,6]	[2,0–5,1]	[1,1–3,3]
istruzioni eseguite per pacchetto	606	1 162	1 346	4 578	7 575
istruzioni caricate	135	624	961	16 813	12 288
istruzioni per ciclo	2,6	2,9	3,2	4,5	4,4

91 modelli (P2: 85). Ricevere costa 40 ns (rxonly), leggere l'intestazione e inoltrare altri 27: la baseline, uguale con ogni modello.

Modello per modello, sopra la baseline:

- **P1 $\leq$ P2 $\leq$ P3 su 85 modelli su 85**;
- rendere configurabile la forma (P2) costa **4,3 [2,7–12,8] volte** P1, anche la profondità (P3) **7,8 [4,9–24,6] volte**; P3 costa 1,9 [1,4–2,3] volte P2; P1.5 costa 1,1 [0,9–1,7] volte P1. I rapporti più alti vengono dai modelli più piccoli, dove P1 costa poche decine di ns;
- P2 carica più istruzioni di P3 ma ne esegue meno su 85 modelli su 85: la dimensione del programma non ordina le pipeline per lavoro. Dentro una pipeline la dimensione ordina bene i modelli per P1 (correlazione di rango 0,98), meno per P1.5 (0,90) e P2 (0,77); P3 ha la stessa dimensione, 12 288 istruzioni, con ogni modello.

15.6 P-core, E-core, LP E-core

E-core rispetto al P-core	baseline	P1 statica	P1.5	P2	P3
capacità E/P	0,63	0,77	0,76	0,82	0,83
	[0,61–0,66]	[0,70–0,91]	[0,68–0,88]	[0,77–0,87]	[0,72–0,89]
istruzioni per ciclo E/P	0,65	0,79	0,78	0,84	0,84
cicli della rete E/P	—	0,94	0,99	1,10	1,13
		[0,55–1,17]	[0,59–1,34]	[1,02–1,18]	[1,05–1,40]
LP E-core rispetto al P-core					
capacità LP/P (14 modelli)	0,26	0,35	0,35	0,45	0,48
		[0,32–0,45]	[0,32–0,44]	[0,42–0,48]	[0,45–0,53]

- **Le istruzioni per pacchetto non dipendono dal core**: fra P-core ed E-core differiscono al più dello 0,3 % su 91 modelli, sul LP E-core al più dello 0,7 % sulle pipeline.
- **L'E-core rallenta il nodo, non la rete**: la parte fissa (i cicli della baseline) passa da 231 a 360 cicli, 1,56 [1,50–1,61] volte, su ogni modello. I cicli della sola rete cambiano poco. Per questo la capacità E/P sale con il peso della pipeline: più tempo nella rete, meno conta il core.
- **Il LP E-core paga anche la memoria**: sta fuori dalla L3 e ha 14–19 mancate dell'ultimo livello di cache per pacchetto (zero su P-core ed E-core). Con IPC 1,0–3,0 e 2,5 GHz regge dal 32 al 53 % del P-core sulle pipeline.

15.7 Sotto traffico crescente, e con due core

Le curve a traffico crescente (da 0,5 a 12 milioni di pacchetti al secondo, sei modelli, P-core ed E-core) salgono lungo la diagonale fino alla capacità e poi restano piatte. Il massimo inoltrato sta a **0,98 [0,88–1,03]** della capacità a massima spinta sul P-core e a **0,99 [0,94–1,03]** sull'E-core, su 24 curve per core. Della perdita oltre la capacità, la quota persa alla coda d'ingresso, prima del programma, è 1,000 in mediana: il collo di bottiglia è il programma eBPF.

L'eccezione

P1 sui modelli più leggeri regge oltre 9 milioni di pacchetti al secondo. Lì comincia a perdere anche l'uscita: la quota persa alla coda scende fino a 0,69, il massimo inoltrato fino a 0,88 della capacità. È il limite del cavo virtuale e del core d'uscita, non della rete neurale.

Con **due core** del nodo, ciascuno con la sua coda e il suo core d'uscita, la capacità è il **99 [94–103] %** del doppio sul P-core e il **99 [98–101] %** sull'E-core, su 40 coppie modello-pipeline per core.

15.8 Il programma, il trasporto, e due modi di misurare la rete

Con i tre orologi (T_1 all'ingresso, T_2 prima di inoltrare, T_3 all'arrivo al nodo successivo):

- **il trasporto** $T_3 - T_2$ (redirect, cavo virtuale, ricezione) è 187–221 ns sul P-core e 226–274 sull'E-core, su ogni modello; fra la pipeline più cara e la meno cara dello stesso modello differisce del 4 [1–17] %. È il minimo: la media contiene l'attesa in coda, perché qui l'uscita gira sul core del nodo, e cresce col traffico (da circa 550 a circa 1 200 ns fra 0,25 e 0,5 milioni di pacchetti al secondo);
- **il programma** $T_2 - T_1$ (minimo) va da 27 ns per la baseline a 391 per P3 in mediana, e per P3 da 237 a 797 ns secondo il modello.

Il costo della rete si ricava in due modi indipendenti: tempo di CPU a nodo saturo meno la baseline, oppure media di $T_2 - T_1$ a traffico leggero meno la baseline. Il loro rapporto, modello per modello:

traffico leggero / nodo saturo	P1 statica	P1.5	P2	P3
P-core	0,77 [0,48–1,02]	0,83 [0,50–1,02]	1,03 [0,94–1,09]	1,02 [0,94–1,11]
E-core	1,27 [0,34–2,73]	1,22 [0,30–2,52]	1,08 [0,93–1,35]	1,07 [0,82–1,13]

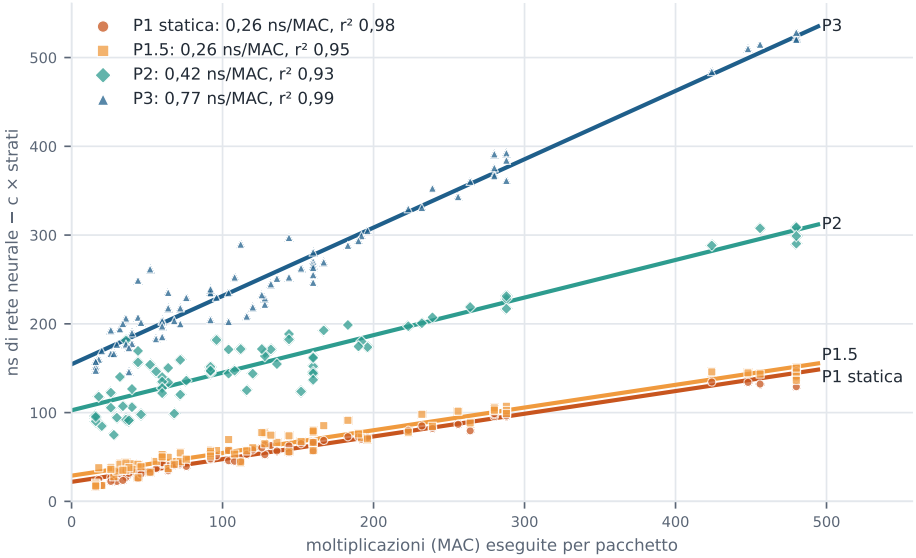
Per **P2 e P3 le due misure coincidono** su ogni modello. Per P1 e P1.5 no: la loro rete costa poche decine di ns sopra una baseline di circa 67, e la differenza fra due misure grandi è rumorosa. Il loro costo della rete si cita con il metodo che lo ha misurato; quello di riferimento è il tempo di CPU a nodo saturo, il costo che il nodo paga davvero.

15.9 La legge di costo

La legge è stimata sugli 83 modelli densi (famiglie base, replica e imbuto; 77 per P2), sul P-core:

	a (ns)	b (ns/MAC)	c (ns/strato)	r^2	errore su modelli non visti
P1 statica	22	0,26	1	0,98	6 %
P1.5	29	0,26	1	0,95	9 %
P2	103	0,42	20	0,93	6 %
P3	154	0,77	46	0,99	3 %

Errore = errore relativo mediano su un modello lasciato fuori dalla stima, uno alla volta. Sull'E-core P3 vale 153 ns + 0,79 ns/MAC + 62 ns/strato.



Ogni punto è un modello denso: costo della rete meno $c\times$ strati, contro le MAC eseguite. Le rette sono $a + b\times$ MAC.

Il trucco è contare le moltiplicazioni **davvero eseguite**. Una feature one-hot occupa molte colonne nella matrice dei pesi ma ne attiva una sola. Contando le MAC dalla forma del modello la legge spiega meno (r^2 0,58–0,79); contando quelle eseguite spiega il costo di tutte e quattro le pipeline, e prevede un modello nuovo con qualche punto percentuale di errore.

Dove va il tempo

La legge dice anche *dove* va il tempo. Per ogni modello denso si divide il costo previsto nei suoi tre termini; la tabella dà la quota mediana di ciascuno.

	fisso (a)	moltiplicazioni ($b\times$ MAC)	strati ($c\times$ strati)
P1 statica	40 % [14–77]	50 % [14–80]	8 % [3–20]
P1.5	48 % [18–83]	46 % [12–78]	5 % [2–14]
P2	47 % [23–69]	18 % [5–46]	31 % [18–54]
P3	37 % [18–60]	18 % [5–44]	39 % [23–64]

Con i pesi nel codice (P1, P1.5) circa metà del tempo è aritmetica. Con i pesi in tabella (P2, P3) circa l'82 % è **struttura**: il termine fisso (dispatcher, lettura del descrittore del modello, costruzione degli ingressi da tabella) e quello per strato (la tail call allo strato generico e la rilettura del suo contesto). La legge è lineare proprio per questo: ogni tail call e ogni lettura di tabella costa quasi sempre lo stesso, e quante ce ne sono dipende solo dalla forma del modello.

Anche il termine per moltiplicazione contiene le tabelle: P3 paga 0,77 ns per MAC contro 0,26 di P1 perché legge ogni peso dalla memoria di una mappa, in un ciclo non srotolato, mentre in P1 il peso è una costante nel codice. Nessun pezzo del costo per pacchetto passa dallo user space: le mappe si leggono dentro il kernel (`bpf_map_lookup_elem`, che per le mappe array il verifier di solito sostituisce con un calcolo di indirizzo), e lo user space le scrive solo quando installa un modello. Le letture e i salti si contano (sezione 15.11): P3 fa 35 [23–54] letture di tabella per pacchetto, circa 6 in più per strato, e un salto per strato. Quanto dei 46 ns per strato sia il salto e quanto le letture, la campagna non lo separa.

La stessa forma spiega le istruzioni: P3 esegue **901 istruzioni in più per ogni strato** (r^2 0,99), identiche su P-core ed E-core, P2 370. È il salto allo strato generico e la rilettura del suo contesto da tabella. Le istruzioni caricate: P2 ne aggiunge 887 per strato (r^2 0,96), perché ricompila e srotola per ogni profondità; P3 ne ha 12 288 con ogni modello.

15.10 La forma del modello

- **Profondità.** A MAC ferme uno strato in più costa circa 46 ns a P3, 20 a P2, 1 a P1 e P1.5 (la legge). P2 lo paga anche in spazio, con un programma più grande da ricompilare.
- **A parità di pesi** (famiglia imbuto, 592 pesi da 1 a 5 strati), da 1 a 5 strati la rete costa il 48 [44–53] % in più a P2 e il 63 [55–70] % in più a P3, circa 27 e 58 ns per strato; a P1 e P1.5 il 14–17 %, circa 4 ns per strato. Con le pipeline generiche conviene una rete larga e poco profonda; con le specializzate la forma si sceglie per l'accuratezza.
- **Larghezza.** Da 2 a 8 neuroni per strato la rete sale su tutte (in mediana P1 da 37 a 90 ns, P3 da 389 a 537): un neurone in più è lavoro a ogni pacchetto. La legge lo conta nelle MAC.
- **Taglia della rete.** Sui 56 modelli con l'identità del nodo in ingresso (reti da 10 a 100 nodi), lo scarto dalla legge non cresce con i nodi: al più 0,03 ns per nodo, su tutte le pipeline. La one-hot del nodo attiva una colonna sola, qualunque sia la sua larghezza.
- **Pesi a zero.** Al 90 % di zeri P1 costa 0,44 [0,31–0,63] volte quanto la legge densa prevede per la stessa forma, P1.5 0,62 [0,27–0,83], e il programma di P1.5 scende a 0,34–0,35 volte quello del modello denso: il compilatore cancella le moltiplicazioni per zero. P2 e P3 restano sulla legge (1,02 e 1,01) con un programma identico.
- **I pesi estratti.** Sei forme con quattro semi ciascuna: il costo della rete varia al più del 5–6 % per P1, P1.5 e P2 e del 2 % per P3 (coefficiente di variazione fra i semi).

15.11 Il programma da solo, e il cambio di modello

La sezione `solo` della campagna (`bench_solo.py`) carica ogni modello in ogni pipeline con lo stesso costruttore dei banchi sotto traffico, e lo esegue con `BPF_PROG_TEST_RUN` sul pacchetto e con gli ingressi del traffico: TTL 32, il nodo e la porta del fabric, lo stato dei link che

fa inoltrare il modello. Ogni misura ha inoltrato il pacchetto in tutte le esecuzioni; 2 misure su 91 sono fuori perché la macchina era disturbata.

	baseline	P1 statica	P1.5	P2	P3
letture di tabella per pacchetto	3	5 [4–5]	6 [5–6]	12 [11–12]	35 [23–54]
salti fra programmi per pacchetto	0	1	1	1	1 per strato
installare un modello (ms)	—	0,6 [0,3–1,5]	0,9 [0,3–5,6]	0,3 [0,2–0,4]	0,3 [0,2–0,5]
generare e compilare P1 (ms)	—	49 [34–114]	61 [34–181]	—	—
compilare il programma generico (s)	—	—	—	1,6 [1,5–1,7]	1,2 [1,2–1,2]

Mediana [minimo–massimo] su 89 modelli (P2: 83). Installare = un modello nuovo su un nodo in servizio: per P1 caricare l'oggetto compilato (verifier e JIT), per P2 e P3 scrivere le tabelle. Generare e compilare P1 si fa fuori dal nodo, con clang senza cache, su 91 modelli.

- **La configurabilità si conta.** Le letture di tabella per pacchetto crescono da P1 a P3, e per P3 crescono con la profondità: circa 6 letture in più per strato. I salti fra programmi di P3 sono uno per strato su 89 modelli su 89. È la struttura che la legge di costo vede nel termine per strato.
- **Cambiare modello costa millisecondi o meno a tutte**, su ogni modello: sul nodo al più 6 ms. La differenza fra le pipeline è dove serve un compilatore: P1 ne vuole uno per ogni modello nuovo, fuori dal nodo (34–181 ms); P2 e P3 compilano il programma generico una volta sola, all'avvio.
- **Il programma da solo, a chiamate singole**, costa per P2 e P3 quanto sotto traffico o poco di più: la rete a nodo saturo sta a 0,94 [0,77–1,10] e 0,91 [0,84–0,97] volte la rete da sola. Ogni esecuzione è una chiamata al kernel, che raffredda cache e predittori come fa il traffico. Il programma in un ciclo caldo, senza nulla in mezzo, la popolazione non lo misura.

15.12 Il resto è solido

Sui sottoinsiemi, dal modello più leggero al più pesante:

- **taglia del pacchetto**: fra 64 e 1 514 byte il tempo del nodo cambia di 1,2 [0,3–3,1] % (30 coppie modello-pipeline);
- **porta d'uscita**: le classi che inoltrano costano uguale, 0 [0–9] % fra la più cara e la meno cara; scartare costa 51 [17–63] ns in più, perché la memoria del pacchetto si libera sul core del nodo (un effetto del banco);
- **TTL diversi a ogni pacchetto**: 0 [−6–4] % sul tempo del nodo rispetto al pacchetto fisso (48 coppie).

15.13 Le affermazioni, e su che cosa reggono

Affermazione	sulla popolazione
Tutte le pipeline decidono come il riferimento intero	P1 91/91, P2 85/85, P3 91/91
P2 ha un tetto sui pesi che le altre non hanno	6 modelli su 91 fuori da P2
$P1 \leq P2 \leq P3$ nel costo della rete	85/85
Rendere configurabile la forma costa più volte P1	P2/P1 4,3 [2,7–12,8], P3/P1 7,8 [4,9–24,6]

Affermazione	sulla popolazione
P2 è il programma più grande ma P3 esegue di più	85/85
Le istruzioni per pacchetto non dipendono dal core	entro 0,3 % (P/E), 0,7 % (LP)
L'E-core rallenta soprattutto la parte fissa	cicli fissi E/P 1,56 [1,50–1,61]
Il LP E-core regge un terzo–metà del P-core	0,32–0,53 sulle pipeline
Oltre la capacità si perde alla coda d'ingresso	quota 1,000 [0,689–1,000]
Il ginocchio coincide con la capacità	0,98 [0,88–1,03] (P), 0,99 [0,94–1,03] (E)
Due core reggono il doppio	99 [94–103] % (P), 99 [98–101] % (E)
Il trasporto è un costo comune	187–221 ns (P), 226–274 (E)
Traffico leggero e nodo saturo danno lo stesso costo (P2, P3)	1,03 e 1,02 [0,94–1,11]
Il costo segue a + b × MAC eseguite + c × strati	r^2 0,93–0,99, errore 3–9 %
Con i pesi in tabella pesa la struttura, non l'aritmetica	P2, P3: ∼82 % fisso + strati
Le MAC eseguite spiegano meglio di quelle della forma	4 pipeline su 4
Ogni strato di P3 costa le stesse istruzioni	+901 per strato, r^2 0,99
A pari pesi la profondità si paga solo con P2 e P3	+48 % e +63 % da 1 a 5 strati
La taglia della rete non costa	$\leq$ 0,03 ns per nodo
I pesi a zero aiutano solo P1 e P1.5	0,44 e 0,62 del previsto al 90 %
I pesi estratti contano poco	variazione $\leq$ 6 % (P3 2 %)
Le letture di tabella crescono da P1 a P3, e con gli strati	5, 6, 12, 35 [23–54]; +6 per strato
P3 salta una volta per strato	89/89
Cambiare modello costa millisecondi o meno sul nodo	$\leq$ 6 ms; P1 compila fuori in 34–181 ms
Taglia del pacchetto, porta, TTL non contano	1,2 %, 0 %, 0 % in mediana

15.14 Che cosa non dice

- **I modelli sono sintetici**: coprono forme, composizioni e pesi, non l'accuratezza di un modello addestrato.
- **Il programma in un ciclo caldo non è misurato sulla popolazione**: il programma da solo è misurato a chiamate singole, che non tengono cache e predittori caldi fra un'esecuzione e l'altra.
- **Le letture di tabella e i salti si contano, ma non si separano nel tempo**: quanto dei circa 46 ns per strato di P3 sia il salto e quanto le letture, la campagna non lo dice.
- **Il cambio di modello è misurato sul nodo, non durante il traffico**: che cosa succede ai pacchetti che passano mentre le tabelle cambiano resta da provare.
- **Il banco resta un portatile con cavi virtuali**: nessuna scheda di rete, generatore sulla stessa macchina. I costi del programma sono quelli veri; quello di ricezione su una scheda vera può essere diverso.

15.15 Come rifarla

```
cd ~/Scrivania/ipa_lab
CAMPAGNA=results/popolazione_2026-10 bash ipa/test/remeasure_popolazione.sh
# prova breve, due modelli in tutte le sezioni
CAMPAGNA=results/prova_pop POP_SOLO="m000 m037" bash ipa/test/remeasure_popolazione.sh
```

```
# rifare solo cio' che il report ha lasciato fuori
CAMPAGNA=results/popolazione_2026-10 POP_RIFAI_DISTURBATE=1 bash ipa/test/
    remeasure_popolazione.sh
# la sintesi, le slide e la figura di questo capitolo
python3 ipa/test/population_report.py results/popolazione_2026-10 > sintesi.md
python3 docs/slides_src/popolazione.py results/popolazione_2026-10 --pptx
```

CAPITOLO 16

I numeri in una pagina

	baseline	P1 statica	P1.5	P2	P3
Il nodo su traffico vero, un P-core (capitolo 12), 64 byte					
milioni di pacchetti al secondo	15,27	8,56	8,04	3,45	2,36
ns di CPU per pacchetto	66	117	124	290	425
costo della rete (sopra la baseline)	—	51 ns	58 ns	224 ns	359 ns
istruzioni eseguite per pacchetto	606	1 220	1 426	4 556	6 573
istruzioni per ciclo	2,7	3,0	3,3	4,5	4,4
pulita fino a (bit rate)	$\geq$ 4,05	4,04	4,08	1,54	1,02 Gbit/s
Lo stesso nodo su un E-core e su un LP E-core					
milioni di pacchetti al secondo, E-core	9,39	6,35	5,84	2,83	1,94
rispetto al P-core	0,61	0,74	0,73	0,82	0,82
milioni di pacchetti al secondo, LP E-core	$\geq$ 3,29	3,10	2,91	1,57	1,10
Il solo programma					
$T_2 - T_1$ sul percorso vero (minimo)	26 ns	60 ns	69 ns	216 ns	331 ns
`BPF_PROG_TEST_RUN`, pesi del modello	14 ns	46 ns	52 ns	194 ns	318 ns
istruzioni del programma caricato	135	606	1 019	15 089	12 288
Cambiare modello su un nodo in servizio					
caricare sul nodo	—	0,4–2,2 ms (AOT)		10–12 ms	
anche generare e compilare	—	57–121 ms		non serve	
serve un compilatore sul nodo?	—	no (compilato prima)		no	

Campagna del 6 ottobre (`results/campagna_2026-10-06/`), core del banco a 3,5 GHz (2,5 il LP E-core). Il bit rate si misura su una griglia di valori: "pulita fino a" è l'ultimo punto della griglia senza perdite, non la capacità esatta.

In quattro righe:

1. **Scrivere i pesi nel programma costa circa 50–60 ns per pacchetto sul nodo; leggerli da una tabella 225–360 ns.** È il prezzo della configurabilità.
2. **Con l'oggetto precompilato, cambiare modello costa pochi millisecondi per tutte le pipeline**. Il vantaggio residuo di P2 e P3 è non dover compilare niente, da nessuna parte.
3. **Congelare anche il nodo (P1 statica) vale poco ma si vede**: circa 7 ns sul percorso vero, 5–7 ns sul solo programma, e la dimensione non dipende più dalla taglia della rete.
4. **Su un core lento il codice è lo stesso, l'IPC no**: un E-core regge dal 61% (baseline) all'82% (P2, P3) del P-core, perché rallenta soprattutto la parte fissa del nodo e poco l'aritmetica della rete.

CAPITOLO 17

Quel che resta aperto

- **Il costo del nodo di baseline e** `rxonly` con pacchetti grezzi: con un thread per coda il generatore non le satura sul P-core, e più thread intralciano la coda (sezione 12.8); sul LP E-core il generatore non satura nemmeno la baseline. Serve un generatore più veloce su un solo scrittore, o una scheda vera.
- **Tre marcature e latenza minima su modelli diversi**: solo col checkpoint (capitolo 14).
- **Gli E-core al loro massimo**, 3,8 GHz: misurati solo a 3,5.
- **Hardware vero**: una scheda di rete con XDP nativo e una seconda macchina, per un numero che non sia di un cavo virtuale.
- **Il tetto sull'uscita di P2**: lo strato finale è srotolato a 32 classi per un modello che ne ha 7. Abbassarlo ridurrebbe il programma ma *restringe l'insieme dei modelli rappresentabili*.
- **I salti fra programmi di P3**: tre per pacchetto, ed è lì (con le letture che li accompagnano, 1 096 istruzioni per strato) che sta la latenza.
- **La profondità massima di P2** fra 20 e 37 strati: il punto esatto in cui clang si ferma non è misurato.
- **Isolamento dal boot**: i core del banco sono isolati a sistema acceso; l'isolamento completo (tick e callback del kernel) richiede parametri di avvio.

CAPITOLO 18

I comandi

Tutti i comandi si lanciano dalla radice del repository. `sudo` serve ovunque si carichi un programma nel kernel o si tocchi un'interfaccia; senza `sudo` girano solo le prove che non escono da Python.

Prerequisiti

Linux con BCC installato; per l'oggetto AOT di P1 anche

```
sudo apt install clang libbpf-dev libelf-dev zlib1g-dev libzstd-dev liblzma-dev
```

Il generatore (`xdp_gen`) è uno script del repository; il modulo `pktgen`, per l'alternativa, il banco lo carica da sé.

18.1 La macchina

```
# topologia, piano dei ruoli e condizioni attuali (niente root)
python3 ipa/test/host_conditions.py --show

# un comando qualunque sul core del nodo, a condizioni applicate
sudo python3 ipa/test/host_conditions.py --run -- CMD ...

# se un run e' stato ucciso: rimette la macchina com'era
sudo python3 ipa/test/host_conditions.py --restore

# le condizioni verificate: su un /sys finto, e sul kernel vero
python3 ipa/test/test_host_conditions.py
sudo python3 ipa/test/test_host_kernel.py --bench

# tutte le misure del quaderno (circa un'ora)
bash ipa/test/remeasure_campagna.sh
```

18.2 Correttezza: il modello fa quello che deve

```
python3 ipa/test/test_suite.py
python3 ipa/test/test_class_semantics.py
python3 ipa/test/test_synth.py
python3 ipa/test/verify_synth_kernel.py --all --dry-run
```

18.3 Kernel: si carica, e quanto costa

```
sudo python3 ipa/test/host_conditions.py --run -- \
     python3 ipa/test/test_suite.py --only kernel
sudo python3 ipa/test/verify_multi_model.py
sudo python3 ipa/test/verify_per_model_semantics.py
sudo python3 ipa/test/verify_synth_kernel.py --all --n 300
```

```
sudo python3 ipa/test/verify_synth_kernel.py --all --n 300 --pipeline p2
sudo python3 ipa/test/verify_synth_kernel.py --all --n 300 --pipeline p3
```

18.4 Altri modelli, altre reti

```
python3 ipa/test/test_model_source.py
sudo python3 ipa/test/test_model_source.py --kernel
sudo python3 ipa/test/host_conditions.py --run -- \
     python3 ipa/test/test_suite.py --only kernel --model synth:deep
sudo python3 ipa/test/test_fabric.py --model synth:small -q
python3 ipa/test/traffic_models.py          # i modelli degli assi sotto traffico
```

18.5 Datapath reale: il pacchetto attraversa davvero

```
sudo python3 ipa/test/test_fabric.py
sudo python3 ipa/test/test_fabric.py --method aot
sudo python3 ipa/test/test_fabric.py --sweep
sudo python3 ipa/test/netns_fabric.py --cleanup
```

18.6 Analisi parametrica: come cresce il costo

```
sudo python3 ipa/test/host_conditions.py --run -- \
     python3 ipa/test/bench_scaling.py --axis all --out results/
sudo python3 ipa/test/host_conditions.py --run -- \
     python3 ipa/test/bench_scaling.py --axis campaign --out results/
python3 ipa/test/bench_scaling.py --plot results/
sudo python3 ipa/test/bench_scaling.py --verify
sudo python3 ipa/test/bench_scaling.py --verify-ports
sudo python3 ipa/test/host_conditions.py --run -- \
     python3 ipa/test/bench_depth_vs_width.py
```

18.7 Il test reale

```
# tutto il traffico: P-core, E-core, LP E-core, assi; poi la sintesi
bash ipa/test/remeasure_campagna.sh pcore ecore lpe assi
python3 ipa/test/campaign_report.py results/campagna_2026-10-06

# capacita' a un core: nodo su un P-core (6) o su un E-core (12)
sudo python3 ipa/test/bench_throughput.py --mode compare --generator xdp \
     --rounds 3 --gen-cpus 10 --dut-cpus 6 --egress-cpu 8 --out results/pcore
sudo python3 ipa/test/bench_throughput.py --mode compare --generator xdp \
     --rounds 3 --gen-cpus 10 --dut-cpus 12 --egress-cpu 8 --out results/ecore

# il bit rate crescente: latenza, ricevuti, inoltrati, dove si perde
sudo python3 ipa/test/bench_bitrate.py --generator xdp --gen-cpus 10 \
     --dut-cpus 6 --egress-cpu 8 --out results/bitrate
python3 ipa/test/bench_bitrate.py --report results/bitrate

# le tre marcature T1/T2/T3 su una scala di rate
sudo python3 ipa/test/bench_throughput.py --mode rates --generator xdp \
     --gen-cpus 10 --dut-cpus 6 --frames 64 --rounds 3 --rates 0.05,0.5,1,1.5,2,2.5,3
```

```
# per classe e per taglia
sudo python3 ipa/test/bench_throughput.py --mode compare --generator xdp \
     --gen-cpus 10 --dut-cpus 6 --egress-cpu 8 --per-class --rounds 3
sudo python3 ipa/test/bench_throughput.py --mode compare --generator xdp \
     --gen-cpus 10 --dut-cpus 6 --egress-cpu 8 --frames 64,512,1514 --rounds 3

# i contatori hardware, a mano
sudo python3 ipa/test/hw_counters.py --cpu 6,12,20 --seconds 1

# la finestra di misura e le formule, verificate senza kernel
python3 ipa/test/test_steady_window.py
python3 ipa/test/test_bitrate_math.py

# se un run si interrompe e lascia il generatore configurato
sudo python3 ipa/test/bench_throughput.py --cleanup
```

Come si legge l'uscita

Condizioni del test — in testa, e in `env.csv`: ruoli, frequenza scritta e misurata, temperatura, interventi di throttling durante il run.
Controllo di validità — la baseline deve essere la più veloce entro il 10% e `rxonly` non deve essere più lento della baseline. Se una delle due cose non vale, il run misura il banco e non le pipeline.
Finestre marcate — «macchina» (fuori dalle condizioni dichiarate), «raffica» o «gen» (il generatore non ha offerto il carico chiesto): contate e riportate, non scartate.

18.8 Costi specifici e oggetto precompilato

```
sudo python3 ipa/test/bench_tailcall_overhead.py
python3 ipa/methods/method4_hardcoded_aot.py --build-only   # build, come utente
sudo python3 ipa/methods/method4_hardcoded_aot.py           # verifica e bench
sudo python3 ipa/test/diag_verifier.py                      # statistiche del verificatore
```

18.9 L'ordine consigliato

Partendo da zero su una macchina nuova:

1. `python3 ipa/test/host_conditions.py -show` — com'è fatta la macchina, e dove andrebbe il banco?
2. `python3 ipa/test/test_synth.py` — il C generato per P1 calcola il modello? (`test_suite.py`, che controlla estrazione dei pesi e quantizzazione, richiede PyTorch)
3. `sudo python3 ipa/test/test_host_kernel.py` — le condizioni si mettono e si tolgono davvero?
4. `sudo python3 ipa/test/test_fabric.py` — il pacchetto attraversa davvero?
5. `bash ipa/test/remeasure_campagna.sh` — tutti i numeri.